

# Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

# Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

# Conceptos básicos

## Introducción

- El problema de filtrado
- Algoritmos de filtrado adaptivo
- Aplicaciones

## Procesos estacionarios y modelado

- Modelos estocásticos AR, MA y ARMA
- El problema de los autovalores

# Filtro de Wiener

## Filtros de Wiener

- El problema de filtrado optimo lineal
- El error medio cuadrático mínimo
- Ecuaciones de Wiener-Hopf

## Predicción lineal

- Predicción lineal forward y backward
- Predictores Lattice
- Estimación conjunta y en bloques

# Filtro de Kalman

## Filtros Kalman

- El problema de filtrado Kalman
- Predicción usando innovaciones
- Filtrado y variantes del filtro de Kalman

# Menor Cuadrado Mínimo (LMS)

## Método de Steepest Descent

- Algoritmo Steepest Descent
- Estabilidad del algoritmo

## Algoritmo LMS

- Ajuste de los coeficientes
- Estabilidad y desempeño del algoritmo LMS
- El algoritmo LMS normalizado

## Filtrado adaptativo en el dominio frecuencia

- Filtrado adaptativo en bloques
- Algoritmo adaptativo con preprocesamiento
- Clasificación de algoritmos

# Cuadrados Mínimos Recursivo (RLS)

## Método de Cuadrados Mínimos

- Filtros lineales de cuadrados mínimos
- Cuadrados Mínimos Recursivo (RLS)
- Algoritmo RLS ponderado exponencialmente
- Análisis de convergencia

# Tracking e implementación

Seguimiento de sistemas variantes en el tiempo

- Grado de no estacionaridad
- Criterios de seguimiento
- Desempeño de seguimiento en RLS y LMS
- Comparación de algoritmos LMS y RLS

Efectos de precisión finita

- Errores de cuantización en algoritmos LMS y RLS



# Aprendizaje Automático

## Fundamentos del Aprendizaje Automático

- Algoritmos de Aprendizaje
- Estimadores, Sesgo y Varianza
- Algoritmos de Aprendizaje Supervisado y No Supervisado
- Desarrollo de un Algoritmo de Aprendizaje Automático

# Conceptos básicos

## Introducción

- El problema de filtrado
- Algoritmos de filtrado adaptivo
- Aplicaciones

## Procesos estacionarios y modelado

- Modelos estocásticos AR, MA y ARMA
- El problema de los autovalores

# El problema de filtrado y el procesamiento de la información

**Filtrado**, extracción de información sobre una cantidad de interés disponible en un instante  $n$  utilizando datos medidos hasta e inclusive ese instante.

**Suavizado**, difiere del filtrado en que la información sobre la cantidad de interés no necesita estar disponible en el instante  $n$  y datos medidos posteriormente al instante  $n$  pueden utilizarse. Esto significa que en suavizado existe un retardo en producir el resultado de interés.

**Predicción**, permite el pronóstico de la información. El objetivo es obtener información sobre como la cantidad de interés será en un futuro instante de tiempo  $n + \tau$ , para algún  $\tau > 0$ , usando los datos medidos hasta e inclusive el instante  $n$ .

## El problema de filtrado ...

- En la solución estadística al problema de *filtrado lineal* (la salida función lineal de las observaciones) se supone conocidos ciertos parámetros estadísticos (como media y autocorrelación). El objetivo es minimizar algún criterio en base a la señal de error obtenida.
- Para entradas estacionarias, *filtro de Wiener*, óptimo en sentido medio cuadrático.
- Para ambientes no estacionarios el filtro óptimo debe asumir una forma variante en el tiempo: *filtro de Kalman*.

# Filtros Adaptativos

Cuando los parámetros estadísticos adecuados para el filtro de Wiener (Kalman) no están disponibles existen diferente tipo de soluciones.

- Una solución posible, no muy eficiente, estimar esos parámetros fuera de línea y utilizar una ecuación no recursiva (simple) para obtener una solución aproximada del filtro de Wiener (Kalman).
- Una solución más adecuada para operación en línea (tiempo real) es la utilización de un *filtro adaptivo*. Los coeficientes se ajustan, siguiendo un criterio predefinido, con un algoritmo recursivo cuyas propiedades converjan a una buena aproximación del filtro de Wiener (Kalman).

## Filtros adaptativos: factores de análisis

*Velocidad de convergencia.* Número de iteraciones requerida por el algoritmo, en respuesta a entradas estacionarias, para convergir en forma suficientemente próxima a la solución de Wiener en un sentido medio cuadrático.

*Desajuste.* Medida de la cantidad por la cual el valor final del error medio cuadrático (utilizado usualmente como criterio a minimizar), se desvía del mínimo del filtro de Wiener.

*Seguimiento.* Operación en un ambiente no estacionario, el algoritmo requiere seguir (tracking) las variaciones estadísticas. El desempeño está influenciado por: la velocidad de convergencia y la fluctuación de estado estacionario debido a ruido del algoritmo.

## Filtros adaptativos: factores de análisis

*Robustez.* Para que un filtro adaptivo sea robusto, perturbaciones de pequeña energía deben resultar en errores de estimación pequeños.


*Estructura.* Flujo de información en el algoritmo y forma en que será implementado el hardware.

*Propiedades numéricas.* Los errores de cuantización son debido a la conversión A/D de los datos de entrada y a la representación digital interna. (la fuente más considerable). Dos aspectos: estabilidad numérica y precisión numérica.

*Requerimientos computacionales.* Número de operaciones requeridas para completar una iteración del algoritmo, tamaño de memoria requerido para almacenar datos y control del algoritmo.

# Estructuras de filtros lineales

## Filtro transversal (FIR)




$$y(n) = \sum_{k=0}^{M-1} w_k x(n - k)$$



# Estructuras de filtros lineales

## Filtro lattice



$$f_m(n) = f_{m-1}(n) + K_m b_{m-1}(n-1)$$

$$b_m(n) = b_{m-1}(n-1) + K_m f_{m-1}(n)$$

# Algoritmos de filtrado adaptativo

No existe una solución única para el problema de filtrado adaptativo, sino más bien una variedad de herramientas representadas por un conjunto de algoritmos, cada uno de los cuales ofrece características adecuadas a cierta aplicación.

Es posible identificar en forma general dos formas distintas para derivar algoritmos recursivos para la operación de filtros adaptativos lineales

- Aproximación de gradiente estocástico.
- Estimación de Cuadrados Mínimos.

## Algoritmos de filtrado adaptativo ...

### Aproximación de gradiente estocástico (LMS)

$$\begin{pmatrix} \text{valor próximo} \\ \text{del vector de} \\ \text{coeficientes} \end{pmatrix} = \begin{pmatrix} \text{valor actual} \\ \text{del vector de} \\ \text{coeficientes} \end{pmatrix} + \begin{pmatrix} \text{parámetro} \\ \text{de} \\ \text{convergencia} \end{pmatrix} \begin{pmatrix} \text{vector} \\ \text{de} \\ \text{entradas} \end{pmatrix} \begin{pmatrix} \text{señal} \\ \text{de} \\ \text{error} \end{pmatrix}$$

### Estimación de Cuadrados Mínimos

- El método de cuadrados mínimos puede formularse para estimación en bloques (LS) ó secuencial (RLS).
- La estimación de *cuadrados mínimos recursivo* (RLS) puede interpretarse como un caso especial del *filtro de Kalman*.

$$\begin{pmatrix} \text{valor próximo} \\ \text{del vector de} \\ \text{coeficientes} \end{pmatrix} = \begin{pmatrix} \text{valor actual} \\ \text{del vector de} \\ \text{coeficientes} \end{pmatrix} + \begin{pmatrix} \text{Ganancia de} \\ \text{Kalman} \\ \text{(matriz)} \end{pmatrix} \begin{pmatrix} \text{vector} \\ \text{de} \\ \text{innovación} \end{pmatrix}$$

## Familia de algoritmos RLS de filtrado adaptativo

*RLS estándar*, resultado básico del álgebra lineal conocido como *lema de inversión de matrices*. Tiene las mismas virtudes y defectos que el algoritmo Kalman estándar (carencia de robustez numérica y alta complejidad  $O(M^2)$ ).

*RLS factorizados*, basados en la descomposición  $QR$  de la matriz de datos de entrada (transformación de Householder o rotaciones de Givens). Son estables y robustos.

*RLS rápidos*, complejidad  $O(M)$  usando la *estructura Toeplitz* de la matriz de datos de entrada y también predicción lineal hacia adelante y hacia atrás (forward y backward).

- *Recursivos en orden*, basados en una estructura tipo lattice para realizar las predicciones forward y backward (no necesariamente estables numéricamente).
- *Transversales rápidos*, donde las predicciones forward y backward se realizan con filtros transversales separados.

## Características de seguimiento (tracking)

- Los algoritmos de tipo gradiente estocástico (LMS) son *independientes del modelo*. Genéricamente es posible esperar un buen comportamiento en seguimiento.
- Los algoritmos RLS son *dependientes del modelo*, lo que significa que sus comportamientos en seguimiento pueden ser inferiores al de algún miembro de la familia de gradiente estocástico.

# Aplicaciones


- La habilidad de un filtro adaptativo para operar satisfactoriamente en ciertos contextos desconocidos y seguir variaciones en el tiempo de la estadística de la entrada hacen al filtrado adaptativo una herramienta poderosa para varias aplicaciones de procesamiento de señal y control.
- Han sido exitosamente aplicados en campos tan diversos como comunicaciones, radar, sonar, sismología e ingeniería biomédica.
- A pesar que esas aplicaciones son bien diferentes en naturaleza tienen una base común: el vector de entrada y la respuesta deseada se utilizan para obtener el error de estimación, el cual se usa para controlar los valores de un conjunto de coeficientes ajustables asociados al filtro.
- La diferencia esencial entre las aplicaciones reside en la forma en que se obtiene la respuesta deseada.

## Aplicaciones ...

Es posible distinguir cuatro clases de aplicaciones de filtrado adaptivo, donde:

$u$ : es la entrada aplicada al filtro,  
 $y$ : es la salida del filtro,  
 $d$ : es la respuesta deseada,  
 $e=d-y$  es el error de estimación.

- a) Identificación de sistemas,
- b) filtrado inverso,
- c) predicción,
- d) cancelamiento de interferencias



# Procesos estacionarios

Los procesos estocásticos de interés se definen como discretos y uniformemente espaciados en el tiempo.

Un proceso estocástico no es una única función del tiempo, sino que representa un número infinito de realizaciones diferentes. Una realización particular, normalizando el tiempo con respecto al período de muestreo, de la secuencia  $u(n)$  es  $u(n-1) \dots, u(n-M)$ .

Un proceso estocástico es *estrictamente estacionario* si sus propiedades estadísticas son *invariantes* al desplazamiento en tiempo.

Específicamente, para que el proceso  $u(n)$  anterior sea estrictamente estacionario, la función densidad de probabilidad conjunta de las observaciones realizadas en los instantes  $n, n-1, \dots, n-M$  debe ser la misma independientemente de los valores que asignemos a  $n$ , para un  $M$  fijo.



## Caracterización de procesos estocásticos

En la práctica no siempre es posible determinar (por medio de mediciones) la función densidad de probabilidad conjunta de un conjunto arbitrario de observaciones realizadas sobre un proceso estocástico.

En su lugar es posible conformarse con una caracterización parcial del proceso especificando sus momentos de primer y segundo orden.

Para un proceso estocástico  $u(n)$ , definido para  $u(n-1), \dots, u(n-M)$ , definimos la función valor medio como

$$\mu(n) = E[u(n)]$$

donde  $E[.]$  es el operador esperanza estadística. Definimos también la función autocorrelación del proceso como

$$r(n, n - k) = E[u(n)u^*(n - k)], \quad k = 0, \pm 1, \pm 2, \dots$$

## Caracterización de procesos estocásticos ...

También la función autocovarianza

$$c(n, n - k) = E[(u(n) - \mu(n))(u(n - k) - \mu(n - k))^*], \quad k = 0, \pm 1, \pm 2, \dots$$

de donde

$$c(n, n - k) = r(n, n - k) - \mu(n)\mu(n - k)$$

## Caracterización de procesos estocásticos ...

Esta caracterización parcial ofrece dos ventajas importantes:

- Es adecuada para las mediciones.
- Es adecuada para operaciones lineales sobre procesos estocásticos.

Para el caso de procesos estocásticos estacionarios en sentido amplio

$$\begin{aligned}\mu(n) &= \mu \quad \text{constante} \\ r(n, n-k) &= r(k) \\ c(n, n-k) &= c(k)\end{aligned}$$

Además para  $k=0$ ,  $r(0)$  es el *valor medio cuadrático* de  $u(n)$ , dado por

$$r(0) = E[u^2]$$

y  $c(0) = \sigma_u^2$  es la *varianza* de  $u(n)$ .

## Matriz correlación

Para  $\mathbf{u}(n)$  ( $M \times 1$ ) representando un proceso estocástico  $u(n)$  de  $u(n-1)$  a  $u(n-M+1)$ , la *matriz de correlación*  $\mathbf{R}$  de un proceso estacionario (en sentido amplio) es

$$\mathbf{R} = E[\mathbf{u}(n)\mathbf{u}^H(n)] = \begin{bmatrix} r(0) & r(1) & \cdots & r(M-1) \\ r(-1) & r(0) & \cdots & r(M-2) \\ \vdots & \vdots & \ddots & \vdots \\ r(-M+1) & r(-M+2) & \cdots & r(0) \end{bmatrix}$$

Propiedades:

- $\mathbf{R}^H = \mathbf{R}$  Se verifica por definición.
- Es *Toeplitz* (sub-diagonales con elementos idénticos). Esto es consecuencia directa de estacionaridad en sentido amplio.
- Es siempre no negativa y casi siempre positiva. Esta condición es satisfecha para cualquier proceso estacionario en sentido amplio a menos que existan dependencias lineales entre los  $M$  elementos de  $\mathbf{u}(n)$  (cuando  $u(n)$  es la suma de  $K$  sinusoides, con  $K < M$ ).

## Matriz autocorrelación ...

Cuando los elementos de  $u(n)$  son reordenados hacia atrás, es equivalente a la transposición de la matriz correlación. Si el proceso es estacionario, la matriz correlación es idéntica.

Definamos  $u^B(n)$  ( $M \times 1$ ), reordenando los elementos de  $u(n)$  hacia atrás (backward), o sea

$$u^{BT}(n) = [u(n - M + 1), u(n - M + 2), \dots, u(n)]$$

La matriz correlación de  $u^B(n)$  será, por definición

$$E[u^B(n)u^{BT}(n)] = \begin{bmatrix} r(0) & r(-1) & \dots & r(-M + 1) \\ r(1) & r(0) & \dots & r(-M + 2) \\ & & \vdots & \\ r(M - 1) & r(M - 2) & \dots & r(0) \end{bmatrix} = \mathbf{R}^T$$

y si el proceso es estacionario  $E[u^B(n)u^{BT}(n)] = \mathbf{R}^T = \mathbf{R}$ .

## Matriz autocorrelación ...

Las matrices de correlación de orden  $M$  y  $M+1$ ,  $\mathbf{R}_M$  y  $\mathbf{R}_{M+1}$  de un proceso estacionario, están relacionadas por

$$\mathbf{R}_{M+1} = \begin{bmatrix} r(0) & \mathbf{r}^H \\ \mathbf{r} & \mathbf{R}_M \end{bmatrix} = \begin{bmatrix} \mathbf{R}_M & \mathbf{r}^{B*} \\ \mathbf{r}^{BT} & r(0) \end{bmatrix}$$

donde  $r(0)$  es el proceso de autocorrelación correspondiente al retardo 0.

También,

$$\begin{aligned} \mathbf{r}^H &= [r(1), r(2), \dots, r(M)] \\ \mathbf{r}^{BT} &= [r(-M), r(-M+1), \dots, r(-1)] \end{aligned}$$

## Modelos estocásticos

El término *modelo* se aplica a cualquier suposición o hipótesis que pueda aplicarse para explicar o describir las leyes ocultas que se supone gobiernan la generación de los datos físicos de interés.

La idea es que un proceso estocástico  $u(n)$  puede describirse a través de un filtro lineal cuya entrada es fácilmente caracterizable, en particular ruido blanco gaussiano de media cero y varianza unitaria (AWGN),  $\nu(n)$  descrito por

$$\begin{aligned} E[\nu(n)] &= 0 \quad \text{para todo } n \\ E[\nu^2(n)] &= \begin{cases} \sigma_\nu^2, & k = n \\ 0, & \text{para todo otro } n \end{cases} \end{aligned}$$

donde  $\sigma_\nu^2$  es la varianza de ese ruido de entrada.

## Modelos estocásticos ...

- En general, la descripción en el dominio tiempo de la relación entrada - salida del modelo estocástico puede describirse como

$$\left( \begin{array}{c} \text{valor presente} \\ \text{de salida del modelo} \end{array} \right) + \left( \begin{array}{c} \text{combinación lineal} \\ \text{de valores pasados} \\ \text{de salida del modelo} \end{array} \right) = \left( \begin{array}{c} \text{combinación lineal} \\ \text{de valores presentes y pasados} \\ \text{de salida del modelo} \end{array} \right)$$

- Un proceso estocástico definido de esta forma se denomina *proceso lineal*. Existen otras descripciones diferentes a la de *entrada - salida* (por ej., variables de estado) para caracterizar tal tipo de sistemas.
- En particular discutiremos tres tipos de modelos estocásticos: a) autoregresivos (AR), b) promedios móviles (MA) y c) ARMA.



## Modelos Autoregresivos (AR)

Un proceso  $u(n)$ , definido para  $u(n-1), \dots, u(n-M)$  representa la realización de un proceso AR de orden  $M$  si

$$u(n) + a_1^* u(n-1) + \dots + a_M^* u(n-M) = \nu(n)$$

donde  $a_1, \dots, a_M$  son constantes denominadas parámetros AR, y  $\nu(n)$  es el proceso de ruido blanco de entrada.

Consideremos  $\sum_{k=0}^M a_k^* u(n-k) = \nu(n)$ , donde  $a_0 = 1$ , tal que

$$H_A(z)U(z) = V(z)$$

donde  $H_A(z)$ ,  $U(z)$  y  $V(z)$  son las TZ de las secuencias  $a_k^*$ ,  $u(n)$  y  $\nu(n)$ .

## Modelos Autoregresivos (AR) ...

Dependiendo de considerar  $u(n)$  la entrada o salida de un filtro de interés, la TZ anterior ofrece las siguientes interpretaciones:


- *Analizador del proceso*, para  $u(n)$  como entrada los coeficientes del filtro corresponden con los del modelo AR y la TZ inversa de  $H_A(z)$  es la respuesta impulsiva de duración finita (FIR) (filtro todo ceros).
- *Generador del proceso*, para  $u(n)$  como salida el filtro tendrá como función transferencia  $H_G(z) = \frac{1}{H_A(z)}$ , cuya respuesta impulsiva es de duración infinita (filtro solo polos).

Los ceros o polos están determinados por las raíces de la ecuación característica

$$1 + a_1^* z^{-1} + a_2^* z^{-2} + \dots + a_M^* z^{-M} = 0$$

## Modelos Autoregresivos (AR) ...

a) Analizador



b) Generador

## Modelos de promedios móviles (MA)

Este modelo se describe por

$$u(n) = \nu(n) + b_1^* \nu(n-1) + \cdots + b_K^* \nu(n-K)$$

donde los  $b_k$  se denominan parámetros MA y  $\nu(n)$  es ruido blanco de media cero y varianza  $\sigma_\nu^2$ .

Los filtros asociados al modelo MA, de análisis y generación son los duales de los del modelo AR.

## Modelos ARMA

Para generar un proceso mixto autoregresivo - promedios móviles (ARMA), la función transferencia del modelo debe tener ceros y polos.

Para un proceso de ruido blanco  $\nu(n)$  de entrada la ecuación será

$$u(n) + a_1^* u(n-1) + \cdots + a_M^* u(n-M) = \nu(n) + b_1^* \nu(n-1) + \cdots + b_K^* \nu(n-K)$$

donde  $a_1, \cdots, a_M$  y  $b_1, \cdots, b_K$  son los parámetros ARMA.

- Desde un punto de vista computacional, y como es más simple su obtención, los modelos AR son más populares que los modelos MA y ARMA.
- Para el primer caso es necesaria la obtención de la solución de un conjunto de ecuaciones lineales, conocidas como ecuaciones de *Yule-Walker*, mientras que para MA y ARMA es necesario en general resolver un sistema de ecuaciones no lineales.

## Autocorrelación de un proceso AR

En base a la ecuación a diferencias de un proceso AR, multiplicando por  $u(n - \ell)$  y luego aplicando el operador esperanza obtenemos:

$$E \left[ \sum_{k=0}^M a_k^* u(n - k) u^*(n - \ell) \right] = E[\nu(n) u^*(n - \ell)]$$

Teniendo en cuenta ahora, la definición de autocorrelación de un proceso estacionario y que el término de la derecha es cero para  $\ell > 0$ , se tiene que

$$\sum_{k=0}^M a_k^* r(\ell - k) = 0, \quad \ell > 0$$

donde  $a_0 = 1$ . De esta forma, la función autocorrelación de un proceso AR satisface

$$r(\ell) = w_1^* r(\ell - 1) + w_2^* r(\ell - 2) + \cdots + w_M^* r(\ell - m), \quad \ell > 0$$

donde  $w_k = -a_k$ ,  $k = 1, 2, \dots, M$ .

## Autocorrelación de un proceso AR ...

La solución general a esa ecuación es del tipo

$$r(m) = \sum_{k=1}^M C_k p_k^m$$

donde  $C_1, C_2, \dots, C_M$  son constantes y  $p_1, p_2, \dots, p_M$  son las raíces de la ecuación característica.

Notar que si se satisface la condición de estabilidad de la ecuación característica, la función autocorrelación tiende a cero para  $m \rightarrow \infty$ .

La forma exacta de la contribución de cada polo  $p_k$  depende de que el polo sea real o complejo.

- Para polos reales la contribución será exponencialmente decreciente.
- Para polos complejos en pares conjugados la contribución será la de una sinusoidal amortiguada.

## Ecuaciones de Yule - Walker

Para obtener unívocamente un modelo AR de orden  $M$ , es necesario especificar los siguientes parámetros

- Los coeficientes AR,  $a_1, a_2, \dots, a_M$ .
- La varianza  $\sigma_v^2$  del ruido blanco  $v(n)$  usado como entrada.

Para el primer conjunto de parámetros utilizamos la autocorrelación de proceso AR para  $\ell = 1, 2, \dots, M$ , para obtener las *ecuaciones de Yule - Walker*

$$\begin{bmatrix} r(0) & r(1) & r(2) & \cdots & r(M-1) \\ r^*(1) & r(0) & r(1) & \cdots & r(M-2) \\ & & \vdots & & \\ r^*(M-1) & r^*(M-2) & r^*(M-3) & \cdots & r(0) \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_M \end{bmatrix} = \begin{bmatrix} r_1^* \\ r_2^* \\ \vdots \\ r_M^* \end{bmatrix}$$

donde  $r(0), r(1), \dots, r(M)$  se suponen conocidas y  $w_1, w_2, \dots, w_M$  son las incógnitas. En forma compacta:  $Rw = r$ , cuya solución es

$$w = R^{-1}r$$



## Ecuaciones de Yule – Walker ...

De esta forma, existe una relación única entre los coeficientes del modelo AR y los *coeficientes de correlación normalizados* definidos por  $\rho_k = \frac{r(k)}{r(0)}$ , tal que

$$\{a_1, a_2, \dots, a_M\} \Leftrightarrow \{\rho_1, \rho_2, \dots, \rho_M\}$$

Por otro lado, para obtener la varianza del ruido blanco, para  $\ell = 0$ , la esperanza de la ecuación de un proceso AR es

$$E[\nu(n)u^*(n)] = E[u(n)u^*(n)] = \sigma_\nu^2$$

de esta forma del lado izquierdo de aquella ecuación se obtiene

$$\sigma_\nu^2(n) = \sum_{k=0}^M a_k r(k) \quad a_0 = 1.$$

De aquí, dadas  $r(0), r(1), \dots, r(M)$  es posible determinar la varianza del ruido.

## Ecuaciones de Yule – Walker ...

Ejemplo: AR de segundo orden

Se ilustrará los aspectos de modelado AR estudiados para el caso de un proceso AR de segundo orden con coeficientes reales.

La descripción en el dominio tiempo es

$$u(n) + a_1 u(n-1) + a_2 u(n-2) = \nu(n)$$

donde  $\sigma_\nu^2$  se elige para que la varianza de  $u(n)$  sea unitaria.

## Ecuaciones de Yule – Walker ...

Ejemplo: AR de segundo orden ...

Función autocorrelación. La solución de la ecuación de la autocorrelación del AR para el caso de segundo orden, se obtiene de

$$r(m) + a_1 r(m-1) + a_2 r(m-2) = 0, \quad m > 0$$

requiere de la especificación de condiciones iniciales para  $r(0)$  y  $r(1)$ , que sustituidas en la anterior permiten obtener una solución general del tipo

$$r(m) = C_1 p_1^m + C_2 p_2^m$$

donde  $p_1$  y  $p_2$  son las raíces de  $1 + a_1 z^{-1} + a_2 z^{-2}$ . Las condiciones iniciales se eligen como

$$r(0) = \sigma_u^2 \quad r(1) = \frac{-a_1}{1 + a_2} \sigma_u^2$$

## Ecuaciones de Yule – Walker ...

Ejemplo: AR de segundo orden ...

Existen dos casos a ser considerados, dependiendo de que el tipo de raíces  $p_1$  y  $p_2$  sean reales o complejas:

- Raíces reales: En este caso se tiene que  $a_1^2 - 4a_2 > 0$  y la función autocorrelación se mantiene positiva mientras se desvanece o se amortigua alternando el signo, correspondiendo a una raíz dominante positiva o negativa respectivamente.
- Raíces complejas: En este caso  $a_1^2 - 4a_2 < 0$ . En ese caso la función autocorrelación muestra un comportamiento seudoperiódico amortiguado.

## Ecuaciones de Yule – Walker ...

Ejemplo: AR de segundo orden ...

Ecuaciones de Yule – Walker: del proceso AR se obtiene

$$\begin{bmatrix} r(0) & r(1) \\ r(1) & r(0) \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} r(1) \\ r(2) \end{bmatrix}$$

de donde resolviendo para  $w_1$  y  $w_2$ ,

$$w_1 = -a_1 = \frac{r(1)[r(0) - r(2)]}{r^2(0) - r^2(1)}$$

$$w_2 = -a_2 = \frac{r(0)r(2) - r^2(1)}{r^2(0) - r^2(1)}$$

y expresando  $r(1)$  y  $r(2)$  en términos de  $a_1$  y  $a_2$

$$r(1) = \frac{-a_1}{1 + a_2} \sigma_u^2 \quad r(2) = \left( -a_2 + \frac{a_1^2}{1 + a_2} \right) \sigma_u^2$$

donde  $\sigma_u^2 = r(0)$ .

## Ecuaciones de Yule – Walker ...

Ejemplo: AR de segundo orden ...

Varianza del ruido blanco. La varianza del proceso de ruido blanco  $\nu(n)$  se puede obtener de

$$\sigma_\nu^2 = r(0) + a_1 r(1) + a_2 r(2)$$

de forma que sustituyendo se obtiene

$$\sigma_u^2 = \left( \frac{1 + a_2}{1 - a_2} \right) \frac{\sigma_\nu^2}{[(1 + a_1)^2 - a_1^2]}$$

## El problema de los autovalores

En relación a la matriz correlación de un proceso ESA,  $R$  interesa hallar  $q$  que satisfaga

$$Rq = \lambda q$$

para alguna constante  $\lambda$ .  $q$  así formado se mantiene invariante en dirección a partir de transformaciones lineales.

Para  $R$  de  $(M \times M)$  deben existir típicamente  $M$  de esos vectores. En particular reescribiendo

$$(R - \lambda I) = 0$$

La matriz  $(R - \lambda I)$  debe ser singular, de forma que esta ecuación tendrá alguna solución no nula en el vector  $q$  si y solo si

$$\det(R - \lambda I) = 0$$

## El problema de los autovalores ...

Este determinante, expandido, es un polinomio en  $\lambda$  de orden  $M$ , la ecuación característica. En general tendrá  $M$  raíces distintas correspondientes a las soluciones en el vector  $\mathbf{q}$ .

Las raíces de ese polinomio  $\lambda_1, \dots, \lambda_M$  son los *autovalores* de  $\mathbf{R}$ , que pueden no ser necesariamente distintos.

Si  $\lambda_i$  es un autovalor de  $\mathbf{R}$ , entonces un vector  $\mathbf{q}_i$  que verifica

$$\mathbf{R}\mathbf{q}_i = \lambda_i\mathbf{q}_i$$

se denomina *autovector* asociado a  $\lambda_i$ .



## El problema de los autovalores ...

Ejemplo: Ruido blanco

La matriz correlación que representa un proceso de ruido blanco está dada por

$$\mathbf{R} = \text{diag}(\sigma^2, \sigma^2, \dots, \sigma^2)$$

donde  $\sigma^2$  es la varianza del proceso.

Esta matriz correlación  $\mathbf{R}$  tiene un único autovalor igual a la varianza  $\sigma^2$  de multiplicidad  $M$ .

Cualquier vector de  $(M \times 1)$  puede ser un autovector, lo que muestra que un autovalor puede tener múltiples autovectores asociados.

## El problema de los autovalores ...

Ejemplo: Sinusoidal compleja

Considerando una secuencia cuyos elementos son muestras de una sinusoidal compleja con fase aleatoria y potencia unitaria, su matriz correlación puede escribirse como

$$\mathbf{R} = \begin{bmatrix} 1 & e^{jw} & \dots & e^{j(M-1)w} \\ e^{-jw} & 1 & \dots & e^{j(M-2)w} \\ & & \vdots & \\ e^{-j(M-1)w} & e^{-j(M-2)w} & \dots & 1 \end{bmatrix}$$

donde  $w$  es la frecuencia angular de la sinusoidal compleja. El vector

$$\mathbf{q} = [1, e^{-jw}, \dots, e^{-j(M-1)w}]^T$$

es un autovector de  $\mathbf{R}$  y el autovalor correspondiente es  $M$ .

Notar que  $\mathbf{R}$  tiene rango 1, lo cual significa que cualquier columna puede expresarse como una combinación lineal de las columnas restantes. Esto significa también que los otros autovalores son cero con multiplicidad  $M-1$ .

## El problema de los autovalores ...

### Propiedades

- Si  $\lambda_1, \lambda_2, \dots, \lambda_M$  son los autovalores de  $\mathbf{R}$ , entonces los autovalores de  $\mathbf{R}^k$  son  $\lambda_1^k, \lambda_2^k, \lambda_M^k$ , para cualquier  $k > 0$ .
- Sean  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M$  los autovectores correspondientes a autovalores distintos  $\lambda_1, \lambda_2, \dots, \lambda_M$  de  $\mathbf{R}$ , respectivamente. Entonces los autovectores  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M$  son linealmente independientes.

## El problema de los autovalores ...

### Propiedades ...

Un uso importante de esta propiedad es en el uso de autovectores como base de representación de un vector arbitrario  $w$ . En particular, es posible representarlo como

$$w = \sum_{i=1}^M \nu_i q_i$$

donde los  $\nu_i$  son constantes. Aplicando ahora una transformación lineal sobre  $w$  a través de la pre-multiplicación por una matriz  $R$ , se obtiene

$$Rw = \sum_{i=1}^M \nu_i Rq_i$$

pero como por definición  $Rq_i = \lambda_i q_i$ , se tendrá que

$$Rw = \sum_{i=1}^M \nu_i \lambda_i q_i$$

tal que el efecto es multiplicar cada autovector por el respectivo autovalor.

## El problema de los autovalores ...

### Propiedades ...

- Sean  $\lambda_1, \lambda_2, \dots, \lambda_M$  los autovalores de  $\mathbf{R}$ . Entonces todos los autovalores deben ser reales y no negativos.
- Sean  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M$  los autovectores correspondientes a autovalores distintos  $\lambda_1, \lambda_2, \dots, \lambda_M$  de  $\mathbf{R}$ . Entonces los autovectores  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M$  son ortogonales entre sí.

## El problema de los autovalores ...

Propiedades ...

Transformación de similaridad unitaria. Sean  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M$  los autovectores correspondientes a autovalores distintos  $\lambda_1, \lambda_2, \dots, \lambda_M$  de  $\mathbf{R}$ .

Definamos la matriz

$$\mathbf{Q} = [\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M] \quad \mathbf{q}_i^H \mathbf{q}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}.$$

Y definamos además una matriz diagonal

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_M)$$

Entonces,  $\mathbf{R}$  puede diagonalizarse como

$$\mathbf{Q}^H \mathbf{R} \mathbf{Q} = \mathbf{\Lambda}$$

## El problema de los autovalores ...

### Propiedades ...

- Sean  $\lambda_1, \lambda_2, \dots, \lambda_M$  los autovalores de  $\mathbf{R}$ . Entonces la suma de esos autovalores es igual a la traza de la matriz  $\mathbf{R}$ .
- La matriz correlación es mal condicionada si la relación entre el máximo y el mínimo autovalor de  $\mathbf{R}$  es grande.
- Los autovalores de la matriz correlación de un proceso estocástico están acotados por los valores mínimos y máximos de la densidad espectral de potencia del proceso.

# Conceptos básicos

## Introducción

- El problema de filtrado
- Algoritmos de filtrado adaptivo
- Aplicaciones

## Procesos estacionarios y modelado

- Modelos estocásticos AR, MA y ARMA
- El problema de los autovalores