Procesamiento Adaptativo de Señales

Juan E. Cousseau
Departamento de Ingeniería Eléctrica y Computadoras
Universidad Nacional del Sur

Contenidos

- Conceptos básicos.
- Filtro de Wiener.
- Filtro de Kalman.
- Menor cuadrado mínimo (LMS)
- Cuadrados mínimos recursivo (RLS)
- Tracking e implementación.
- Aprendizaje automático.

Filtro de Wiener

Filtros de Wiener

- El problema de filtrado optimo lineal
- El error medio cuadrático mínimo
- Ecuaciones de Wiener-Hopf

Predicción lineal

- Predicción lineal forward y backward
- Predictores Lattice
- Estimación conjunta y en bloques

Filtrado óptimo lineal

Se han introducido dos restricciones al filtro:

- Que el filtro sea *lineal*, lo cual conduce a un tratamiento estadístico manejable.
- Que el filtro opere en *tiempo discreto*, lo cual hace posible que sea implementado utilizando hardware/software digital.

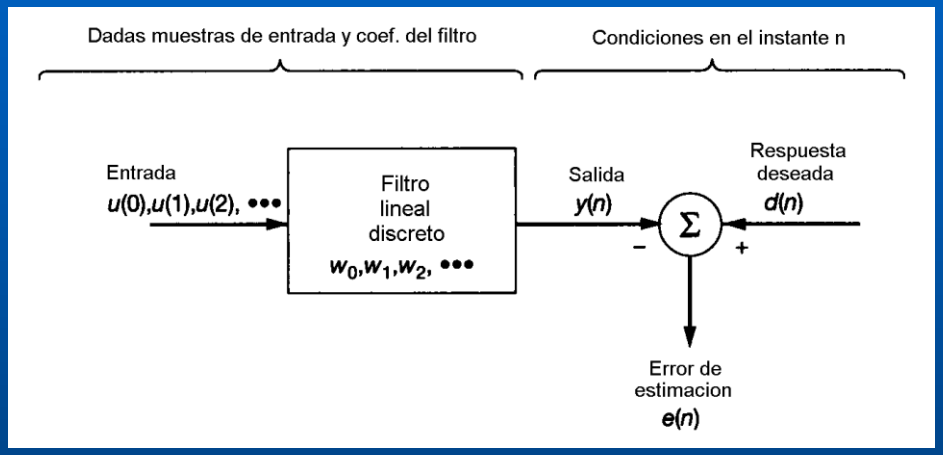

Los detalles de las especificaciones del filtro dependerán sin embargo de otras dos elecciones que deben realizarse:

- Que la respuesta impulsiva del filtro sea de duración *finita* o *infinita*.
- El tipo de *criterio estadístico* a ser utilizado en la optimización.

Filtrado óptimo lineal ...

La elección de filtros FIR o IIR queda determinada por consideraciones prácticas. El estudio será, inicialmente, en base a filtros FIR.

La elección del criterio estadístico para optimizar el diseño del filtro está influenciada por la simplicidad del análisis formal del problema. Es posible elegir un diseño para minimizar una función costo definida, por ejemplo, por:

1. El valor medio cuadrático del error de estimación.
2. La esperanza del valor absoluto del error de estimación.
3. La esperanza de la tercera o cuarta potencia del valor absoluto del error de estimación.

Claramente la opción 1 tiene ventajas sobre las otras dos debido a que conduce a un tratamiento matemático manejable y a una interpretación física directa.

Filtrado óptimo lineal ...

Resumiendo, la esencia del problema de filtrado óptimo:

Diseñar un filtro lineal discreto cuya salida $y(n)$ permita obtener una estimación de la respuesta deseada $d(n)$, dadas un conjunto de muestras $u(0), u(1), u(2), \ldots$, tal que el valor medio cuadrático del error de estimación $e(n)=d(n) - y(n)$, sea minimizado.

Nuestra forma de aproximación a la solución del problema

- estudio de un importante teorema: el principio de ortogonalidad.
- comportamiento de la superficie de desempeño del error.

Filtrado óptimo: El principio de ortogonalidad

- La salida del filtro puede escribirse como una convolución lineal

$$y(n) = \sum_{k=0}^{\infty} w_k^* u(n-k), \quad n = 0, 1, \cdots$$

- El propósito del filtro lineal es generar una respuesta deseada *d(n)*. Suponemos en general que la entrada del filtro y la respuesta deseada son realizaciones de procesos ESA.
- La estimación de *d(n)* se acompaña por un error definido por $e(n) = d(n) - y(n)$
- Para optimizar el diseño del filtro se minimiza el valor medio cuadrático del error de estimación *e(n)*. Es posible definir la función costo como

$$J = E[e(n)e^*(n)] = E[|e(n)|^2]$$

- El problema es determinar las condiciones de operación para las cuales *J* alcanza su valor mínimo.

Filtrado óptimo: El principio de ortogonalidad ...

Para datos de entrada complejos, los coeficientes son en general complejos. Si w_k es el *k*-ésimo coeficiente será $w_k = a_k + jb_k$, *k=0,1,2,* ... . Entonces podemos definir el gradiente para el *k*-ésimo coeficiente

$$\nabla_k = \frac{\partial}{\partial a_k} + j\frac{\partial}{\partial b_k}, \quad k = 0, 1, 2, \cdots$$

Luego aplicando el operador $\boldsymbol{\nabla}[\cdot]$ a la función costo *J* obtenemos un vector gradiente cuyo *k*-ésimo elemento es

$$\nabla_k J = \frac{\partial J}{\partial a_k} + j\frac{\partial J}{\partial b_k}, \quad k = 0, 1, 2, \cdots$$

Notar que para que la definición del gradiente complejo sea válida es necesario que la función costo *J* sea real.

El operador gradiente se utiliza siempre en la obtención de los puntos estacionarios de la función de interés. Esto significa que la restricción compleja debe convertirse a un par de restricciones reales.

Filtrado óptimo: El principio de ortogonalidad ...

Para que la función costo alcance su valor mínimo, todos los elementos del gradiente ∇J deben ser simultáneamente cero, o sea

$$\nabla_k J = 0, \quad k = 0, 1, 2, \cdots$$

La función costo *J* es un escalar independiente de *n*, de esta forma

$$\nabla_k J \;=\; E\left[\frac{\partial e(n)}{\partial a_k} e^*(n) + \frac{\partial e^*(n)}{\partial a_k} e(n) + j\frac{\partial e(n)}{\partial b_k}\, e^*(n) + j\frac{\partial e^*(n)}{\partial b_k}\, e(n)\right]$$

Filtrado óptimo: El principio de ortogonalidad ...

Entonces

$$\begin{aligned}
\frac{\partial e(n)}{\partial a_k} &= -u(n-k) \\
\frac{\partial e(n)}{\partial b_k} &= j\,u(n-k) \\
\frac{\partial e^*(n)}{\partial a_k} &= -u^*(n-k) \\
\frac{\partial e^*(n)}{\partial b_k} &= -j\,u^*(n-k)
\end{aligned}$$

De forma que

$$\nabla_k J = -2E[u(n-k)e^*(n)]$$

Filtrado óptimo: El principio de ortogonalidad ...

Si $e_O(n)$ es el valor particular del error de estimación para el filtro opera en la condición del mínimo, en ese caso se verifica que

$$E[u(n-k)e_O^*(n)] = 0, \quad k = 0, 1, 2, \cdots$$

En palabras esta ecuación sintetiza el *principio de ortogonalidad:*

- La condición necesaria y suficiente para que la función costo *J* alcance su valor mínimo es que el valor correspondiente del error de estimación $e_O(n)$ sea ortogonal a cada muestra de entrada que permite obtener la respuesta deseada en el instante *n*.

Filtrado óptimo: corolario

Utilizando la relación entrada – salida del filtro, es posible expresar

$$E[y(n)e^*(n)] = E[\sum_{k=0}^{\infty} w_k^* u(n-k)e^*(n)] = \sum_{k=0}^{\infty} w_k^* E[u(n-k)e^*(n)]$$

Si $y_O(n)$ es la salida del filtro optimizada en sentido medio cuadrático, con $e_O(n)$ el correspondiente error de estimación, entonces en base al principio de ortogonalidad

$$E[y_O(n)e_O^*(n)] = 0$$

Si $\hat{d}(n|U_n)$ es la estimación de la respuesta deseada óptima en sentido medio cuadrático sobre datos de entrada U_n e incluyendo *n*, entonces

$$\hat{d}(n|U_n) = y_o(n)$$

$\hat{d}(n|U_n)$ tiene media 0 debido a que las entradas se suponen de media 0. Esto es compatible con la suposición de media 0 en *d(n)*.

Filtro óptimo: El error medio cuadrático

Cuando el filtro lineal opera en su condición óptima, el error toma la forma

$$e_O(n) = d(n) - y(n) = d(n) - \hat{d}(n|U_n)$$

de donde $d(n) = \hat{d}(n|U_n) + e_O(n)$.

Si J_{min} es el error medio cuadrático mínimo (MMSE) $J_{min} = E[|e_O(n)|^2]$, entonces usando el corolario del principio de ortogonalidad se obtiene

$$\sigma_d^2 = \sigma_{\hat{d}}^2 + J_{min}$$

donde σ_d^2 es la varianza de la respuesta deseada y $\sigma_{\hat{d}}^2$ es la varianza de $\hat{d}(n|U_n)$.

De esta ecuación es posible obtener $J_{min} = \sigma_d^2 - \sigma_{\hat{d}}^2$, i.e., en un filtro óptimo, el MMSE es igual a la diferencia entre las varianzas de la respuesta deseada y la estimada.

Filtro óptimo: Ecuaciones de Wiener - Hopf

En forma más general el principio de ortogonalidad puede escribirse como

$$E\left[u(n-k)\left(d^*(n)-\sum_{i=0}^{\infty} w_{oi}u^*(n-i)\right)\right]=0, \quad k=0,1,2,\cdots$$

donde w_{oi} es el *i*-ésimo coeficiente en la respuesta impulsiva del filtro óptimo.

Reordenando esta ecuación se obtiene

$$\sum_{i=0}^{\infty} w_{oi}E[u(n-k)u^*(n-i)]=E[u(n-k)d^*(n)], \quad k=0,1,2,\cdots$$

que puede escribirse como

$$\sum_{i=0}^{\infty} w_{oi}r(i-k)=p(-k), \quad k=0,1,2,\cdots$$

que se denominan *ecuaciones de Wiener- Hopf*.

Filtro óptimo: estructura FIR

La solución del conjunto de ecuaciones de Wiener-Hopf se simplifica para el caso especial en que se utilice un filtro transversal o FIR.

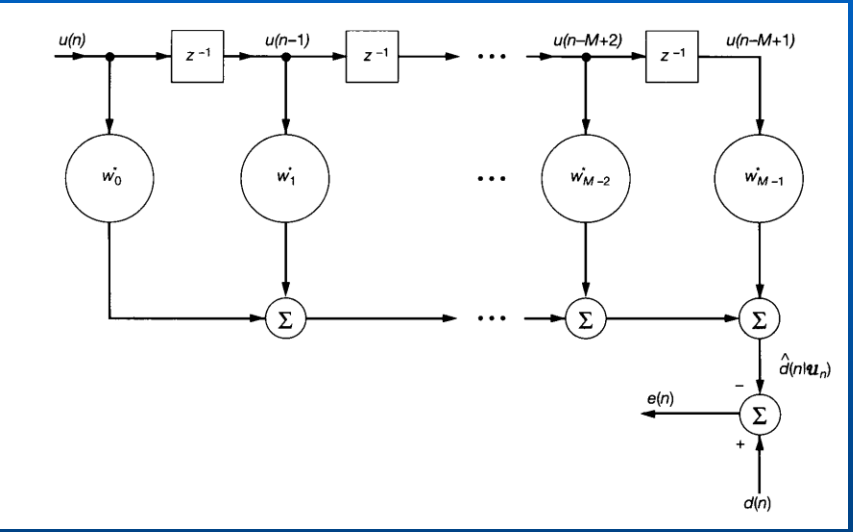

En ese caso las ecuaciones de Wiener - Hopf se convierten en un conjunto de *M* ecuaciones simultaneas:

$$\sum_{i=0}^{M-1} w_{oi}\, r(i-k) = p(-k), \quad k = 0, 1, 2, \cdots M-1$$

Filtro óptimo: estructura FIR ...

Si $\boldsymbol{R} = E[\boldsymbol{u}(n)\boldsymbol{u}^H(n)]$, es la matriz de correlación de las entradas de *u(n)* a *u(n-M+1)* al filtro FIR, donde $\boldsymbol{u}(n) = [u(n), u(n-1), \cdots, u(n-M+1)]^T$

En forma expandida

$$\boldsymbol{R} = \begin{bmatrix} r(0) & r(1) & \cdots & r(M-1) \\ r^*(1) & r(0) & \cdots & r(M-2) \\ & & \vdots & \\ r^*(M-1) & r^*(M-2) & \cdots & r(0) \end{bmatrix}$$

Además, el vector de correlaciones cruzadas es $\boldsymbol{p} = E[\boldsymbol{u}(n)d^*(n)]$, tal que $\boldsymbol{p}(n) = [p(0), p(-1), \cdots, p(1-M)]^T$.

Filtro óptimo: estructura FIR ...

Entonces las ecuaciones de Wiener-Hopf pueden reescribirse en forma matricial como

$$\boldsymbol{R}\boldsymbol{w}_o = \boldsymbol{p}$$

donde $\boldsymbol{w}_o$ es el vector de coeficientes óptimos del filtro transversal,

$$\boldsymbol{w}_o = [w_{o0}, w_{o1}, \cdots, w_{o,M-1}]^T$$

Dado que la matriz de correlación es generalmente no singular, la solución de las ecuaciones de Wiener-Hopf será

$$\boldsymbol{w}_o = \boldsymbol{R}^{-1}\boldsymbol{p}$$

Filtro óptimo: Superficie de MSE

Las ecuaciones de Wiener-Hopf como discutidas están relacionadas con el principio de ortogonalidad.

Es posible obtener esas ecuaciones examinando la dependencia en la función costo *J* de los coeficientes del filtro transversal. Con ese objetivo

$$e(n) = d(n) - \sum_{k=0}^{M-1} w_k^* u(n-k)$$

tal que

$$\begin{aligned} J &= E[e(n)e^*(n)] \\ &= E[|d(n)|^2] - \sum_{k=0}^{M-1} w_k^* E[u(n-k)d^*(n)] - \sum_{k=0}^{M-1} w_k E[u^*(n-k)d(n)] \\ &\quad + \sum_{k=0}^{M-1} \sum_{i=0}^{M-1} w_k^* w_i E[u(n-k)u^*(n-i)] \end{aligned}$$

Filtro óptimo: Superficie de MSE

Es posible reconocer

- Para el primer término tenemos $\sigma_d^2 = E[|d(n)|^2]$, donde σ_d^2 es la *varianza* de la respuesta deseada *d(n)*, supuesta de media cero.
- Para el segundo y el tercer término se tiene

$$\begin{aligned} p(-k) &= E[u(n-k)d^*(n)] \\ p^*(-k) &= E[u^*(n-k)d(n)] \end{aligned}$$

  donde *p(-k)* es la correlación cruzada entre *u(n-k)* y *d(n)*.
- Finalmente, pare el cuarto término se tiene

$$r(i-k) = E[u(n-k)u^*(n-i)]$$

  donde *r(i-k)* es la función autocorrelación para el retardo *i-k*.

Filtro óptimo: Superficie de MSE ...

- De esta forma

$$J = \sigma_d^2 - \sum_{k=0}^{M-1} w_k^* p(-k) + \sum_{k=0}^{M-1} w_k p^*(-k) + \sum_{k=0}^{M-1} \sum_{i=0}^{M-1} w_k^* w_i r(i-k)$$

- *J* es una *función de segundo orden de los coeficientes* del filtro y define en relación a los coeficientes $w_0, w_1, \cdots, w_{M-1}$ una superficie paraboloide de *M+1* dimensiones, con *M* grados de libertad representados por esos coeficientes, caracterizada por un único mínimo y denominada *superficie de desempeño del error* del filtro transversal.

- En el mínimo de la superficie de error, la función costo *J* alcanza su valor mínimo de J_{min}. En este punto el vector gradiente ∇J se anula, i.e.

$$\nabla_k J = 0, \quad k = 0, 1, \cdots, M-1$$

donde $\nabla_k J$ es el *k*-ésimo elemento del vector gradiente.

Filtro óptimo: Superficie de MSE ...

- Teniendo en cuenta, como antes la parte real e imaginaria de $w_k = a_k + jb_k$, es posible reescribir $\nabla_k J$ en base a *J* de la siguiente forma

$$\nabla_k J = \frac{\partial J}{\partial a_k} + j\frac{\partial J}{\partial b_k} = -2p(-k) + 2\sum_{i=0}^{M-1} w_i r(i-k)$$

tal que aplicando la condición de optimalidad se obtiene

$$\sum_{i=0}^{M-1} w_{oi} r(i-k) = p(-k), \quad k = 0, 1, \cdots, M-1$$

donde $w_{o0}, w_{o1}, \cdots, w_{o,M-1}$ son los coeficientes óptimos del filtro transversal. Estas ecuaciones son idénticas a las de Wiener-Hopf para ese filtro.

Filtro óptimo: MMSE

Si $\hat{d}(n|U_n)$ es la estimación de la respuesta deseada *d(n)*, entonces

$$\hat{d}(n|U_n) = \sum_{k=0}^{M-1} w_{ok}^* u(n-k) = \boldsymbol{w}_o^H \boldsymbol{u}(n)$$

de donde

$$\begin{aligned} \sigma_{\hat{d}}^2 &= E[\boldsymbol{w}_o^H \boldsymbol{u}(n) \boldsymbol{u}^H(n) \boldsymbol{w}_o] \\ &= \boldsymbol{w}_o^H E[\boldsymbol{u}(n) \boldsymbol{u}^H(n)] \boldsymbol{w}_o = \boldsymbol{w}_o^H \boldsymbol{R} \boldsymbol{w}_o \end{aligned}$$

donde $\boldsymbol{R}$ es la matriz correlación.

Filtro óptimo: MMSE ...

En particular es posible reescribir esta ecuación, usando la solución óptima de los coeficientes como

$$\sigma_{\hat{d}}^2 = \boldsymbol{w}_o^H \boldsymbol{p} = \boldsymbol{p}^H \boldsymbol{w}_o$$

Para evaluar el error medio cuadrático mínimo (MMSE) producido por el filtro transversal usamos esta última en J_{min} para obtener

$$J_{min} = \sigma_d^2 - \boldsymbol{p}^H \boldsymbol{w}_o = \sigma_d^2 - \boldsymbol{p}^H \boldsymbol{R}^{-1} \boldsymbol{p}$$

Filtro óptimo: Forma canónica del MSE

Utilizando la notación matricial

$$J(\boldsymbol{w}) = \sigma_d^2 - \boldsymbol{w}^H \boldsymbol{p} - \boldsymbol{p}^H \boldsymbol{w} + \boldsymbol{w}^H \boldsymbol{R} \boldsymbol{w}$$

Completando cuadrados sobre $J(\boldsymbol{w})$ en $\boldsymbol{w}$

$$J(\boldsymbol{w}) = \sigma_d^2 - \boldsymbol{p}^H \boldsymbol{R}^{-1} \boldsymbol{p} + (\boldsymbol{w} - \boldsymbol{R}^{-1} \boldsymbol{p})^H \boldsymbol{R} (\boldsymbol{w} - \boldsymbol{R}^{-1} \boldsymbol{p})$$

de donde obviamente es posible concluir que

$$\min_{\boldsymbol{w}} J(\boldsymbol{w}) = \sigma_d^2 - \boldsymbol{p} \boldsymbol{R}^{-1} \boldsymbol{p}$$

para $w_o = \boldsymbol{R}^{-1} \boldsymbol{p}$.

Filtro óptimo: Forma canónica del MSE ...

De esta forma

$$J(\boldsymbol{w}) = J_{min} + (\boldsymbol{w} - \boldsymbol{R}^{-1}\boldsymbol{p})^H \boldsymbol{R}(\boldsymbol{w} - \boldsymbol{R}^{-1}\boldsymbol{p}) \ (1)$$

Considerando que $\boldsymbol{R} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^H$, entonces

$$J(\boldsymbol{w}) = J_{min} + (\boldsymbol{w} - \boldsymbol{w}_o)^H \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^H(\boldsymbol{w} - \boldsymbol{w}_o)$$

Con una transformación sobre $\boldsymbol{w}$, de la forma $\boldsymbol{\nu} = \boldsymbol{Q}^H(\boldsymbol{w} - \boldsymbol{w}_o)$, es posible reescribir $J(\boldsymbol{w})$ en la forma *canónica*

$$J(\boldsymbol{w}) = J_{min} + \boldsymbol{\nu}^H \boldsymbol{\Lambda}\boldsymbol{\nu}$$

Filtro óptimo: Forma canónica del MSE ...

En esta nueva formulación del MSE no existen productos cruzados, de forma que

$$J = J_{min} + \sum_{k=1}^{M} \lambda_k \nu_k \nu_k^* = J_{min} + \sum_{k=1}^{M} \lambda_k |\nu_k|^2$$

donde ν_k es la *k*-ésima componente del vector $\boldsymbol{\nu}$.

El aspecto práctico de esta última representación es que $\boldsymbol{\nu}$ constituye el *sistema principal de coordenadas* de la superficie de desempeño.

Filtro óptimo: Forma canónica del MSE ...

Ejemplo

La señal deseada *d(n)* es un modelo AR de primer orden $H_1(z) = \frac{1}{1 + 0.8458z^{-1}}$

con una entrada $\nu_1(n)$ ruido blanco de media cero y varianza $\sigma_1^2 = 0.27$.
d(n) se aplica a un canal de comunicaciones modelado por un filtro de la forma

$$H_2(z) = \frac{1}{1 + 0.9458z^{-1}}$$

La salida del canal *x(n)* tiene una perturbación $\nu_2(n)$, ruido blanco de media cero y varianza $\sigma_2^2 = 0.1$, tal que la señal recibida es $u(n) = x(n) + \nu_2(n)$ ($\nu_1(n)$ y $\nu_2(n)$ no están correlacionados).

El objetivo es diseñar un filtro de Wiener de forma transversal con dos coeficientes para obtener una estimación de *d(n)* en sentido medio cuadrático.

Filtro óptimo: Forma canónica del MSE ...

Ejemplo ...

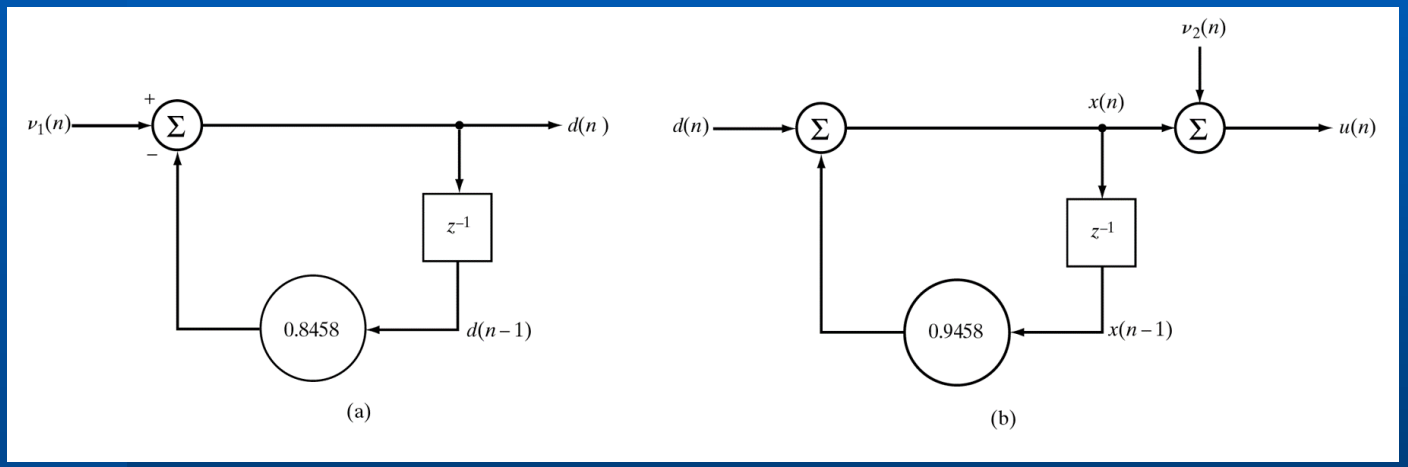

a) Modelo de señal, b) canal.

Filtro óptimo: Forma canónica del MSE ...

Ejemplo ...

La varianza de *d(n)* es

$$\sigma_d^2 = \frac{\sigma_1^2}{1 - a_1^2} = \frac{0.27}{1 - (0.8458)^2} = 0.9486$$

La salida del canal *x(n)* es entonces un proceso AR de segundo orden dado por

$$x(n) + a_1 x(n-1) + a_2 x(n-2) = \nu(n)$$

Donde $a_1 = -0.1$ y $a_2 = -0.8$. Notar que *d(n)* y *x(n)* son procesos estacionarios en sentido amplio.

Para obtener el filtro de Wiener es necesaria la matriz correlación $\boldsymbol{R}$ (2 x 2) asociada a la señal recibida *u(n)* y el vector de correlación cruzada $\boldsymbol{p}$ (2 x 1) entre *u(n)* y *d(n)*.

Filtro óptimo: Forma canónica del MSE ...

Ejemplo ...

La matriz de correlación será $\boldsymbol{R} = \boldsymbol{R}_x + \boldsymbol{R}_2$

Para $\boldsymbol{R}_x$ se tiene que

$$\begin{aligned} r_x(0) &= \sigma_x^2 = \left(\frac{1+a_2}{1-a_2}\right)\frac{\sigma_1^2}{[(1+a_2)^2 - a_1^2]} = 1 \\ r_x(1) &= \frac{-a_1}{1+a_2} = 0.5 \end{aligned}$$

de donde

$$\boldsymbol{R} = \begin{bmatrix} 1.1 & 0.5 \\ 0.5 & 1.1 \end{bmatrix}$$

Filtro óptimo: Forma canónica del MSE ...

Ejemplo ...

Para obtener $\boldsymbol{p}$ es necesario evaluar $E[u(n-k)d(n)]$, para *k=0,1*.

Sustituyendo $u(n) = x(n) + \nu_2(n)$ en la definición de *p(k)* se obtiene

$$p(k) = r_x(k) + b_1 r_x(k-1), \quad k = 0, 1$$

de forma que con $b_1 = -0.9458$ se obtiene

$$\boldsymbol{p} = \begin{bmatrix} 0.5272 \\ -0.4458 \end{bmatrix}.$$

Filtro óptimo: Forma canónica del MSE ...

Ejemplo ...

De esta forma es posible obtener el MSE

$$J(w_0, w_1) = 0.9486 - 1.0544 w_0 + 0.8916 w_1 + w_0 w_1 + 1.1(w_0^2 + w_1^2)$$

donde $J_{min} = 0.1579$, el filtro de Wiener $\boldsymbol{w}_o = \boldsymbol{R}^{-1}\boldsymbol{p} = \begin{bmatrix} 0.8360 \\ -0.7853 \end{bmatrix}$

y la superficie de desempeño canónica (con $\lambda_1 = 1.6$ y $\lambda_2 = 0.6$) dada por

$$J(\nu_1, \nu_2) = J_{min} + 1.6\nu_1^2 + 0.6\nu_2^2$$

Filtro óptimo: Forma canónica del MSE ...

Ejemplo ...

Superficie de MSE del filtro transversal del ejemplo.

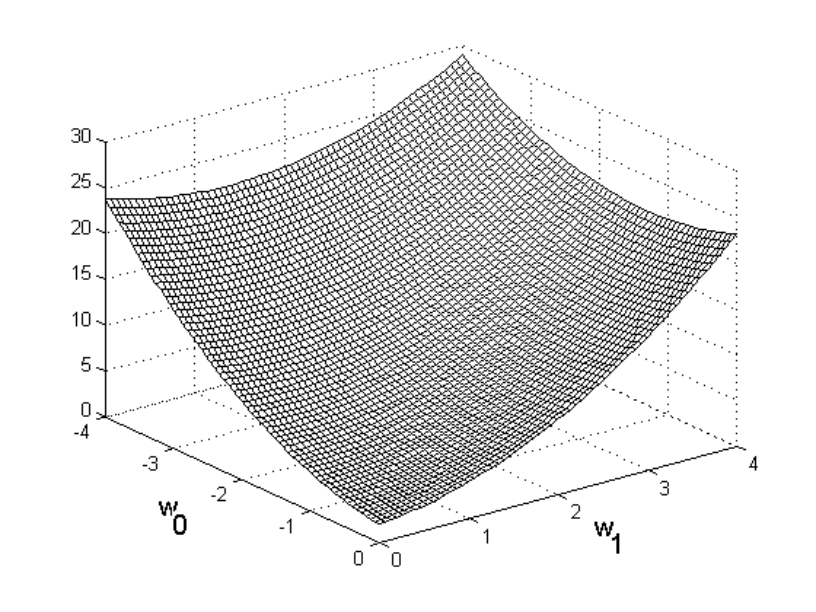

El lugar geométrico de ν_2, ν_1 es una *elipse* para un valor fijo de $J - J_{min}$.

En particular, la elipse tiene como eje menor

$$[(J - J_{min}/\lambda_1]^{1/2}$$

sobre ν_1 y como eje mayor

$$[(J - J_{min}/\lambda_2]^{1/2}$$

sobre la coordenada ν_2.

Filtro de Wiener

Filtros de Wiener

- El problema de filtrado optimo lineal
- El error medio cuadrático mínimo
- Ecuaciones de Wiener-Hopf

Predicción lineal

- Predicción lineal forward y backward
- Predictores Lattice
- Estimación conjunta y en bloques