

Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

Filtro de Kalman

Filtros Kalman


- El problema de filtrado Kalman
- Predicción usando innovaciones
- Filtrado y variantes del filtro de Kalman

Filtro de Kalman

- Se estudiará en términos de la *descripción por variables de estado*.
- La solución obtenida con el filtro Kalman se obtiene *recursivamente*.
- Puede utilizarse en la estimación de *estados y parámetros* de un sistema, aunque se utilizará esencialmente en la primera aplicación, a partir de la utilización de filtros FIR.
- El concepto de *innovación* es particularmente importante en su caracterización.
- Servirá esencialmente para un tratamiento unificado de una familia de algoritmos de filtrado adaptativo: Cuadrados Mínimos Recursivo (RLS).
- Se estudiará primero el problema de *estimación recursiva de media cuadrática mínima* (MMS) para el caso escalar y luego se extenderán los resultados al caso vectorial.

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar



Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

- Asumiendo que los datos en (y antes de) $n=0$ son cero y en base a un conjunto de datos $y(1), y(2), \dots, y(n-1)$ (Y_{n-1}), se estudiará el **estimador de media cuadrática mínima (MMS)** de una variable $x(n)$, $\hat{x}(n-1|Y_{n-1})$.
- Con $y(n)$, en el instante n es posible obtener una **estimación** $\hat{x}(n|Y_n)$ en base ahora a los datos almacenados $y(1), y(2), \dots, y(n-1)$ e $y(n)$.
- Es eficiente obtener esa estimación en forma recursiva. Existen varias formas, por ej.: definiendo el error de predicción forward como

$$f_{n-1}(n) = y(n) - \hat{y}(n|Y_{n-1}), \quad n = 1, 2, \dots$$

donde $\hat{y}(n|Y_{n-1})$ es la *predicción de un paso* de $y(n)$ utilizando los datos pasados hasta $n-1$. $f_{n-1}(n)$ es la salida de un filtro de predicción forward de orden $n-1$, cuyo orden aumenta linealmente con n .

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

- Por el principio de ortogonalidad, $f_{n-1}(n)$ es ortogonal a $y(1), y(2), \dots, y(n-1)$ y puede interpretarse como una medida de la información *nueva* que aporta $y(n)$, por ello se introduce el nombre de *innovación*.
- La parte realmente *nueva* asociada a $y(n)$ está dada por $f_{n-1}(n)$, que definimos entonces como la *innovación* dada por

$$\alpha(n) = f_{n-1}(n), \quad n = 1, 2, \dots$$

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

Algunas propiedades importantes del proceso de innovación $\alpha(n)$:

1. $\alpha(n)$, asociado con $y(n)$ es ortogonal a los datos pasados $y(1), y(2), \dots, y(n-1)$, ya que

$$E[\alpha(n)y^*(k)] = 0, \quad 1 \leq k \leq n-1$$

Esto es simplemente otra forma de escribir el principio de ortogonalidad.

2. $\alpha(1), \alpha(2), \dots, \alpha(n)$ son ortogonales entre si, de forma que

$$E[\alpha(n)\alpha^*(k)] = 0, \quad 1 \leq k \leq n-1$$

Esto es la reformulación de

$$E[f_{n-1}(n)f_{n-1}^*(k)] = 0, \quad 1 \leq k \leq n-1$$

Esto implica que $\alpha(n)$ es un proceso *blanco*.

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

3. Existe una correspondencia uno a uno entre $\alpha(1), \alpha(2), \dots, \alpha(n)$ y $y(1), y(2), \dots, y(n)$, en el sentido que una secuencia puede obtenerse de la otra por medio de un filtro causal (y causalmente invertible) sin ninguna pérdida de información, o sea

$$[y(1), y(2), \dots, y(n)] \rightleftharpoons [\alpha(1), \alpha(2), \dots, \alpha(n)]$$

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

Para probar esta propiedad se utilizará una forma del *procedimiento de ortogonalización de Gram-Schmidt*.

- a) Suponiendo los datos $y(1), y(2), \dots, y(n)$ algebraicamente independientes, es posible hacer $\alpha(1) = y(1)$ (asumiendo $\hat{y}(1|Y_0) = 0$).
- b) Luego hacemos $\alpha(2) = y(2) + a_{1,1}y(1)$. $a_{1,1}$ se elige tal que $E[\alpha(2)\alpha(1)] = 0$.

$$a_{1,1} = -\frac{E[y(2)y^*(1)]}{E[y(1)y(1)]}$$

- a) Haciendo luego $\alpha(3) = y(3) + a_{2,1}y(2) + a_{2,2}y(1)$, donde $a_{2,1}$ y $a_{2,2}$ se eligen tal que $\alpha(3)$ sea ortogonal a $\alpha(1)$ y $\alpha(2)$.

$$a_{2,1} = -\frac{E[y(3)y^*(1)]}{E[y(1)y(1)]} \quad a_{2,2} = -\frac{E[y(3)y^*(2)]}{E[y(2)y(2)]}$$

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

d) Así en general

$$\begin{bmatrix} \alpha(1) \\ \alpha(2) \\ \vdots \\ \alpha(n) \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ a_{1,1} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n-1,n-1} & a_{n-1,n-2} & \cdots & 1 \end{bmatrix} \begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(n) \end{bmatrix}$$

e) Los elementos de la fila k de esta matriz triangular inferior de transformación dados por $a_{k-1,k-1}, a_{k-1,k-2}, \dots, 1$, $k=1, 2, \dots, n$, representan los coeficientes de un *filtro de error de predicción* de orden $k-1$.

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

- En base a la propiedad 3 es posible escribir

$$\begin{aligned}\hat{x}(n|Y_n) &= \text{estimación de MMS de } x(n) \text{ dados } y(1), y(2), \dots, y(n) \\ &= \text{estimación de MMS de } x(n) \text{ dados } \alpha(1), \alpha(2), \dots, \alpha(n)\end{aligned}$$

- Luego, es posible definir $\hat{x}(n|Y_n)$ como una combinación lineal de las innovaciones $\alpha(1), \alpha(2), \dots, \alpha(n)$, o sea

$$\hat{x}(n|Y_n) = \sum_{k=1}^n b_k \alpha(k)$$

donde los coeficientes b_k deben ser determinados.

Filtro de Kalman:

Estimación de media cuadrática mínima (MMS), caso escalar ...

- Utilizando la ortogonalidad de las innovaciones $\alpha(k)$ y eligiendo los b_k para minimizar la media cuadrática de $x(n) - \hat{x}(n|Y_n)$ (usando un procedimiento de ortogonalización como el anterior), hallamos que

$$b_k = \frac{E[x(n)\alpha^*(k)]}{E[\alpha(k)\alpha^*(k)]}, \quad 1 \leq k \leq n$$

- Notar que $\hat{x}(n|Y_n) = \sum_{k=1}^{n-1} b_k \alpha(k) + b_n \alpha(n)$, donde $b_n = \frac{E[x(n)\alpha^*(n)]}{E[\alpha(n)\alpha^*(n)]}$.


Pero, por definición, esto se puede escribir en forma recursiva como

$$\hat{x}(n|Y_n) = \hat{x}(n-1|Y_{n-1}) + b_n \alpha(n)$$

que define la **estimación (escalar) de media cuadrática mínima (MMC)**.

Filtro de Kalman

Un *sistema dinámico lineal discreto* se puede describir mediante el siguiente esquema



$x(n)$ (de dimensión M , desconocido) es suficiente para describir unívocamente el comportamiento dinámico del sistema no forzado.

Para estimarlo se utiliza el conjunto de datos observados $y(n)$, de dimensión N .

Filtro de Kalman

Las ecuaciones relacionadas son las siguientes:

1. Una *ecuación del proceso*, dada por

$$\mathbf{x}(n+1) = \mathbf{F}(n+1, n)\mathbf{x}(n) + \mathbf{v}_1(n)$$

donde $\mathbf{F}(n+1, n)$ ($M \times M$) es la *matriz de transición de estados*, conocida.

$\mathbf{v}_1(n)$ ($M \times 1$) representa el *ruido de proceso*, modelado por un proceso de ruido blanco, media cero y matriz correlación

$$E[\mathbf{v}_1(n)\mathbf{v}_1^H(n)] = \begin{cases} \mathbf{Q}_1(n), & n = k \\ \mathbf{0} & n \neq k \end{cases}$$

Filtro de Kalman

2. Una *ecuación de medición*, descrita por

$$\mathbf{y}(n) = \mathbf{C}(n)\mathbf{x}(n) + \mathbf{v}_2(n)$$

donde $\mathbf{C}(n)$ ($N \times M$) es la *matriz de medición*, conocida. $\mathbf{v}_2(n)$ ($N \times 1$) representa el *ruido de medición*, modelado por un proceso de ruido blanco, media cero y matriz correlación

$$E[\mathbf{v}_2(n)\mathbf{v}_2^H(k)] = \begin{cases} \mathbf{Q}_2(n), & n = k \\ \mathbf{0} & n \neq k \end{cases}$$

Se supone que el valor inicial del estado $\mathbf{x}(0)$ no está correlacionado con $\mathbf{v}_1(n)$ y $\mathbf{v}_2(n)$ para $n \geq 0$ y además que ambos son estadísticamente independientes, o sea $E[\mathbf{v}_1(n)\mathbf{v}_2^H(k)] = \mathbf{0}$ para todo n y k .

Filtro de Kalman

El problema de filtrado Kalman puede formalizarse como:

- Utilizar los datos completos, consistentes en $y(1), y(2), \dots, y(n)$ para obtener, para cada $n \geq 1$, la estimación de media cuadrática mínima (MMS) de los componentes del estado $x(i)$.
- El problema se denomina de **filtrado** si $i=n$, de **predicción** si $i > n$ y de **suavizado** si $1 \leq i < n$.

Filtro de Kalman ...

El proceso de Innovación $\alpha(n)$

Sea $\hat{\mathbf{y}}(n|\mathbf{Y}_{n-1})$ la estimación MMS de los datos $\mathbf{y}(n)$ en el instante n , dados $\mathbf{y}(1), \mathbf{y}(2), \dots, \mathbf{y}(n-1)$ que forman el espacio vectorial $\mathbf{Y}_{n-1}$.

El proceso de *innovación* asociado a $\mathbf{y}(n)$ se define como

$$\alpha(n) = \mathbf{y}(n) - \hat{\mathbf{y}}(n|\mathbf{Y}_{n-1}), \quad n = 1, 2, \dots$$

Filtro de Kalman ...

El proceso de Innovación $\alpha(n)$...

Generalizando los resultados del caso escalar, las propiedades del proceso de innovación $\alpha(n)$ ($M \times 1$) son las siguientes

1. $\alpha(n)$ asociado a $y(n)$ es ortogonal a $y(1), y(2), \dots, y(n-1)$, o sea

$$E[\alpha(n)y^H(k)] = 0, \quad 1 \leq k \leq n-1$$

2. La secuencia de procesos de innovación es ortogonal, o sea

$$E[\alpha(n)\alpha^H(k)] = 0, \quad 1 \leq k \leq n-1$$

Filtro de Kalman ...

El proceso de Innovación $\alpha(n)$...

3. Existe una correspondencia uno a uno entre la secuencia de datos y las secuencias de innovaciones, en el sentido que una puede obtenerse de la otra por medio de operadores lineales estables sin pérdida de información. Esto puede escribirse como

$$[\mathbf{y}(1), \mathbf{y}(2), \dots, \mathbf{y}(n-1)] \rightleftharpoons [\boldsymbol{\alpha}(1), \boldsymbol{\alpha}(2), \dots, \boldsymbol{\alpha}(n-1)]$$

para obtener este mapeo puede utilizarse un procedimiento de ortogonalización de Gram – Schmidt como el analizado anteriormente.

Filtro de Kalman ...

Matriz de correlación del proceso de innovación $R(n)$

Para obtener la matriz de correlación del proceso de innovación $\alpha(n)$ tendremos en cuenta la solución de la ecuación del proceso, dada por

$$\mathbf{x}(k) = \mathbf{F}(k, 0)\mathbf{x}(0) + \sum_{i=1}^{k-1} \mathbf{F}(k, i+1)\mathbf{v}_1(i)$$

donde $\mathbf{x}(k)$ es una combinación lineal de $\mathbf{x}(0)$ y $\mathbf{v}_1(1), \mathbf{v}_1(2), \dots, \mathbf{v}_1(k-1)$ y, además, se utilizaron las siguientes definiciones y suposiciones

1. $\mathbf{x}(0)$ es el valor inicial del estado.
2. Los datos (y $\mathbf{v}_1(0)$) se asumen 0 para $n \leq 0$.
3. La matriz de transición de estados satisface

$$\mathbf{F}(k, k-1)\mathbf{F}(k-1, k-2) \cdots \mathbf{F}(i+1, i) = \mathbf{F}(k, i) \quad \text{y} \quad \mathbf{F}(k, k) = \mathbf{I}$$

Para un sistema invariante en el tiempo

$$\mathbf{F}(n+1, n) = \mathbf{F}(n+1-n) = \mathbf{F}(1) = \mathbf{I}$$

Filtro de Kalman ...

Matriz de correlación del proceso de innovación $\mathbf{R}(n)$...

Por hipótesis, es fácil verificar que: ($\mathbf{v}_2(n)$ no correlacionado con $\mathbf{x}(0)$ y $\mathbf{v}_1(n)$)

$$E[\mathbf{x}(k)\mathbf{v}_2^H(n)] = \mathbf{0}, \quad k, n \leq 0$$

Luego, de la ecuación de medición es posible concluir que

$$E[\mathbf{y}(k)\mathbf{v}_2^H(n)] = \mathbf{0}, \quad 0 \leq k \leq n-1$$

Además es posible escribir que

$$E[\mathbf{y}(k)\mathbf{v}_1^H(n)] = \mathbf{0}, \quad 0 \leq k \leq n$$

Filtro de Kalman ...

Matriz de correlación del proceso de innovación $R(n)$...

Dados los datos pasados $y(1), y(2), \dots, y(n-1)$, y usando la ecuación de medición, es posible hallar que la estimación MMS de $y(n)$ es:

$$\hat{y}(n|Y_{n-1}) = C(n)\hat{x}(n|Y_{n-1}) + \hat{v}_2(n|Y_{n-1})$$

Pero la estimación $\hat{v}_2(n|Y_{n-1})$ es cero ya que $v_2(n)$ es ortogonal a Y_{n-1} . De esto puede obtenerse

$$\hat{y}(n|Y_{n-1}) = C(n)\hat{x}(n|Y_{n-1})$$

de donde el *proceso de innovación* puede escribirse

$$\alpha(n) = y(n) - C(n)\hat{x}(n|Y_{n-1})$$

Filtro de Kalman ...

Matriz de correlación del proceso de innovación $R(n)$...

Sustituyendo la ecuación de medición en la anterior se obtiene

$$\alpha(n) = C(n)\epsilon(n, n-1) + v_2(n)$$

donde $\epsilon(n, n-1)$ es el *error de predicción del vector de estados* en el instante n utilizando datos hasta el instante $n-1$, o sea

$$\epsilon(n, n-1) = x(n) - \hat{x}(n|Y_{n-1})$$

Notar que $\epsilon(n, n-1)$ es ortogonal a $v_1(n)$ y $v_2(n)$.

Filtro de Kalman ...

Matriz de correlación del proceso de innovación $\mathbf{R}(n)$...

Finalmente la matriz de correlación del proceso de innovación se define por

$$\mathbf{R}(n) = E[\boldsymbol{\alpha}(n)\boldsymbol{\alpha}^H(n)]$$

Luego, usando el error de predicción en la anterior, expandiendo términos, y usando la ortogonalidad entre $\boldsymbol{\epsilon}(n, n-1)$ y $\mathbf{v}_2(n)$, se obtiene

$$\mathbf{R}(n) = \mathbf{C}(n)\mathbf{K}(n, n-1)\mathbf{C}^H(n) + \mathbf{Q}_2(n)$$

donde $\mathbf{K}(n, n-1)$ es la *matriz de correlación del error de predicción en los estados*, definida por

$$\mathbf{K}(n, n-1) = E[\boldsymbol{\epsilon}(n, n-1)\boldsymbol{\epsilon}^H(n, n-1)]$$

Filtro de Kalman ...

Predicción usando $\alpha(n)$

- La estimación de MMS de $x(i)$ puede obtenerse como una combinación lineal de la secuencia de procesos de innovación $\alpha(1), \alpha(2), \dots, \alpha(n)$, de la misma forma que en el caso escalar, o sea

$$\hat{x}(i|Y_n) = \sum_{k=1}^n B_i(k) \alpha(k)$$

donde $B_i(k)$, $k=1, 2, \dots, n$ es un conjunto de matrices de $(M \times N)$ a ser determinado.

- De acuerdo al principio de ortogonalidad, el error de predicción del vector de estados es ortogonal al proceso de innovación, como mostrado por

$$E[\epsilon(i, n) \alpha^H(m)] = E\{[x(i) - \hat{x}(i|Y_n)] \alpha^H(m)\} = \mathbf{0}, \quad m = 1, 2, \dots, n$$

Filtro de Kalman ...

Predicción usando $\alpha(n)$...

- Sustituyendo la primera ecuación en la segunda y utilizando la ortogonalidad del proceso de innovación se obtiene

$$E[\mathbf{x}(i)\boldsymbol{\alpha}^H(m)] = \mathbf{B}_i(m)E[\boldsymbol{\alpha}(m)\boldsymbol{\alpha}^H(m)] = \mathbf{B}_i(m)\mathbf{R}(m)$$

de donde $\mathbf{B}_i(m) = E[\mathbf{x}(i)\boldsymbol{\alpha}^H(m)]\mathbf{R}^{-1}(m)$

- Finalmente, sustituyendo esta ecuación en la combinación lineal, la estimación de MMS puede escribirse

$$\begin{aligned}\hat{\mathbf{x}}(i|\mathbf{Y}_n) &= \sum_{k=1}^n E[\mathbf{x}(i)\boldsymbol{\alpha}^H(k)]\mathbf{R}^{-1}(k)\boldsymbol{\alpha}(k) \\ &= \sum_{k=1}^{n-1} E[\mathbf{x}(i)\boldsymbol{\alpha}^H(k)]\mathbf{R}^{-1}(k)\boldsymbol{\alpha}(k) + E[\mathbf{x}(i)\boldsymbol{\alpha}^H(n)]\mathbf{R}^{-1}(n)\boldsymbol{\alpha}(n)\end{aligned}$$

Filtro de Kalman ...

Predicción usando $\alpha(n)$...

y para $i=n+1$ es posible escribir

$$\begin{aligned}\hat{\mathbf{x}}(n+1|\mathbf{Y}_n) &= \sum_{k=1}^n E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(k)]\mathbf{R}^{-1}(k)\boldsymbol{\alpha}(k) \\ &= \sum_{k=1}^{n-1} E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(k)]\mathbf{R}^{-1}(k)\boldsymbol{\alpha}(k) + E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(n)]\mathbf{R}^{-1}(n)\boldsymbol{\alpha}(n)\end{aligned}$$

- Para reducir esta ecuación, en particular, usando la matriz de transición de estados que relaciona $\mathbf{x}(n+1)$ con $\mathbf{x}(n)$, es posible escribir para $0 \leq k \leq n$

$$E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(k)] = E\{[\mathbf{F}(n+1, n)\mathbf{x}(n) + \mathbf{v}_1(n)]\boldsymbol{\alpha}^H(k)\} = \mathbf{F}(n+1, n)E[\mathbf{x}(n)\boldsymbol{\alpha}^H(k)]$$

Filtro de Kalman ...

Predicción usando $\alpha(n)$...

- Luego

$$\begin{aligned}\sum_{k=1}^{n-1} E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(k)]\mathbf{R}^{-1}(k)\boldsymbol{\alpha}(k) &= \mathbf{F}(n+1, n) \sum_{k=1}^{n-1} E[\mathbf{x}(n)\boldsymbol{\alpha}^H(k)]\mathbf{R}^{-1}(k)\boldsymbol{\alpha}(k) \\ &= \mathbf{F}(n+1, n)\hat{\mathbf{x}}(n|\mathbf{Y}_{n-1})\end{aligned}$$

- Para obtener una forma más simple del estimador se discutirán e introducirán a continuación algunas definiciones.

Filtro de Kalman ...

Ganancia de Kalman $G(n)$

- Definamos la matriz de $(M \times N)$, $G(n) = E[x(n+1)\alpha^H(n)]R^{-1}(n)$.
- Luego usando el resultado de la sección anterior es posible escribir la estimación MMS de estados como

$$\hat{x}(n+1|Y_n) = F(n+1, n)\hat{x}(n|Y_{n-1}) + G(n)\alpha(n)$$

- Esta es una versión vectorial de la ecuación recursiva del caso escalar. Es especialmente importante porque muestra que para obtener la estimación de MMS $\hat{x}(n+1|Y_n)$ de un sistema dinámico, es suficiente sumar a la estimación previa $\hat{x}(n|Y_{n-1})$ un término de corrección.
- Esencialmente la matriz $G(n)$ juega el papel de una *ganancia en relación al proceso de innovación* $\alpha(n)$.

Filtro de Kalman ...

Ganancia de Kalman $G(n)$...

- Para obtener una forma computacionalmente factible de $G(n)$ es posible tener en cuenta que

$$\begin{aligned} E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(n)] &= \mathbf{F}(n+1, n)E[\mathbf{x}(n)\boldsymbol{\alpha}^H(n)] \\ &= \mathbf{F}(n+1, n)E[\mathbf{x}(n)(\mathbf{C}(n)\boldsymbol{\epsilon}(n, n-1) + \mathbf{v}_2(n))^H] \\ &= \mathbf{F}(n+1, n)E[\mathbf{x}(n)\boldsymbol{\epsilon}^H(n, n-1)]\mathbf{C}^H(n) \end{aligned}$$

- Como $\boldsymbol{\epsilon}(n, n-1)$ es ortogonal a $\hat{\mathbf{x}}(n|Y_{n-1})$ es posible reemplazar


$$\begin{aligned} E[\mathbf{x}(n+1)\boldsymbol{\alpha}^H(n)] &= \mathbf{F}(n+1, n)E[\boldsymbol{\epsilon}(n, n-1)\boldsymbol{\epsilon}^H(n, n-1)]\mathbf{C}^H(n) \\ &= \mathbf{F}(n+1, n)\mathbf{K}(n, n-1)\mathbf{C}^H(n) \end{aligned}$$

de forma que sustituyendo esta ecuación en la definición de $G(n)$ se obtiene

$$\mathbf{G}(n) = \mathbf{F}(n+1, n)\mathbf{K}(n, n-1)\mathbf{C}^H(n)\mathbf{R}^{-1}(n)$$


Filtro de Kalman ...

Ganancia de Kalman $G(n)$...



Filtro de Kalman ...

Predictor de un paso usando la ganancia de Kalman $G(n)$



Esquema completo del *predictor de un paso* usando la ganancia de Kalman.

Filtro de Kalman ...

Ecuación de Riccati

- La ecuación de $G(n)$ aún no es útil dado que se requiere $K(n, n-1)$. El objetivo entonces es obtener recursivamente

$$K(n, n-1) = E[\epsilon(n+1, n)\epsilon^H(n+1, n)].$$

- Luego como

$$\begin{aligned}\epsilon(n+1, n) &= \mathbf{F}(n+1, n)[\mathbf{x}(n) - \hat{\mathbf{x}}(n|\mathbf{Y}_{n-1})] - \mathbf{G}(n)[\mathbf{y}(n) - \mathbf{C}(n)\hat{\mathbf{x}}(n|\mathbf{Y}_{n-1})] + \mathbf{v}_1(n) \\ &= [\mathbf{F}(n+1, n) - \mathbf{G}(n)\mathbf{C}(n)]\epsilon(n, n-1) + \mathbf{v}_1(n) - \mathbf{G}(n)\mathbf{v}_2(n)\end{aligned}$$

se obtiene que

$$\begin{aligned}K(n+1, n) &= [\mathbf{F}(n+1, n) - \mathbf{G}(n)\mathbf{C}(n)]K(n, n-1)[\mathbf{F}(n+1, n) - \mathbf{G}(n)\mathbf{C}(n)]^H \\ &\quad + \mathbf{Q}_1(n) - \mathbf{G}(n)\mathbf{Q}_2(n)\mathbf{G}(n)\end{aligned}$$

- Expandiendo el lado derecho de esta ecuación y utilizando las expresiones de las matrices $G(n)$ y $R(n)$, se obtiene la *ecuación a diferencias de Riccati*.

Filtro de Kalman ...

Ecuación de Riccati ...

- La ecuación de Riccati para obtener en forma recursiva la matriz de correlación del error de predicción en los estados está dada por


$$\mathbf{K}(n+1, n) = \mathbf{F}(n+1, n)\mathbf{K}(n)\mathbf{F}^H(n+1, n) + \mathbf{Q}_1(n)$$

donde, en particular usando $\mathbf{F}(n+1, n)\mathbf{F}(n, n+1) = \mathbf{I}$, se obtiene la recursividad para la matriz $\mathbf{K}(n)$ ($M \times M$), dada por

$$\mathbf{K}(n) = \mathbf{K}(n, n-1) - \mathbf{F}(n, n+1)\mathbf{G}(n)\mathbf{C}(n)\mathbf{K}(n, n-1)$$

esta matriz tiene una interpretación directa en el contexto de *filtrado* que se discutirá a continuación.

Filtro de Kalman ... Ecuación de Riccati ...



Filtro de Kalman: Observaciones

- La entrada al filtro Kalman son los datos $y(1), y(2), \dots, y(n)$ y la salida es la predicción del estado $\hat{x}(n+1|Y_n)$.
- Como $F(n+1, n)$, $C(n)$, $Q_1(n)$ y $Q_2(n)$ se suponen conocidas, de las ecuaciones de estimación MMS de la predicción del error en los estados y de Riccati es posible verificar que $K(n+1, n)$ es independiente de $y(n)$, y también $G(n)$. Luego ambas pueden ser obtenidas *antes de poner al filtro en operación*.
- $K(n+1, n)$ permite un análisis estadístico (condicionamiento numérico de la matriz) del error de estimación en los estados, de forma de conocer a priori si la solución que se obtiene con el filtro de Kalman es satisfactoria.

Filtro de Kalman: Observaciones ...

- Si $F(n+1, n)$, $C(n)$, $Q_1(n)$ y $Q_2(n)$ *no son totalmente conocidas a priori*, puede generalizarse los resultados del filtro de Kalman cuando estas dependen de $y(n)$.
- En ese caso $\hat{x}(n+1|Y_n)$ y $K(n+1, n)$ aún se obtienen de las ecuaciones de estimación MMS del vector de los estados y de Riccati respectivamente, pero ahora dependerán de $y(n)$.
- En particular, $K(n+1, n)$ es en ese caso una matriz correlación de error de predicción en los estados *condicional* sobre la entrada $y(n)$.

Filtro de Kalman: Filtrado

En particular se desea obtener la estimación $\hat{x}(n|Y_n)$ usando el algoritmo de predicción de un paso descrito anteriormente.

Para hallar la estimación de MMS de $x(n+1)$ a partir de la ecuación del proceso (teniendo en cuenta que $v_1(n)$ es independiente de $x(n)$ y de las entradas)

$$\hat{x}(n+1|Y_n) = F(n+1, n)\hat{x}(n|Y_n)$$

Luego

$$\begin{aligned}\hat{x}(n|Y_n) &= F^{-1}(n+1, n)\hat{x}(n+1|Y_n) \\ &= F(n, n+1)\hat{x}(n+1|Y_n)\end{aligned}$$

Filtro de Kalman: Filtrado ...

Error de estimación y factor de conversión

- En un contexto de filtrado es natural definir un *error de estimación de filtrado*, dado por

$$e(n) = \mathbf{y}(n) - \mathbf{C}(n)\hat{\mathbf{x}}(n|\mathbf{Y}_n)$$

- Esta definición es similar a la definición de $\alpha(n)$, excepto que se ha sustituido la predicción $\hat{\mathbf{x}}(n|\mathbf{Y}_{n-1})$ por la estimación de filtrado $\hat{\mathbf{x}}(n|\mathbf{Y}_n)$. Usando la ecuación de recursión de los estados en la anterior se obtiene

$$\begin{aligned} e(n) &= \mathbf{y}(n) - \mathbf{C}(n)\hat{\mathbf{x}}(n|\mathbf{Y}_{n-1}) - \mathbf{C}(n)\mathbf{F}(n, n+1)\mathbf{G}(n)\alpha(n) \\ &= \alpha(n) - \mathbf{C}(n)\mathbf{F}(n, n+1)\mathbf{G}(n)\alpha(n) \\ &= [\mathbf{I} - \mathbf{C}(n)\mathbf{F}(n, n+1)\mathbf{G}(n)]\alpha(n) \end{aligned}$$

- La matriz $[\mathbf{I} - \mathbf{C}(n)\mathbf{F}(n, n+1)\mathbf{G}(n)]$ se denomina *factor de conversión*, y convierte el vector de innovación $\alpha(n)$ en el vector de error de estimación de filtrado $e(n)$.

Filtro de Kalman: Filtrado ...

Error de estimación y factor de conversión ...

- Usando la expresión de la ganancia de Kalman es posible eliminar $G(n)$ para obtener

$$e(n) = Q_2(n)R^{-1}(n)\alpha(n)$$

- Así, excepto por $Q_2(n)$, la matriz $R(n)$ juega el papel de factor de conversión en la teoría de filtrado Kalman.
- Además en el caso en que $Q_2(n) = I$, R^{-1} es el factor de conversión exacto.

Filtro de Kalman: Filtrado ...

Matriz de correlación del error de estimación en filtrado $K(n)$

- Analizaremos una interpretación de $K(n)$, introducida en la ecuación de Riccati, a partir del cual será posible concluir que es igual a la *matriz de correlación del error de estimación en los estados*.

- Definimos el vector de error de estimación en filtrado $\epsilon(n)$ como

$$\epsilon(n) = \mathbf{x}(n) - \hat{\mathbf{x}}(n|\mathbf{Y}_n)$$

- Usando la ecuación recursiva de predicción de estados, y su reformulación para estimación, en la anterior se obtiene

$$\begin{aligned}\epsilon(n) &= \mathbf{x}(n) - \hat{\mathbf{x}}(n|\mathbf{Y}_{n-1}) - \mathbf{F}(n, n+1)\mathbf{G}(n)\boldsymbol{\alpha}(n) \\ &= \epsilon(n, n-1) - \hat{\mathbf{x}}(n|\mathbf{Y}_{n-1}) - \mathbf{F}(n, n+1)\mathbf{G}(n)\boldsymbol{\alpha}(n)\end{aligned}$$

Filtro de Kalman: Filtrado ...

Matriz de correlación del error de estimación en filtrado $\mathbf{K}(n)$...

- Luego la matriz correlación del error de estimación en los estados será

$$\begin{aligned} E[\epsilon(n)\epsilon^H(n)] &= E[\epsilon(n, n-1)\epsilon^H(n, n-1)] \\ &\quad + \mathbf{F}(n, n+1)\mathbf{G}(n)E[\alpha(n)\alpha^H(n)]\mathbf{G}^H(n)\mathbf{F}^H(n, n+1) \\ &\quad - 2E[\epsilon(n, n-1)\alpha^H(n)]\mathbf{G}^H(n)\mathbf{F}^H(n, n+1) \end{aligned}$$

- Para reducir esta expresión es posible tener en cuenta que las esperanzas del lado derecho pueden interpretarse como sigue:

1. El 1er. término es la matriz correlación del error de predicción en los estados $\mathbf{K}(n, n-1)$.
2. El 2do. término es la matriz de correlación de la innovación $\mathbf{R}(n)$.

Filtro de Kalman: Filtrado ...

Matriz de correlación del error de estimación en filtrado $\mathbf{K}(n)$...

3. Para interpretar el último término tenemos en cuenta que

$$\begin{aligned} E[\epsilon(n, n-1)\alpha^H(n)] &= E[(\mathbf{x}(n) - \hat{\mathbf{x}}(n|\mathbf{Y}_{n-1}))\alpha^H(n)] \\ &= E[\mathbf{x}(n)\alpha^H(n)] \end{aligned}$$

Luego, usando la correlación entre los vectores de estado e innovación para $k=n$ y premultiplicando por $\mathbf{F}^{-1}(n+1, n) = \mathbf{F}(n, n+1)$, se obtiene

$$\begin{aligned} E[\mathbf{x}(n)\alpha^H(n)] &= \mathbf{F}(n, n+1)E[\mathbf{x}(n+1)\alpha^H(n)] \\ &= \mathbf{F}(n, n+1)\mathbf{G}(n)\mathbf{R}(n) \end{aligned}$$

de donde

$$E[\epsilon(n, n-1)\alpha^H(n)] = \mathbf{F}(n, n+1)\mathbf{G}(n)\mathbf{R}(n)$$

Filtro de Kalman: Filtrado ...

Matriz de correlación del error de estimación en filtrado $\mathbf{K}(n)$...

- Además teniendo en cuenta que

$$\mathbf{G}(n)\mathbf{R}(n) = \mathbf{F}(n+1, n)\mathbf{K}(n, n-1)\mathbf{C}^H(n)$$

es posible finalmente obtener

$$E[\boldsymbol{\epsilon}(n)\boldsymbol{\epsilon}^H(n)] = \mathbf{K}(n, n-1) - \mathbf{K}(n, n-1)\mathbf{C}^H(n)\mathbf{G}^H(n)\mathbf{F}^H(n, n+1)$$

o en forma equivalente

$$E[\boldsymbol{\epsilon}(n)\boldsymbol{\epsilon}^H(n)] = \mathbf{K}(n, n-1) - \mathbf{F}(n, n+1)\mathbf{G}(n)\mathbf{C}(n)\mathbf{K}(n, n-1)$$

de donde se verifica, comparando con la ecuación de Riccati, que
 $E[\boldsymbol{\epsilon}(n)\boldsymbol{\epsilon}^H(n)] = \mathbf{K}(n)$.

Filtro de Kalman: Algoritmo completo

- Para operar adecuadamente los algoritmos de predicción de un paso y de filtrado descritos en las secciones anteriores es necesario obviamente especificar *condiciones iniciales*.
- El estado inicial de la ecuación del proceso no es conocido en general en forma exacta, de forma que es posible caracterizarlo por su media y correlación como

$$\begin{aligned}\hat{\mathbf{x}}(1|\mathbf{Y}_0) &= E[\mathbf{x}(1)] \\ \mathbf{K}(1,0) &= E[(\mathbf{x}(1) - E[\mathbf{x}(1)])(\mathbf{x}(1) - E[\mathbf{x}(1)])^H]\end{aligned}$$

- La tabla siguiente presenta un resumen del filtro de Kalman para la predicción de un paso.

Filtro de Kalman: Algoritmo completo ...

Vector de entrada:

$$\text{Observaciones} = \{\mathbf{y}(1), \mathbf{y}(2), \dots, \mathbf{y}(n)\}$$

Parámetros conocidos:

$$\text{Matriz de transición de estados} = \mathbf{F}(n+1, n)$$

$$\text{Matriz de medición} = \mathbf{C}(n)$$

$$\text{Matriz de correlación del ruido de proceso} = \mathbf{Q}_1(n)$$

$$\text{Matriz de correlación del ruido de medición} = \mathbf{Q}_2(n)$$

Condiciones iniciales:

$$\hat{\mathbf{x}}(1|\mathbf{Y}_0) = E[\mathbf{x}(1)]$$

$$\mathbf{K}(1, 0) = E[(\mathbf{x}(1) - E[\mathbf{x}(1)])(\mathbf{x}(1) - E[\mathbf{x}(1)])^H] = \mathbf{\Pi}_0$$

Calcular: Para $n = 1, 2, 3, \dots$

$$\mathbf{G}(n) = \mathbf{F}(n+1, n)\mathbf{K}(n, n-1)\mathbf{C}^H(n)[\mathbf{C}(n)\mathbf{K}(n, n-1)\mathbf{C}^H(n) + \mathbf{Q}_2(n)]^{-1}$$

$$\boldsymbol{\alpha}(n) = \mathbf{y}(n) - \mathbf{C}(n)\hat{\mathbf{x}}(n|\mathbf{Y}_{n-1})$$


$$\hat{\mathbf{x}}(n+1|\mathbf{Y}_n) = \mathbf{F}(n+1, n)\hat{\mathbf{x}}(n|\mathbf{Y}_{n-1}) + \mathbf{G}(n)\boldsymbol{\alpha}(n)$$

$$\mathbf{K}(n) = \mathbf{K}(n, n-1) - \mathbf{F}(n, n+1)\mathbf{G}(n)\mathbf{C}(n)\mathbf{K}(n, n-1)$$

$$\mathbf{K}(n+1, n) = \mathbf{F}(n+1, n)\mathbf{K}(n)\mathbf{F}^H(n+1, n) + \mathbf{Q}_1(n)$$

Filtro de Kalman: Algoritmo completo

Diagrama en bloques del estimador de estados con el filtro de Kalman en base a predicción de un paso.



Variantes del filtro de Kalman

Caso especial: sistema sin ruido de proceso

La principal razón para introducir el filtro de Kalman es la de proveer un marco general para el estudio de ciertos algoritmos de filtrado adaptivo conocidos colectivamente como algoritmos de *Cuadrados Mínimos Recursivos* (RLS).

- Consideremos un sistema dinámico lineal

$$\begin{aligned} \mathbf{x}(n+1) &= \lambda^{-1/2} \mathbf{x}(n) \\ y(n) &= \mathbf{u}^H(n) \mathbf{x}(n) + \nu(n) \end{aligned}$$

donde λ es un escalar positivo, el ruido de proceso ($\mathbf{v}_2(n)$) es cero, y el ruido de medición $\nu(n)$ es un proceso escalar, de media cero y varianza unitaria, o sea

$$E[\nu^2(n)] = \begin{cases} 1, & n = k \\ 0, & n \neq k \end{cases}$$

Variantes del filtro de Kalman ...

Caso especial: sistema sin ruido de proceso ...


- Comparándolo con el modelo general, ahora se tiene

$$\begin{aligned} \mathbf{F}(n+1, n) &= \lambda^{-1/2} \mathbf{I} & \mathbf{Q}_1(n) &= \mathbf{0} \\ \mathbf{C}(n) &= \mathbf{u}^H(n) & \mathbf{Q}_2(n) &= 1 \end{aligned}$$

- El sistema así descrito se denomina *modelo dinámico no forzado* porque la ecuación del proceso no tiene una excitación externa.
- Este modelo es la clave para analizar la familia de algoritmos RLS. En ese caso, λ tiene un papel importante en el funcionamiento de esos algoritmos.

Variantes del filtro de Kalman ...

Caso especial: sistema sin ruido de proceso ...



Modelo en variables de estado de un filtro RLS con un factor de ponderación exponencial $0 < \lambda \leq 1$.

Variantes del filtro de Kalman ...

Algoritmo de filtrado tipo *covarianza*

El algoritmo general de la tabla anterior está diseñado para utilizar $\mathbf{K}(n+1, n)$ asociada al error en la estimación del estado $\hat{\mathbf{x}}(n+1|Y_n)$. Se denomina *filtro Kalman tipo covarianza* y en la tabla usa el *modelo dinámico no forzado*.

Entrada escalar:

Observaciones = $y(1), y(2), \dots, y(n)$

Parámetros conocidos:

Matriz de transición de estados = $\lambda^{-1/2} \mathbf{I}$

Matriz de medición = $\mathbf{u}^H(n)$

Matriz de correlación del ruido de medición $\nu(n) = 1$

Condiciones iniciales:

$\hat{\mathbf{x}}(1|Y_0) = E[\mathbf{x}(1)]$

$\mathbf{K}(1, 0) = E[(\mathbf{x}(1) - E[\mathbf{x}(1)])(\mathbf{x}(1) - E[\mathbf{x}(1)])^H] = \mathbf{\Pi}_0$

Calcular: Para $n = 1, 2, 3, \dots$

$\mathbf{g}(n) = \frac{\lambda^{-1/2} \mathbf{K}(n-1) \mathbf{u}(n)}{\mathbf{u}^H(n) \mathbf{K}(n-1) \mathbf{u}(n) + 1}$

$\alpha(n) = y(n) - \mathbf{u}^H(n) \hat{\mathbf{x}}(n|Y_{n-1})$

$\hat{\mathbf{x}}(n+1|Y_n) = \lambda^{-1/2} \hat{\mathbf{x}}(n|Y_{n-1}) + \mathbf{g}(n) \alpha(n)$

$\mathbf{K}(n) = \lambda^{-1} \mathbf{K}(n-1) - \lambda^{-1/2} \mathbf{g}(n) \mathbf{u}^H(n) \mathbf{K}(n-1)$

Variantes del filtro de Kalman ...

Algoritmo de filtrado tipo *información*

- El filtro Kalman también puede implementarse utilizando recursivamente la matriz $K^{-1}(n)$.
- Esta matriz está relacionada con la *matriz de Información de Fisher*, la cual permite una interpretación del desempeño del filtro en términos de Teoría de Estimación (en particular asociada a la varianza mínima de un estimador o Límite de Cramer-Rao).
- Por ello este tipo se denomina *filtro Kalman tipo información*.

Variantes del filtro de Kalman ...

Algoritmo de filtrado tipo *información* ...

Para obtener el algoritmo tipo información para el modelo dinámico no forzado seguiremos los siguientes pasos

1. A partir de la ecuación de Riccati (última línea del algoritmo anterior) y de la ecuación de ganancia $g(n)$ se obtiene

$$\mathbf{K}^{-1}(n) = \lambda \mathbf{K}^{-1}(n-1) + \lambda \mathbf{u}(n) \mathbf{u}^H(n)$$

2. De la primera, segunda y tercera líneas del algoritmo anterior se obtiene

$$\mathbf{K}^{-1}(n) \hat{\mathbf{x}}(n+1|Y_n) = \lambda^{1/2} [\mathbf{K}^{-1}(n-1) \hat{\mathbf{x}}(n|Y_{n-1}) + \mathbf{u}(n) y(n)]$$

3. Combinando el resultado de los pasos anteriores

$$\begin{aligned} \hat{\mathbf{x}}(n+1|Y_n) &= \mathbf{K}(n) (\mathbf{K}^{-1}(n) \hat{\mathbf{x}}(n+1|Y_n)) \\ &= [\mathbf{K}^{-1}(n)]^{-1} (\mathbf{K}^{-1}(n) \hat{\mathbf{x}}(n+1|Y_n)) \end{aligned}$$

Variantes del filtro de Kalman ...

Algoritmo de filtrado tipo *información* ...

A pesar que los algoritmos tipo covarianza e información son algebraicamente equivalentes (tienen igual complejidad computacional $O(M^2)$), sus propiedades numéricas difieren sustancialmente. La tabla siguiente describe el algoritmo de *filtrado Kalman tipo información* para el modelo dinámico no forzado.

Entrada escalar:

$$\text{Observaciones} = y(1), y(2), \dots, y(n)$$

Parámetros conocidos:

$$\text{Matriz de transición de estados} = \lambda^{-1/2} \mathbf{I}$$

$$\text{Matriz de medición} = \mathbf{u}^H(n)$$

$$\text{Matriz de correlación del ruido de medición } \nu(n) = 1$$

Condiciones iniciales:

$$\hat{\mathbf{x}}(1|\mathbf{Y}_0) = E[\mathbf{x}(1)]$$

$$\mathbf{K}(1,0) = E[(\mathbf{x}(1) - E[\mathbf{x}(1)])(\mathbf{x}(1) - E[\mathbf{x}(1)])^H] = \mathbf{\Pi}_0$$

Calcular: Para $n = 1, 2, 3, \dots$

$$\mathbf{K}^{-1}(n) = \lambda \mathbf{K}^{-1}(n-1) + \lambda \mathbf{u}(n) \mathbf{u}^H(n)$$

$$\mathbf{K}^{-1}(n) \hat{\mathbf{x}}(n+1|Y_n) = \lambda^{1/2} [\mathbf{K}^{-1}(n-1) \hat{\mathbf{x}}(n|Y_{n-1}) + \mathbf{u}(n) y(n)]$$

$$\hat{\mathbf{x}}(n+1|Y_n) = [\mathbf{K}^{-1}(n)]^{-1} (\mathbf{K}^{-1}(n) \hat{\mathbf{x}}(n+1|Y_n))$$

Variantes del filtro de Kalman ...

Factorización de $K(n)$

- El algoritmo tipo covarianza sufre de problemas numéricos graves. En particular, dado que $K(n)$ está definida por la diferencia entre dos matrices no negativas solo una gran precisión numérica evitará que en alguna iteración $K(n)$ sea indefinida.
- Estos problemas de condicionamiento numérico con aritmética de longitud finita se denominan *fenómenos de divergencia*.
- Estos problemas pueden evitarse trabajando con una factorización adecuada de la matriz $K(n)$.

Variantes del filtro de Kalman ...

Factorización de $\mathbf{K}(n)$...

- En particular utilizando recursivamente la matriz $\mathbf{K}(n)$ a partir de la *factorización de Cholesky*

$$\mathbf{K}(n) = \mathbf{K}^{1/2}(n)\mathbf{K}^{T/2}(n)$$

donde $\mathbf{K}^{1/2}(n)$ es una matriz triangular inferior. Esta factorización se denomina de *raíz cuadrada* y es mucho menos proclive a problemas numéricos.

- Para el caso del algoritmo tipo información puede utilizarse recursivamente una factorización de $\mathbf{K}^{-1}(n)$ de la forma

$$\mathbf{K}^{-1}(n) = \mathbf{K}^{-1/2}(n)\mathbf{K}^{-T/2}(n)$$

Filtro de Kalman

Filtros Kalman

- El problema de filtrado Kalman
- Predicción usando innovaciones
- Filtrado y variantes del filtro de Kalman