

Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

Menor Cuadrado Mínimo (LMS)

Método de Steepest Descent

- Algoritmo Steepest Descent
- Estabilidad del algoritmo

Algoritmo LMS

- Ajuste de los coeficientes
- Estabilidad y desempeño del algoritmo LMS
- El algoritmo LMS normalizado

Filtrado adaptativo en el dominio frecuencia

- Filtrado adaptativo en bloques
- Algoritmo adaptativo con preprocesamiento
- Clasificación de algoritmos

Método Steepest Descent

- Este método determinístico es básico para el entendimiento de varias formas prácticas de implementar algoritmos de adaptivos con base en el gradiente.
- El método de Steepest Descent (SD) es recursivo en si mismo ya que, comenzando en algún valor inicial arbitrario del vector de parámetros, evoluciona con el incremento del número de iteraciones.
- El valor final así calculado converge a la solución de Wiener.
- El aspecto importante a notar con este método es que describe un sistema determinístico realimentado que encuentra el mínimo de la superficie de desempeño sin conocimiento específico del mismo. De esta forma, provee ideas heurísticas, en un contexto estocástico, para el algoritmo Least Mean Squares (LMS), que será discutido posteriormente.

Método Steepest Descent ...


Algunos conceptos

- Consideraremos un filtro transversal con entrada $u(n)$ (proceso ESA de media cero y matriz correlación R) y coeficientes $\mathbf{w}(n) = [w_0(n), w_1(n), \dots, w_{M-1}(n)]^T$, y además $d(n)$ que provee la referencia para la acción de filtrado óptimo.
- Es posible definir el vector de entrada $\mathbf{u}(n) = [u(n), u(n-1), \dots, u(n-M+1)]^T$ y la estimación de la respuesta deseada como $\hat{d}(n|\mathcal{U}_n)$.
- El error de estimación se definirá como

$$e(n) = d(n) - \hat{d}(n|\mathcal{U}_n) = d(n) - \mathbf{w}^H(n)\mathbf{u}(n)$$

Método Steepest Descent ...

Algunos conceptos ...



Estructura del filtro adaptativo transversal

Método Steepest Descent ...

Algunos conceptos ...

- Si $u(n)$ y $d(n)$ son conjuntamente ESA, entonces el *error medio cuadrático* (MSE) ó la función costo $J(n)$ en el instante n es una función cuadrática del vector de coeficientes, como mostrado por

$$J(n) = E[|e(n)|^2] = \sigma_d^2 - \mathbf{w}^H(n)\mathbf{p} - \mathbf{p}^H\mathbf{w}(n) + \mathbf{w}^H(n)\mathbf{R}\mathbf{w}(n)$$

$$\mathbf{R} = E[\mathbf{u}(n)\mathbf{u}^H(n)] \quad \mathbf{p} = E[\mathbf{u}(n)d(n)]$$

- Esto define el MSE que resultaría si el vector de coeficientes del filtro fuera fijo en el valor $\mathbf{w}(n)$. Dado que $\mathbf{w}(n)$ varía con n , es natural que el error medio cuadrático varía con n en la forma correspondiente. Esta variación de $J(n)$ significa que el proceso de error de estimación $e(n)$ no es estacionario.

Método Steepest Descent ...

Algunos conceptos

- Es posible visualizar la relación entre los coeficientes del filtro y $J(n)$ como una superficie paraboloides con un único mínimo, que denominaremos *superficie de desempeño del error* asociado al filtro adaptativo. El proceso adaptativo tiene como propósito buscar el punto de mínimo de esta superficie.
- En el punto de mínimo de la superficie de desempeño el vector de coeficientes tomará el valor óptimo w_o , definido por las ecuaciones de Wiener-Hopf:
 $Rw_o = p$.
- El valor del error medio cuadrático mínimo será $J_{min} = \sigma_d^2 - p^H w_o$

Método Steepest Descent ... Algoritmo

- El requerimiento para el filtro que minimice el MSE es resolver la ecuación de Wiener-Hopf en términos de los coeficientes asociados. Una forma es resolver el sistema de ecuaciones por medios analíticos directamente.
- Sin embargo, esa forma introduce problemas computacionales serios (complejidad) sobre todo cuando el filtro tiene un gran número de coeficientes y cuando la velocidad de procesamiento requerida es alta.
- Un procedimiento alternativo es a través del método Steepest Descent (SD), uno de los métodos más antiguos de optimización.

Método Steepest Descent ... Algoritmo

- Para hallar el valor del mínimo del error medio cuadrático J_{min} mediante el algoritmo SD, **en forma iterativa**, es posible proceder como a continuación:
 1. Comenzamos con un valor inicial $w(0)$ para el vector de coeficientes, el cual provee una estimación inicial del punto de mínimo de la superficie de error. A menos que se disponga de alguna información a priori, $w(0) = 0$.
 2. Con la estimación disponible se calcula el **vector gradiente**, cuyas partes real e imaginaria están definidas como la derivada del error medio cuadrático $J(n)$, evaluada con respecto a las partes real e imaginaria del vector de coeficientes $w(n)$.
 3. Se calcula la próxima estimación del vector de coeficientes haciendo un cambio en la estimación anterior en la dirección opuesta a la del vector gradiente.
 4. Se vuelve al paso 2 y se repite el proceso.

Método Steepest Descent ... Algoritmo

- Si $\nabla J(n)$ es el vector gradiente en el instante n , entonces el método SD puede escribirse recursivamente como

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \frac{1}{2}\mu[-\nabla J(n)]$$

donde μ es una constante positiva real y el factor $1/2$ se incluye para simplificar constantes posteriores en el análisis del método.

- El vector gradiente está dado por

$$\begin{aligned}\nabla J(n) &= \begin{bmatrix} \frac{\partial J(n)}{\partial a_0(n)} + j \frac{\partial J(n)}{\partial b_0(n)} \\ \frac{\partial J(n)}{\partial a_1(n)} + j \frac{\partial J(n)}{\partial b_1(n)} \\ \vdots \\ \frac{\partial J(n)}{\partial a_{M-1}(n)} + j \frac{\partial J(n)}{\partial b_{M-1}(n)} \end{bmatrix} \\ &= -2\mathbf{p} + 2\mathbf{R}\mathbf{w}(n)\end{aligned}$$

donde se supone que $\mathbf{R}$ y $\mathbf{p}$ son conocidos.

Método Steepest Descent ... Algoritmo

- Sustituyendo el gradiente en la ecuación de adaptación del método SD se obtiene

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \mu[\mathbf{p} - \mathbf{R}\mathbf{w}(n)]$$

- Es posible observar que el parámetro μ controla el tamaño del paso de la corrección incremental aplicada al vector de coeficientes, se lo denomina en general *factor de convergencia*.

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo

- Como el algoritmo es recursivo existe la posibilidad de volverse *inestable*.
- El *desempeño de estabilidad* del algoritmo SD está determinado por dos factores: μ y R .
- Para determinar la *condición de estabilidad* del algoritmo es necesario examinar los *modos naturales* del mismo.
- En particular, utilizaremos la representación de R en términos de autovalores y autovectores para definir una versión transformada del vector de coeficientes.

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...

- Comenzaremos el análisis definiendo el *vector de error en los coeficientes* como

$$\mathbf{c}(n) = \mathbf{w}(n) - \mathbf{w}_o$$

donde $\mathbf{w}_o$ es el valor óptimo del vector de coeficientes, definido por la ecuación de Wiener-Hopf.

- Luego, usando $\mathbf{p} = \mathbf{R}\mathbf{w}_o$ en la ecuación de adaptación se obtiene

$$\mathbf{c}(n+1) = (\mathbf{I} - \mu\mathbf{R})\mathbf{c}(n)$$

- También, usando la transformación de similaridad unitaria es posible expresar la matriz correlación como $\mathbf{R} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^H$.

- De esta forma

$$\mathbf{c}(n+1) = (\mathbf{I} - \mu\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^H)\mathbf{c}(n)$$

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...

- Premultiplicando ambos lados de esta ecuación por Q^H y usando que $Q^H = Q^{-1}$, se tiene que

$$Q^H c(n+1) = (I - \mu\Lambda)Q^H c(n)$$

- Si definimos ahora un nuevo conjunto de coordenadas como

$$\nu(n) = Q^H c(n) = Q^H [w(n) - w_o]$$

la ecuación anterior toma la forma

$$\nu(n+1) = (I - \mu\Lambda)\nu(n)$$

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...

- El valor inicial de $\nu(n)$ será

$$\begin{aligned}\nu(0) &= Q^H[w(0) - w_o] \\ &= -Q^H w_o\end{aligned}$$

donde en el segundo paso se consideró que $w(0) = 0$

- Para el k -ésimo *modo natural* del algoritmo SD se tiene que

$$\nu_k(n+1) = (1 - \mu\lambda_k)\mu_k(n), \quad k = 1, 2, \dots, M$$

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...

- La ecuación anterior es una *ecuación a diferencias escalar de primer orden*.
- Suponiendo que $\nu_k(n)$ tiene valor inicial $\nu_k(0)$, la solución tiene la forma

$$\nu_k(n) = (1 - \mu\lambda_k)^n \nu_k(0), \quad k = 1, 2, \dots, M$$

- Dado que todos los autovalores de $\mathbf{R}$ son positivos y reales, la respuesta $\nu_k(n)$ no exhibe oscilaciones. Además, los valores generados por esa ecuación representan una *serie geométrica*, con razón igual a $1 - \mu\lambda_k$.
- Para garantizar la **estabilidad (o convergencia)** del algoritmo SD, la magnitud de esta razón debe ser menor que 1 para todo k , *i.e.*, si $-1 < 1 - \mu\lambda_k < 1$. (para $n \rightarrow \infty$ todos los modos naturales del algoritmo se desvanecen, independientemente de las condiciones iniciales).

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...


- Esto es equivalente a decir que $w(n) \rightarrow w_o$ cuando n tiende a infinito.
- *La condición necesaria y suficiente para la convergencia* o estabilidad del algoritmo SD es que el factor de convergencia μ satisfaga

$$0 < \mu < \frac{2}{\lambda_{max}}$$

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...

Variación en el tiempo del modo natural k -ésimo en el algoritmo SD con el tiempo, suponiendo que $1 - \mu\lambda_k < 1$.



- En base a la figura, es posible inferir una envolvente exponencial de *constante de tiempo* τ_k asociada a la serie geométrica.

Método Steepest Descent ...

Estabilidad (convergencia) del algoritmo ...

- Asumiendo que la unidad de tiempo es la duración de un ciclo de iteración y eligiendo la constante de tiempo τ_k tal que

$$1 - \mu\lambda_k = e^{-\frac{1}{\tau_k}}$$

se obtiene

$$\tau_k = \frac{-1}{\ln(1 - \mu\lambda_k)}$$

- La constante de tiempo τ_k define el número de iteraciones requeridas por la amplitud del k -ésimo modo natural $\nu_k(n)$ para decaer $1/e$ de su valor inicial $\nu_k(0)$.
- Para el caso especial de adaptación lenta (μ pequeño), es posible aproximar la constante de tiempo por

$$\tau_k \cong \frac{1}{\mu\lambda_k}, \quad \mu \ll 1$$

Método Steepest Descent ...

Comportamiento transitorio

- Es posible formular el comportamiento transitorio del vector de coeficientes premultiplicando ambos lados de la ecuación de transformación de coordenadas por Q , y resolviendo para $w(n)$

$$w(n) = w_o + Q\nu(n) = w_o + \sum_{k=1}^M q_k \nu_k(n)$$

- Luego, el comportamiento transitorio del i -ésimo coeficiente será

$$w_i(n) = w_{oi} + \sum_{k=1}^M q_{ki} \nu_k(0) (1 - \mu \lambda_k)^n, \quad i = 1, 2, \dots, M$$

donde w_{oi} es el valor óptimo del i -ésimo coeficiente y q_{ki} es el i -ésimo elemento del k -ésimo autovector q_k .

- Cada coeficiente converge a una sumatoria ponderada de exponenciales de la forma $(1 - \mu \lambda_k)^n$. τ_k anterior es la cantidad de muestras requerida por cada término para que $w_i(n)$ alcance 1/e de su valor inicial.

Método Steepest Descent ...

Comportamiento transitorio ...

- La *constante de tiempo total*, τ_a , definida como el tiempo requerido por el término de sumatoria del transitorio de coeficientes anterior para decaer $1/e$ de su valor inicial, no puede expresarse en forma cerrada.
- Independientemente de eso, la *menor velocidad de convergencia* se logra cuando $q_{ki}\nu_k(0) = 0$ para todo k excepto para el modo correspondiente al menor autovalor λ_{min} de R , tal que el límite superior de τ_a , está definido por $-1/\ln(1 - \mu\lambda_{min})$.
- La *mayor velocidad de convergencia* se logra cuando todos los $q_{ki}\nu_k(0) = 0$ excepto para el modo correspondiente al mayor autovalor λ_{max} , tal que la cota inferior sobre τ_a está definida para $-1/\ln(1 - \mu\lambda_{max})$.
- En consecuencia, la constante de tiempo total para cualquier coeficiente del algoritmo SD está acotada como sigue:

$$\frac{-1}{\ln(1 - \mu\lambda_{max})} \leq \tau_a \leq \frac{-1}{\ln(1 - \mu\lambda_{min})}$$

Método de Steepest Descent ...

Comportamiento del MSE en el transitorio

- Es posible obtener mayores detalles del SD examinando el comportamiento transitorio del MSE $J(n)$. Ya vimos que

$$J(n) = J_{min} + \sum_{k=1}^M \lambda_k |\nu_k(n)|^2$$

donde J_{min} es el MSE mínimo (MMSE).

- El comportamiento transitorio del k -ésimo modo natural, $\nu_k(n)$ está definido por la ecuación en coordenadas principales, de forma que sustituida en la anterior se tiene que

$$J(n) = J_{min} + \sum_{k=1}^M \lambda_k (1 - \mu \lambda_k)^{2n} |\nu_k(0)|^2$$

Método de Steepest Descent ...

Comportamiento del MSE en el transitorio ...

- Cuando el algoritmo SD converge (o sea, μ satisface las cotas de la condición de convergencia), es posible observar que, independientemente de las condiciones iniciales

$$\lim_{n \rightarrow \infty} J(n) = J_{min}$$

- La curva obtenida graficando el MSE $J(n)$ versus el número de iteraciones n se denomina *curva de aprendizaje*.
- De la expresión del transitorio del MSE anterior vemos que *la curva de aprendizaje del algoritmo SD consiste en la suma de exponenciales, cada una de las cuales corresponde a un modo natural del algoritmo*.

Método de Steepest Descent ...

Comportamiento del MSE en el transitorio ...

- En general el número de modos iguala al número de coeficientes. Para llegar del valor inicial $J(0)$ al valor final J_{min} , la disminución exponencial del k -ésimo modo tiene una constante de tiempo igual a

$$\tau_{\kappa, mse} \cong \frac{-1}{2 \ln(1 - \mu \lambda_k)}$$


que para pequeños valores de μ puede aproximarse por

$$\tau_{\kappa, mse} \cong \frac{1}{2\mu\lambda_k}$$

y que muestra que cuanto menor es el factor de convergencia μ , menor será la velocidad de disminución de cada modo natural del algoritmo SD.

Método de Steepest Descent ...

Ejemplo: predictor de 2do. orden



- Se estudiará en este ejemplo el comportamiento transitorio del algoritmo SD aplicado a un predictor que opera sobre un proceso autoregresivo (AR) real. La figura muestra la estructura del predictor, formado por dos coeficientes $w_1(n)$ y $w_2(n)$;
- La dependencia de esos coeficientes del número de iteraciones n enfatiza las condiciones del transitorio del predictor.

Método de Steepest Descent ...

Ejemplo: predictor de 2do. orden

- El proceso AR, $u(n)$ se describe por

$$u(n) + a_1 u(n-1) + a_2 u(n-2) = \nu(n)$$

donde $\nu(n)$ es un proceso de ruido blanco de media cero y varianza σ_ν^2 .

- Los parámetros AR se eligen tal que las raíces de la ecuación característica

$$1 + a_1 z^{-1} + a_2 z^{-2} = 0$$

sean complejas, o sea $a_1^2 < 4a_2$. Los valores particulares de a_1 y a_2 están determinados por la dispersión de los autovalores $\chi(\mathbf{R})$ deseada.

- Para valores de a_1 y a_2 especificados, la varianza σ_ν^2 del proceso de ruido blanco se elige de forma que $u(n)$ tenga varianza $\sigma_u^2 = 1$.

Método de Steepest Descent ...

Ejemplo: predictor de 2do. orden

La idea es evaluar el comportamiento transitorio del algoritmo SD para las siguientes condiciones:

- Variación de la dispersión de los autovalores $\chi(\mathbf{R})$ manteniendo fijo el factor de convergencia μ .
- Variación del factor de convergencia μ , manteniendo fija la dispersión de autovalores $\chi(\mathbf{R})$.

Método de Steepest Descent ...

Ejemplo: Caracterización del proceso AR

- Como el predictor tiene dos coeficientes y el proceso AR es real, la matriz correlación $\mathbf{R}$ (2 x 2) es simétrica

$$\mathbf{R} = \begin{bmatrix} r(0) & r(1) \\ r(1) & r(0) \end{bmatrix}$$

donde $r(0) = \sigma_u^2$, $r(1) = -\frac{a_1}{1+a_2}\sigma_u^2$, $\sigma_u^2 = \left(\frac{1+a_2}{1-a_2}\right) \frac{\sigma_v^2}{(1+a_2)^2 - a_1^2}$.

- Las autovalores de $\mathbf{R}$ serán

$$\lambda_1 = \left(1 - \frac{a_1}{1+a_2}\right) \sigma_u^2 \quad \lambda_2 = \left(1 + \frac{a_1}{1+a_2}\right) \sigma_u^2$$

de donde, suponiendo a_1 negativo, la dispersión de autovalores es

$$\chi(\mathbf{R}) = \frac{\lambda_1}{\lambda_2} = \frac{1 - a_1 + a_2}{1 + a_1 + a_2}$$

Método de Steepest Descent ...

Ejemplo: Caracterización del proceso AR

- Los autovectores q_1 y q_2 asociados con λ_1 y λ_2 son

$$q_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad q_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

- Se utilizarán los siguientes valores de parámetros del modelo AR de segundo orden

Caso	Parámetros AR		Autovalores		Dispersión	MSE mínimo
	a_1	a_2	λ_1	λ_2	$\chi = \lambda_1/\lambda_2$	$J_{min} = \sigma_v^2$
1	-0.1950	0.95	1.1	0.9	1.22	0.0965
2	-0.9750	0.95	1.5	0.5	3	0.0731
3	-1.5955	0.95	1.818	0.182	10	0.0322
4	-1.9114	0.95	1.957	0.0198	100	0.0038

Método de Steepest Descent ...

Experimento 1: Variación de la dispersión de autovalores

- En este experimento se fijó $\mu = 0.3$, y se realizaron evaluaciones para los cuatro conjuntos de parámetros AR de la tabla anterior.
- Para cada conjunto de parámetros se obtiene un gráfico bidimensional de los coeficientes transformados $\nu_1(n)$ y $\nu_2(n)$ para mostrar el comportamiento transitorio del algoritmo SD.
- En particular, en las coordenadas principales se obtiene

$$\boldsymbol{\nu}(n) = \begin{bmatrix} \nu_1(n) \\ \nu_2(n) \end{bmatrix} = \begin{bmatrix} (1 - \mu\lambda_1)^n \nu_1(0) \\ (1 - \mu\lambda_2)^n \nu_2(0) \end{bmatrix}, \quad n = 1, 2, \dots$$

Método de Steepest Descent ...

Experimento 1: Variación de la dispersión de autovalores ...

- Para calcular el valor inicial se utiliza $\nu(0) = -Q^H w_o$ suponiendo el valor inicial $w(0) = 0$, que requiere el conocimiento de w_o . Entonces, con el proceso de segundo orden AR como entrada del predictor se tiene que

$$w_o = \begin{bmatrix} -a_1 \\ -a_2 \end{bmatrix}$$

$$\text{y } J_{min} = \sigma_\nu^2.$$

- Teniendo en cuenta también $\nu(0) = -Q^H w_o$, se tiene que

$$\nu(0) = \begin{bmatrix} \nu_1(0) \\ \nu_2(0) \end{bmatrix} = \frac{-1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} -a_1 \\ -a_2 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} a_1 + a_2 \\ a_1 - a_2 \end{bmatrix}$$

Método de Steepest Descent ...

Experimento 1: Variación de la dispersión de autovalores ...

- De esta forma, obtenido el valor inicial $\nu(0)$, se puede usar la ecuación del transitorio para calcular $\nu(1), \nu(2), \dots$. Asociando estos valores se obtiene una *trayectoria* del comportamiento transitorio del algoritmo SD.
- Resulta muy informativo incluir en los gráficos el lugar de $\nu_1(n)$ y $\nu_2(n)$ con el MSE en coordenadas principales para valores fijos de n . Para el ejemplo, se tiene que

$$J(n) - J_{min} = \lambda_1 \nu_1^2(n) + \lambda_2 \nu_2^2(n)$$

- Cuando $\lambda_1 = \lambda_2$ y n es fijo, esto representa un *círculo* con centro en el origen y radio igual a la raíz cuadrada de $[J(n) - J_{min}]/\lambda$.
- Cuando $\lambda_1 \leq \lambda_2$, la anterior representa una *elipse* con eje mayor igual a la raíz cuadrada de $[J(n) - J_{min}]/\lambda_2$ y el eje menor igual a la raíz cuadrada de $[J(n) - J_{min}]/\lambda_1$.



Método de Steepest Descent ...

Experimento 1: Variación de la dispersión de autovalores ...

Autovalores similares (coordenadas principales)

Lugar geométrico de $\nu_1(n)$ y $\nu_2(n)$ para el algoritmo SD con factor de convergencia $\mu = 0.3$ y dispersión de autovalores variable:

- a) Caso 1: $\chi(\mathbf{R}) = 1.22$.
 $\chi(\mathbf{R}) = 1.22$.
b) Caso 2: $\chi(\mathbf{R}) = 3.0$.



Método de Steepest Descent ...


Experimento 1: Variación de la dispersión de autovalores ...

Autovalores similares (coordenadas naturales)

Lugar geométrico de $w_1(n)$ y $w_2(n)$ para el algoritmo SD con factor de convergencia $\mu = 0.3$ y dispersión de autovalores variable:

a) Caso 1: $\chi(\mathbf{R}) = 1.22$.

b) Caso 2: $\chi(\mathbf{R}) = 1.22$.



Método de Steepest Descent ...



Experimento 1: Variación de la dispersión de autovalores ...

Autovalores diferentes (coordenadas principales)

Lugar geométrico de $\nu_1(n)$ y $\nu_2(n)$ para el algoritmo SD con factor de convergencia $\mu = 0.3$ y dispersión de autovalores variable:

c) Caso 3: $\chi(\mathbf{R}) = 10$,

d) Caso 4: $\chi(\mathbf{R}) = 100$.



Método de Steepest Descent ...


Experimento 1: Variación de la dispersión de autovalores ...

Autovalores diferentes (coordenadas naturales)


Lugar geométrico de $w_1(n)$ y $w_2(n)$ para el algoritmo SD con factor de convergencia $\mu = 0.3$ y dispersión de autovalores variable:

c) Caso 3: $\chi(\mathbf{R}) = 10$,

d) Caso 4: $\chi(\mathbf{R}) = 100$.




(c)



(d)

Método de Steepest Descent ...

Experimento 1: Variación de la dispersión de autovalores ...



Curvas de aprendizaje del MSE para las diferentes dispersiones de autovalores 1.22, 3, 10 y 100 (cuando la dispersión de autovalores aumenta, y la entrada se vuelve mal correlacionada, el MMSE disminuye).

Método de Steepest Descent ...

Experimento 2: Variación del factor de convergencia

- En este experimento se fija $\chi(\mathbf{R}) = 10$ y se varía el factor de convergencia μ . En particular, examinaremos el comportamiento transitorio del algoritmo SD para $\mu = 0.3$ y $\mu = 1.0$.
- Notar también que el valor crítico $\mu_{max} = 2/\lambda_{max} = 1.1$, es que es un poco mayor que el usado en la figura.


Método de Steepest Descent ...

Experimento 1: Variación de la dispersión de autovalores ...

Coordenadas principales

Lugar geométrico de $\nu_1(n)$ y $\nu_2(n)$ para el algoritmo SD con factor de convergencia variable (dispersión de autovalores $\chi(\mathbf{R}) = 10$):

- a) sobreamortiguado $\mu = 0.3$,
- b) subamortiguado, $\mu = 1.0$.




Método de Steepest Descent ...

Experimento 2: Variación del factor de convergencia

Coordenadas naturales

Lugar geométrico de $w_1(n)$ y $w_2(n)$ para el algoritmo SD con factor de convergencia variable (dispersión de autovalores $\chi(R) = 10$):

- a) Sobreamortiguado, $\mu = 0.3$,
- b) subamortiguado, $\mu = 1.0$.



Método de Steepest Descent ...

Observaciones

Con base en los resultados de los experimentos 1 y 2 es posible realizar las siguientes observaciones:

1. La trayectoria $[\nu_1(n), \nu_2(n)]$ con n como parámetro es normal al lugar geométrico de $[\nu_1(n), \nu_2(n)]$ para $J(n)$ fijo.
2. Cuando los autovalores son iguales, la trayectoria $[\nu_1(n), \nu_2(n)]$ con n como parámetro, es una línea recta.
3. Cuando las condiciones son adecuadas para que el valor inicial de $\nu(0)$ esté sobre el eje ν_1 ó el eje ν_2 , la trayectoria $[\nu_1(n), \nu_2(n)]$, con n como parámetro, la trayectoria es una línea recta.

Método de Steepest Descent ...

Observaciones ...

4. Excepto por dos casos especiales ((2) autovalores iguales y (3) condiciones iniciales adecuadas), la trayectoria $[\nu_1(n), \nu_2(n)]$, con n como parámetro, la trayectoria sigue un camino curvo.
5. Cuando la dispersión de autovalores es muy alta, pueden suceder dos cosas:
 - La superficie de error toma la forma de un valle pronunciado.
 - Las trayectorias de $[\nu_1(n), \nu_2(n)]$ y $[w_1(n), w_2(n)]$ desarrollan curvaturas diferentes.

Método de Steepest Descent ...

Observaciones ...

6. El algoritmo SD converge más rápido cuando los autovalores λ_1 y λ_2 son iguales o cuando la condición inicial es adecuada, en cuyos casos la trayectoria formada siguiendo los valores $\nu(0), \nu(1), \nu(2), \dots$ es una línea recta, el camino más corto.
7. Para un factor de convergencia μ , si la dispersión de los autovalores $\chi(\mathbf{R})$ aumenta ($\mathbf{R}$ es peor condicionada) el lugar geométrico de $[\nu_1(n), \nu_2(n)]$ para valores fijos de $J(n)$ se vuelve cada vez más angosto y abrupto (o sea, el eje menor se vuelve más pequeño).

Método de Steepest Descent ...

Observaciones ...

8. Cuando el factor de convergencia μ es pequeño, el comportamiento transitorio del algoritmo SD es *sobreamortiguado*, en el sentido que la trayectoria formada siguiendo $\nu(0), \nu(1), \nu(2), \dots$ sigue un camino continuo.
9. Cuando, por otro lado, $\mu = 2/\lambda_{max}$, toma el máximo valor permitido, el comportamiento transitorio del algoritmo SD es *subamortiguado*, en el sentido que la trayectoria exhibe oscilaciones.

Menor Cuadrado Mínimo (LMS)

Método de Steepest Descent

- Algoritmo Steepest Descent
- Estabilidad del algoritmo

Algoritmo LMS

- Ajuste de los coeficientes
- Estabilidad y desempeño del algoritmo LMS
- El algoritmo LMS normalizado

Filtrado adaptativo en el dominio frecuencia

- Filtrado adaptativo en bloques
- Algoritmo adaptativo con preprocesamiento
- Clasificación de algoritmos