

# Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

# Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

# Menor Cuadrado Mínimo (LMS)

## Método de Steepest Descent

- Algoritmo Steepest Descent
- Estabilidad del algoritmo

## Algoritmo LMS

- Ajuste de los coeficientes
- Estabilidad y desempeño del algoritmo LMS
- El algoritmo LMS normalizado

## Filtrado adaptativo en el dominio frecuencia

- Filtrado adaptativo en bloques
- Algoritmo adaptativo con preprocesamiento
- Clasificación de algoritmos

## Filtrado adaptativo en el dominio frecuencia

- Teniendo en cuenta que la *Transformada de Fourier* puede mapear eficientemente señales en el dominio tiempo al dominio frecuencia, es razonable llevar a cabo la adaptación en ese dominio.
- En ese caso discutiremos *algoritmos de filtrado adaptativo en el dominio frecuencia* (FDAF).
- Algunas de las razones principales para utilizar este tipo de técnicas en el dominio frecuencia residen en los *algoritmos eficientes disponibles* para realizar el mapeo (implementación de convolución rápida) y las *propiedades de ortogonalización* asociadas a la transformación que permiten mayor velocidad de convergencia.

## Filtrado adaptativo en el dominio frecuencia

- Teniendo en cuenta algoritmos eficientes es posible considerar dos tipos de algoritmos FDAF:
  - a) *Implementación en bloques* de un filtro FIR, lo cual permite el uso eficiente de procesamiento en paralelo y en consecuencia resulta en mejoras de la velocidad computacional.
  - b) A partir de la *Transformada rápida de Fourier* (FFT), efectuando convolución rápida lo cual permite realizar la adaptación de los coeficientes del filtro en el dominio frecuencia en una forma sumamente eficiente.
- En relación a las propiedades de ortogonalización, es posible considerar algoritmos subóptimos, que en el caso ideal permiten tanto aumentar considerablemente la velocidad de convergencia como mejorar el condicionamiento numérico del algoritmo LMS.

## Filtrado adaptativo en el dominio frecuencia ...


### Filtrado adaptativo en bloques

- En un *filtro adaptativo en bloques*,  $u(n)$  se divide en bloques de  $L$  puntos por medio de un conversor serie-paralelo, y el bloque de datos de entrada así generado se aplica a un filtro FIR de longitud  $M$  de a un bloque por vez.
- Los *coeficientes del filtro se mantienen fijos para cada bloque de datos*, de forma que la adaptación del filtro se realiza de bloque en bloque antes que de muestra en muestra como en el algoritmo LMS estándar. El índice  $k$  indicará entonces cada bloque y  $\hat{\mathbf{w}}(k)$  el vector de coeficientes del filtro para el  $k$ -ésimo bloque, tal que

$$\hat{\mathbf{w}}(k) = [\hat{w}_0(k), \hat{w}_1(k), \dots, \hat{w}_{M-1}(k)]^T, \quad k = 0, 1, \dots$$

## Filtrado adaptativo en el dominio frecuencia ...

### Filtrado adaptativo en bloques



Filtro adaptativo en bloques

## Filtrado adaptativo en el dominio frecuencia ...

### Filtrado adaptativo en bloques ...

- El índice  $n$  se reservará para cada muestra particular, lo que escrito en términos de bloques quedaría

$$n = kL + i, \quad i = 0, 1, \dots, M - 1, \quad k = 0, 1, \dots$$

- Escribiendo el vector de entradas  $\mathbf{u}(n)$  como

$$\mathbf{u}(n) = [u(n), u(n-1), \dots, u(n-M+1)]^T$$

la salida del filtro  $y(n)$  producida en el instante  $n$  será

$$y(n) = \hat{\mathbf{w}}^T(k) \mathbf{u}(n)$$

o en forma equivalente

$$\begin{aligned} y(kL + i) &= \hat{\mathbf{w}}^T(k) \mathbf{u}(kL + i) \\ &= \sum_{l=0}^{M-1} \hat{w}_l(k) u(kL + i - l), \quad i = 0, 1, \dots, M - 1 \end{aligned}$$

## Filtrado adaptativo en el dominio frecuencia ...

## Filtrado adaptativo en bloques ...

- Es posible definir la respuesta deseada como  $d(n) = d(kL + i)$ , entonces la señal error  $e(kL + i) = d(kL + i) - y(kL + i)$ , que varía a la velocidad de las muestras como en el algoritmo LMS estándar.
- La secuencia de error  $e(n)$  se divide a su vez en bloques de  $L$  puntos en forma sincrónica con el final de la entrada al filtro adaptativo en bloques y se utiliza para el ajuste de los coeficientes del filtro.
- Para ilustrar la operación del filtro adaptativo en bloques, consideremos la longitud  $M$  y tamaño del bloque  $L$  igual a 3. La secuencia de salida calculada por el filtro en tres bloques consecutivos,  $k-1$ ,  $k$  y  $k+1$  será

$$\begin{array}{ll} \text{bloque } (k-1) & \left\{ \begin{bmatrix} u(3k-3) & u(3k-4) & u(3k-5) \\ u(3k-2) & u(3k-3) & u(3k-4) \\ u(3k-1) & u(3k-2) & u(3k-3) \end{bmatrix} \begin{bmatrix} w_0(k-1) \\ w_1(k-1) \\ w_2(k-1) \end{bmatrix} = \begin{bmatrix} y(3k-3) \\ y(3k-2) \\ y(3k-1) \end{bmatrix} \right. \\ \text{bloque } k & \left\{ \begin{bmatrix} u(3k) & u(3k-1) & u(3k-2) \\ u(3k+1) & u(3k) & u(3k-1) \\ u(3k+2) & u(3k+1) & u(3k) \end{bmatrix} \begin{bmatrix} w_0(k) \\ w_1(k) \\ w_2(k) \end{bmatrix} = \begin{bmatrix} y(3k) \\ y(3k+1) \\ y(3k+2) \end{bmatrix} \right. \\ \text{bloque } (k+1) & \left\{ \begin{bmatrix} u(3k+3) & u(3k+2) & u(3k+1) \\ u(3k+4) & u(3k+3) & u(3k+2) \\ u(3k+5) & u(3k+4) & u(3k+3) \end{bmatrix} \begin{bmatrix} w_0(k+1) \\ w_1(k+1) \\ w_2(k+1) \end{bmatrix} = \begin{bmatrix} y(3k+3) \\ y(3k+4) \\ y(3k+5) \end{bmatrix} \right. \end{array}$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques

- Del desarrollo para el algoritmo LMS de la clase anterior, la forma de adaptación aplicada al vector de coeficientes de una iteración a otra (suponiendo datos reales) es:

$$\begin{pmatrix} \text{Ajuste del} \\ \text{vector de} \\ \text{coeficientes} \end{pmatrix} = \begin{pmatrix} \text{Factor de} \\ \text{convergencia} \end{pmatrix} \begin{pmatrix} \text{Vector de} \\ \text{entradas} \end{pmatrix} (\text{señal de error})$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques ...

- Teniendo en cuenta que en el algoritmo LMS en bloques la señal error varia a la velocidad de las muestras de entrada, se concluye que cada bloque de entrada tiene diferentes valores de la señal error para usar en el proceso de adaptación.
- Entonces, para el  $k$ -ésimo bloque es posible sumar  $u(kL + i)e(kL + i)$  sobre todos los valores de  $i$  y definir así la ecuación de adaptación para los coeficientes del algoritmo LMS en bloques operando sobre datos reales como

$$\begin{aligned}\hat{\mathbf{w}}(k+1) &= \hat{\mathbf{w}}(k) + \mu \sum_{i=0}^{L-1} \mathbf{u}(kM + i)e(kM + i) \\ &= \hat{\mathbf{w}}(k) + \mu \boldsymbol{\phi}(k)\end{aligned}$$

- El  $j$ -ésimo elemento del vector  $\boldsymbol{\phi}(k)$  está definido por

$$\varphi_j(k) = \sum_{i=0}^{L-1} u(kM + i - j)e(kM + i), \quad j = 0, 1, \dots, M-1$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques ...

- Una característica distintiva del algoritmo LMS en bloques es que se incorpora una *estimación promedio del vector gradiente*, dada por

$$\hat{\nabla}(k) = -\frac{2}{L} \sum_{i=0}^{L-1} \mathbf{u}(kL+i)e(kL+i)$$

donde el factor 2 se incluye para ser consistente con el vector de gradiente utilizado en la clase anterior, y el factor  $1/L$  se incluye para que  $\hat{\nabla}(k)$  sea un promedio temporal no sesgado.

- De esta forma es posible reformular el **algoritmo LMS en bloques** como

$$\hat{\mathbf{w}}(k+1) = \hat{\mathbf{w}}(k) - \frac{1}{2}\mu_B \hat{\nabla}(k)$$

donde  $\mu_B$  puede interpretarse como el factor de convergencia *efectivo* para el algoritmo LMS en bloques:  $L\mu$ .

## Filtrado adaptativo en el dominio frecuencia ...

### Propiedades de convergencia del algoritmo en bloques

- El algoritmo LMS en bloques tiene propiedades similares al algoritmo LMS estándar, en el sentido que los dos minimizan el MSE  $J = \frac{1}{2}E[e^2(n)]$ .
- Comparando la estimación del algoritmo LMS en bloques con la del algoritmo LMS convencional, vemos que el primero utiliza una estimación más precisa del vector gradiente debido a el promedio en tiempo, tal que la precisión mejora en la medida que aumenta el tamaño del bloque.
- Sin embargo, esta mejora no implica mayor velocidad de convergencia como se podrá concluir al estudiar las propiedades de convergencia del algoritmo LMS en bloques.
- El análisis de convergencia es similar al realizado en la clase anterior para el algoritmo LMS convencional. Existe solo una pequeña modificación a ser considerada, o sea, la sumatoria de ciertas esperanzas sobre el índice  $i=0, 1, \dots, L-1$ , el cual está relacionado con la muestra de tiempo  $n$  por  $n=kL+i$ .

Filtrado adaptativo en el dominio frecuencia ...

Propiedades de convergencia del algoritmo en bloques ...

- Una síntesis de esas propiedades es la siguiente

1. *Condición de convergencia:*

$$\lim_{k \rightarrow \infty} E[\hat{\mathbf{w}}(k)] = \mathbf{R}^{-1} \mathbf{p} = \mathbf{w}_o$$

La condición que debe satisfacer el factor de convergencia  $\mu$  para que el algoritmo LMS en bloques converja en media es

$$0 < \mu < 2/(L\lambda_{max}),$$

donde  $L$  es el tamaño del bloque y  $\lambda_{max}$  es el mayor autovalor de  $\mathbf{R}$ .

Filtrado adaptativo en el dominio frecuencia ...

Propiedades de convergencia del algoritmo en bloques ...

2. *Desajuste*: En base a las definiciones de exceso de MSE y el MMSE de la clase anterior, es posible notar que para que  $J_{ex}(k)$  para el algoritmo LMS en bloques converja a una constante  $J_{ex}(\infty) < J_{min}$  cuando  $k \rightarrow \infty$ , el factor de convergencia debe satisfacer la condición más restrictiva

$$0 < \mu < \frac{2}{L \sum_{i=1}^M \lambda_i}$$

tal que el desajuste correspondiente es

$$\mathcal{M} = \frac{\mu}{2} \sum_{i=1}^M \lambda_i$$

## Filtrado adaptativo en el dominio frecuencia ...

### Propiedades de convergencia del algoritmo en bloques ...

Comparando los resultados descriptos del algoritmo LMS en bloques con los correspondientes al algoritmo LMS estándar es posible observar que:

- El valor de convergencia en media del vector de coeficientes y el desajuste del algoritmo LMS en bloques son idénticos a los del algoritmo LMS estándar.
- La condición de convergencia en media del algoritmo LMS en bloques es más restrictiva que la correspondiente del algoritmo LMS estándar. En particular, la cota más estrecha sobre el factor de convergencia  $\mu$  puede causar que este algoritmo converja más lentamente que el estándar, en especial cuando la dispersión de autovalores de  $\mathbf{R}$  es grande.

## Filtrado adaptativo en el dominio frecuencia ...

### Elección del tamaño del bloque

Un aspecto importante que necesita ser considerado en el diseño de un filtro adaptativo en bloques es como elegir el tamaño del bloque. De la ecuación de adaptación se observa que la operación del algoritmo LMS en bloques está bien definida siempre que  $L$  sea un entero mayor que la unidad. Independientemente de esto, lo usual es elegir  $L=M$ , la longitud del filtro.

Justificaciones para esta elección son las siguientes:

- Cuando  $L > M$ , se realizan operaciones redundantes en el proceso debido a que la estimación del vector gradiente (calculado sobre  $L$  puntos) utiliza más información que el filtro mismo.
- Cuando  $L < M$ , algunos de los coeficientes del filtro no son utilizados debido a que la secuencia de entrada no es suficientemente larga para alimentar el filtro completo.

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques eficiente

- Un aspecto clave para utilizar en una aplicación el algoritmo LMS en bloques es como implementarlo en forma eficiente. La complejidad computacional del algoritmo LMS en bloques está relacionada con:
  1. La ecuación de adaptación de los coeficientes, que define una *convolución lineal* de la secuencia de entrada y los coeficientes del filtro.
  2. La ecuación de componentes de  $\phi(k)$ , que define una *correlación lineal* entre la secuencia de entrada y el error.
- La FFT es muy eficiente para efectuar *convolución rápida* y *correlación rápida*. Esto apunta a un método en el dominio frecuencia, usando FFT, para implementación del algoritmo LMS en bloques.
- La convolución rápida puede efectuarse eficientemente con el método *overlap-save (OS)* (o, alternativamente, *overlap-add*, pero es menos eficiente cuando el filtro adaptativo es largo). Experimentalmente, la mayor eficiencia computacional obtenida con OS se logra para un solapamiento del 50 %.

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques eficiente ...

- De acuerdo a OS de 50%, los  $M$  coeficientes del filtro se rellenan con igual número de ceros y se utiliza una FFT de  $N=2M$ . Si  $\hat{\mathbf{W}}(k)$  ( $N \times 1$ ) es el vector de coeficientes de la FFT de  $\hat{\mathbf{w}}(k)$  relleno, entonces

$$\hat{\mathbf{W}}(k) = FFT \begin{bmatrix} \hat{\mathbf{w}}(k) \\ \mathbf{0} \end{bmatrix}$$

- Si  $\mathbf{U}(k)$  es la matriz diagonal de ( $N \times N$ ) obtenida de la entrada como:

$$\mathbf{U}(k) = diag\{\underbrace{FFT[u(kM-M), \dots, u(kM-1)]}_{\text{bloque } (k-1)\text{-simo}}, \underbrace{u(kM), \dots, u(kM+M-1)}_{\text{bloque } k\text{-simo}}\}$$

- Entonces, aplicando el método OS a la convolución lineal de la ecuación de adaptación, se obtiene

$$\begin{aligned} \mathbf{y}^T(k) &= [y(kM), y(kM+1), \dots, y(kM+M-1)] \\ &= \text{últimos } M \text{ elementos de la } IFFT[\mathbf{U}(k)\hat{\mathbf{W}}(k)] \end{aligned}$$

donde se usan solo los últimos  $M$  elementos de la ecuación anterior porque los primeros  $M$  sufren efectos de la convolución circular.

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques eficiente ...

- Considerando luego la correlación lineal asociada a  $\phi(k)$ , para el  $k$ -ésimo bloque definimos el vector de respuesta deseada

$$\mathbf{d}(k) = [d(kM), d(kM + 1), \dots, d(kM + M - 1)]^T$$

y el vector de error correspondiente

$$\begin{aligned} \mathbf{e}(k) &= [e(kM), e(kM + 1), \dots, e(kM + M - 1)]^T \\ &= \mathbf{d}(k) - \mathbf{y}(k) \end{aligned}$$

- Como en la implementación OS de la convolución lineal anterior se descartan los primeros  $M$  elementos de la salida, es posible transformar  $\mathbf{e}(k)$  al dominio frecuencia como sigue

$$\mathbf{E}(k) = FFT \begin{bmatrix} \mathbf{0} \\ \mathbf{e}(k) \end{bmatrix}$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS en bloques eficiente ...

- Luego, teniendo en cuenta que una correlación lineal es básicamente una forma (*revertida*) de convolución lineal, aplicando OS a la correlación lineal de  $\phi(k)$ , se obtiene


$$\phi(k) = \text{primeros } M \text{ elementos de la } IFFT[U(k)E(k)]$$

- Notar también que mientras en el caso de convolución lineal se descartan los primeros  $M$  elementos, en correlación se descartan los  $M$  últimos.
- Finalmente, es posible transformar al dominio frecuencia la ecuación de adaptación de los coeficientes como

$$\hat{\mathbf{W}}(k+1) = \hat{\mathbf{W}}(k) + \mu FFT \begin{bmatrix} \phi(k) \\ \mathbf{0} \end{bmatrix}$$

# Filtrado adaptativo en el dominio frecuencia ... Algoritmo LMS en bloques eficiente ...

- Este algoritmo es la representación precisa del algoritmo LMS en bloques en el dominio frecuencia, usando OS.
- Como tal, las propiedades de convergencia son idénticas a las discutidas para ese algoritmo.



## Filtrado adaptativo en el dominio frecuencia ...

### Complejidad computacional

- La complejidad del algoritmo LMS en bloques eficiente se comparará con el algoritmo LMS estándar. La comparación se basa en el **número total de multiplicaciones** involucradas en cada una de esas implementaciones para un tamaño de bloque  $M$ .
- Consideramos primero el algoritmo LMS estándar con  $M$  coeficientes operando sobre datos reales:  $M$  multiplicaciones para la salida y otras  $M$  para los coeficientes, o sea  $2M$  multiplicaciones por iteración. Para un bloque de  $M$  muestras de salida, el número total de multiplicaciones es  $2M^2$ .

## Filtrado adaptativo en el dominio frecuencia ...

### Complejidad computacional

- Considerando el algoritmo LMS en bloques, cada FFT de  $N$  puntos (y IFFT) requiere  $N \log_2 N$  multiplicaciones reales, donde  $N=2M$ . Existen 5 FFT. El vector de salida en el dominio frecuencia requiere  $4N$  multiplicaciones, lo mismo que las correlaciones cruzadas asociadas a  $\phi(k)$ .

$$\begin{aligned} 5N \log_2 N + 8N &= 10M \log_2(2M) + 16M \\ &= 10M \log_2 M + 26M \end{aligned}$$

- La relación de complejidad entre los algoritmos será

$$\begin{aligned} \text{Relación de complejidad} &= \frac{10M \log_2 M + 26M}{2M^2} \\ &= \frac{5 \log_2 M + 13}{M} \end{aligned}$$

Por ejemplo, para  $M=1024$ , el algoritmo en bloques es 16 veces más eficiente que el algoritmo estándar en términos computacionales.

## Filtrado adaptativo en el dominio frecuencia ...

### Mejora en la velocidad de convergencia

Es posible mejorar la velocidad de convergencia de este algoritmo en base a las siguientes observaciones:

- Los *coeficientes se adaptan independientemente*, lo cual significa que cada uno se asocia con un modo del proceso de adaptación. Dado que los modos son fácilmente accesibles, las velocidades de convergencia individuales pueden variarse directamente. Así, mientras en el algoritmo LMS estándar cada coeficiente es responsable por una mezcla de modos, *en el algoritmo eficiente es responsable por un único modo y su velocidad de convergencia entonces puede optimizarse.*
- Suponiendo entradas ESA, el tiempo de convergencia para el  $i$ -ésimo modo es inversamente proporcional a  $\mu\lambda_i$ , donde  $\lambda_i$  es el  $i$ -ésimo autovalor de  $\mathbf{R}$  y *también es una medida de la potencia promedio de entrada al  $i$ -ésimo bin de frecuencia.*

## Filtrado adaptativo en el dominio frecuencia ...

### Mejora en la velocidad de convergencia ...

- De acuerdo a esto, es posible hacer que los modos del proceso de adaptación converjan esencialmente a la misma velocidad asignando a cada coeficiente un factor de convergencia:

$$\mu_i = \frac{\alpha}{P_i} \quad i = 0, 1, \dots, M - 1$$

donde  $\alpha$  es una constante y  $P_i$  es una estimación de la potencia promedio en el  $i$ -ésimo bin.

- Bajo esta condición, los coeficientes convergen con la misma constante de tiempo, definida por

$$\tau = 2M/\alpha$$

## Filtrado adaptativo en el dominio frecuencia ...

### Mejora en la velocidad de convergencia ...

- Cuando el ambiente no es estacionario, es posible utilizar la siguiente recursión para obtener una estimación de la potencia promedio

$$P_i(k) = \gamma P_i(k-1) + (1-\gamma)|U_i(k)|^2, \quad i = 0, 1, \dots, 2M-1$$

donde  $U_i(k)$  es la entrada al  $i$ -ésimo coeficiente del algoritmo LMS en bloques eficiente en el instante  $k$  y  $0 < \gamma < 1$  es una constante que determina la memoria del proceso de estimación anterior.

- De esta forma, dada la estimación  $P_i(k)$  en el  $i$ -ésimo bin, el factor de convergencia se reemplaza por una matriz diagonal de  $(M \times M)$ , dada por

$$\boldsymbol{\mu}(k) = \alpha \mathbf{D}(k)$$

donde

$$\mathbf{D}(k) = \text{diag}[P_0^{-1}(k), P_1^{-1}(k), \dots, P_{M-1}^{-1}(k)].$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo completo

Inicialización

$$\hat{\mathbf{W}}(0) = \mathbf{0} \quad (2M \times 1)$$

$$P_i(0) = \delta_i, \quad i = 0, \dots, 2M - 1$$

Para cada bloque nuevo de  $k$  muestras, calcular

$$\mathbf{U}(k) = \text{diag}\{FFT[u(kM - M), \dots, u(kM - 1), u(kM), \dots, u(kM + M - 1)]^T\}$$

$$\mathbf{y}(k) = \text{últimos } M \text{ elementos de la } IFFT[\mathbf{U}(k)\hat{\mathbf{W}}(k)]$$

$$\mathbf{e}(k) = \mathbf{d}(k) - \mathbf{y}(k)$$

$$\mathbf{E}(k) = FFT \begin{bmatrix} \mathbf{0} \\ \mathbf{e}(k) \end{bmatrix}$$

$$P_i(k) = \gamma P_i(k - 1) + (1 - \gamma)|U_i(k)|^2, \quad i = 0, 1, \dots, 2M - 1$$

$$\mathbf{D}(k) = \text{diag}[P_0^{-1}(k), P_1^{-1}(k), \dots, P_{2M-1}^{-1}(k)]$$

$$\phi(k) = \text{primeros } M \text{ elementos de la } IFFT[\mathbf{D}(k)\mathbf{U}(k)\mathbf{E}(k)]$$

$$\hat{\mathbf{W}}(k + 1) = \hat{\mathbf{W}}(k) + \alpha FFT \begin{bmatrix} \phi(k) \\ \mathbf{0} \end{bmatrix}$$

FDAF en base al algoritmo LMS en bloques

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo adaptativo con preprocesamiento

- Las técnicas de FADF mejoran la eficiencia computacional del algoritmo LMS cuando la aplicación de interés requiere una memoria muy grande.
- Por otro lado, *mejorar la velocidad de convergencia* del algoritmo LMS requiere en general un incremento en la complejidad.
- Consideremos un vector de entrada  $\mathbf{u}(n)$  caracterizado por la matriz correlación  $\mathbf{R}$ . El *algoritmo de filtrado adaptativo ortogonalizador* (FAO), para un ambiente ESA, se describe por

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \alpha \mathbf{R}^{-1} \mathbf{u}(n) e(n)$$

donde la constante  $\alpha$  ( $0 < \alpha < 1$ ) puede elegirse  $\alpha = \frac{1}{2M}$ , donde  $M$  es la longitud del filtro.

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo adaptativo con preprocesamiento ...

- Una propiedad importante del algoritmo de FAO es que en teoría puede garantizar una *velocidad de convergencia constante independientemente de la estadística de la entrada*.
- Para probar esta propiedad definimos el vector de error de los coeficientes del filtro  $\epsilon(n) = \hat{w}(n) - w_o$ , donde  $w_o$  es la solución de Wiener. Entonces, es posible escribir el algoritmo anterior como

$$\epsilon(n+1) = (\mathbf{I} - \alpha \mathbf{R}^{-1} \mathbf{u}(n) \mathbf{u}^T(n)) \epsilon(n) + \alpha \mathbf{R}^{-1} \mathbf{u}(n) e_o(n)$$

donde  $e_o(n)$  es el valor óptimo del error producida por la solución de Wiener.

- Usando la media e invocando la suposición de independencia (o sea,  $\hat{w}(n)$  es independiente de  $\mathbf{u}(n)$ ), se obtiene

$$E[\epsilon(n+1)] = (\mathbf{I} - \alpha \mathbf{R}^{-1} E[\mathbf{u}(n) \mathbf{u}^T(n)]) E[\epsilon(n)] + \alpha \mathbf{R}^{-1} \mathbf{u}(n) e_o(n)$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo adaptativo con preprocesamiento ...

- Luego es posible concluir que: por definición  $E[\mathbf{u}(n)\mathbf{u}^T(n)] = \mathbf{R}$ ; y por el principio de ortogonalidad  $E[\mathbf{u}(n)e_o(n)] = \mathbf{0}$ .

- En consecuencia, la anterior se puede simplificar como

$$E[\boldsymbol{\epsilon}(n+1)] = (\mathbf{I} - \alpha \mathbf{R}^{-1} \mathbf{R}) E[\boldsymbol{\epsilon}(n)] = (1 - \alpha) E[\boldsymbol{\epsilon}(n)]$$

que representa una ecuación a diferencias de primer orden cuya solución es

$$E[\boldsymbol{\epsilon}(n)] = (1 - \alpha)^n E[\boldsymbol{\epsilon}(0)]$$

donde  $\boldsymbol{\epsilon}(0)$  es el valor inicial del vector de error de coeficientes.

- En consecuencia, con  $0 < \alpha < 1$ , se tiene que

$$\lim_{n \rightarrow \infty} E[\boldsymbol{\epsilon}(n)] = \mathbf{0} \qquad \lim_{n \rightarrow \infty} E[\hat{\mathbf{w}}(n)] = \mathbf{w}_o$$

Lo más importante: *la velocidad de convergencia es completamente independiente de la estadística de entrada.*

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo adaptativo con preprocesamiento ...

**Ejemplo:** Para ilustrar las propiedades de convergencia del algoritmo de FAO consideremos el caso de una entrada ruido blanco cuya matriz correlación es

$$\mathbf{R} = \sigma^2 \mathbf{I}$$

donde  $\sigma^2$  es la varianza del ruido. Para esa entrada el algoritmo de adaptación será

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \frac{1}{2M\sigma^2} \mathbf{u}(n)e(n)$$

que coincide con el algoritmo LMS estándar para  $\mu = \frac{1}{2M\sigma^2}$ .

En otras palabras, para el caso especial de una secuencia de entrada ruido blanco caracterizada por una dispersión de autovalores unitaria, el algoritmo LMS se comporta de la misma forma que el algoritmo de FAO.

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas

- Este último ejemplo sugiere que es posible mecanizar un FAO para un contexto arbitrario procediendo en dos etapas:
  1.  $u(n)$  es transformado en un vector correspondiente de variables no correlacionadas.
  2. El vector transformado puede utilizarse como la entrada a un algoritmo LMS.

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas ...

- Teóricamente, el primer objetivo puede realizarse usando la *transformada de Karhunen - Loève* (KLT).
- Específicamente, dado  $\mathbf{u}(n)$  de media cero obtenido de un contexto ESA, el vector de salida de la KLT está definido por

$$\nu_i(n) = \mathbf{q}_i^T \mathbf{u}(n), \quad i = 0, 1, \dots, M - 1$$

donde  $\mathbf{q}_i$  es el autovector asociado con el  $i$ -ésimo autovalor  $\lambda_i$  de  $\mathbf{R}$ .

- Las salidas individuales de la KLT tienen media cero y son variables no correlacionadas o sea

$$E[\nu_i(n)\nu_j(n)] = \begin{cases} \lambda_i, & j = i \\ 0, & j \neq i \end{cases}$$

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas ...

- De esta manera es posible expresar la matriz correlación de  $\mathbf{v}(n)$  como

$$\mathbf{\Lambda} = E[\boldsymbol{\nu}(n)\boldsymbol{\nu}^T(n)] = \text{diag}[\lambda_0, \lambda_1, \dots, \lambda_{M-1}]$$

cuya inversa es

$$\mathbf{\Lambda}^{-1} = \text{diag}[\lambda_0^{-1}, \lambda_1^{-1}, \dots, \lambda_{M-1}^{-1}]$$

- Consideramos ahora el algoritmo de FAO con  $\mathbf{v}(n)$  y  $\mathbf{\Lambda}^{-1}$  en lugar de  $\mathbf{u}(n)$  y  $\mathbf{R}^{-1}$ .
- Entonces

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \alpha \mathbf{\Lambda}^{-1} \mathbf{v}(n) e(n)$$


donde el  $i$ -ésimo elemento puede escribirse como

$$\hat{w}_i(n+1) = \hat{w}_i(n) + \frac{\alpha}{\lambda_i} \nu_i(n) e(n), \quad i = 0, 1, \dots, M-1$$

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable


- La KLT es una transformación **dependiente de la señal y su implementación la hacen impráctica** para aplicaciones en tiempo real.
- Afortunadamente, **la transformada discreta coseno** (DCT) provee un conjunto de vectores base predeterminado que representa una buena aproximación a la KLT (para **un proceso estacionario de Markov de primer orden**, la DCT es asintóticamente equivalente a la KLT).
- Mientras la KLT depende de la señal, la **DCT es independiente de la señal** y puede entonces implementarse en una forma computacionalmente eficiente.



## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable ...

La figura muestra el esquema que consiste en dos etapas, en la primera se implementa una *DCT desplazable* y en la segunda una versión *normalizada* del algoritmo LMS.



## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable ...

- La DCT para esta aplicación utiliza una ventana desplazable donde los cálculos se efectúan por cada nueva muestra de entrada. Entonces el LMS puede *operar a la velocidad de los datos de entrada como en la forma convencional*.
- A diferencia del algoritmo LMS en bloques eficiente, el algoritmo de filtrado adaptivo en el dominio frecuencia discutido aquí *no es un algoritmo en bloques y por lo tanto no es computacionalmente eficiente*.
- Teniendo en cuenta que la transformada discreta de Fourier (*DFT de una secuencia par resulta en la transformada discreta coseno (DCT)*), es posible desarrollar un algoritmo eficiente para calcular la DCT desplazable.

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable ...

- Consideremos una secuencia de  $M$  muestras  $u(n), u(n-1), \dots, u(n-M+1)$ . Construimos luego una secuencia extendida  $a(n)$ , simétrica alrededor del punto  $(n-M+1/2)$  como sigue

$$a(i) = \begin{cases} u(i) & i = n, n-1, \dots, n-M+1 \\ u(-i + 2n - 2M + 1), & i = n-M, n-M-1, \dots, n-2M+1 \end{cases}$$

y definimos  $W_{2m} = e^{-j(2\pi)(2M)}$ .

- El elemento  $m$ -ésimo de la DFT de  $2M$  puntos de la secuencia extendida  $a(i)$  está definida por

$$A_m(n) = \sum_{i=n-2M+1}^n a(i) W_{2M}^{m(n-i)}$$

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable ...

- Excepto por un factor de escala, la sumatoria anterior es la DCT de la secuencia  $u(n)$ . Específicamente, se tiene que

$$C_m(n) = k_m \sum_{i=n-M+1}^n u(i) \cos \left( \frac{m(i - n + M - 1/2)\pi}{M} \right)$$

donde la constante  $k_m$  está definida por

$$k_m = \begin{cases} 1/\sqrt{2}, & m = 0 \\ 1, & \text{para todo otro } m \end{cases}$$

- De esta forma, la DCT de la secuencia  $u(n)$  está relacionada con la DFT de la secuencia extendida  $a(n)$  como sigue

$$C_m(n) = \frac{1}{2} k_m (-1)^m W_{2M}^{m/2} A_m(n), \quad m = 0, 1, \dots, M-1$$

Filtrado adaptativo en el dominio frecuencia ...

Filtro adaptativo de dos etapas: DCT desplazable ...

- La DFT de la secuencia extendida  $a(n)$  puede expresarse como dos DFT complementarias como sigue

$$\begin{aligned} A_m(n) &= \sum_{i=n-M+1}^n u(i) W_{2M}^{m(n-i)} + \sum_{i=n-M+1}^n u(i) W_{2M}^{m(i-n+2M-1)} \\ &= A_m^{(1)}(n) + A_m^{(2)}(n) \end{aligned}$$


- Que en forma recursiva, se pueden escribir como

$$A_m^{(1)}(n) = W_{2M}^m A_m^{(1)}(n-1) + u(n) - (-1)^m u(n-M), \quad m = 0, 1, \dots, M-1$$

$$A_m^{(2)}(n) = W_{2M}^{-m} A_m^{(2)}(n-1) + W_{2M}^{-m} (u(n) - (-1)^m u(n-M)), \quad m = 0, 1, \dots, M-1$$

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable ...



La construcción de la figura ha sido simplificada notando que:

- Las operaciones que involucran  $u(n)$  y  $u(n-M)$  son comunes a las DCT  $A_m^{(1)}(m)$  y  $A_m^{(2)}(m)$ , por ello la terminación común de la figura.
- $z^{-M}$  en el camino directo y  $z^{-1}$  dentro de los lazos de realimentación en la figura se multiplican por un nuevo parámetro  $\beta$ .

El sistema discreto de la figura se denomina *filtro de muestreo en frecuencia*.

## Filtrado adaptativo en el dominio frecuencia ...

### Filtro adaptativo de dos etapas: DCT desplazable ...

- La función transferencia del filtro mostrado en la figura desde la entrada  $u(n)$  a la DCT de salida  $C_m(n)$ , está dada por (con  $\beta = 1$ )

$$H_m(z) = \frac{1}{2}k_m \left( e^{(-j\frac{m\pi}{2M})} \frac{(-1)^m - z^{-M}}{1 - e^{(j\frac{m\pi}{M})}z^{-1}} + e^{(j\frac{m\pi}{2M})} \frac{(-1)^m - z^{-M}}{1 - e^{(-j\frac{m\pi}{M})}z^{-1}} \right)$$

- El numerador común de esta ecuación ( $(-1)^m - z^{-M}$ ) representa un conjunto de ceros uniformemente espaciados sobre el círculo unitario del plano  $z$ , dados por

$$z_m = e^{(j\frac{m\pi}{M})}, \quad m = 0, \pm 1, \dots, \pm(M-1)$$

- Como existe un posible cancelamiento de polos y ceros en el círculo unitario, usualmente eso se controla con  $\beta$  ( $0 < \beta < 1$ ).

## Filtrado adaptativo en el dominio frecuencia ...

### DCT desplazable: Estimación de autovalores

- El único aspecto que debe aún ser considerado en el diseño del algoritmo LMS-DCT es como estimar los autovalores de la matriz correlación  $\mathbf{R}$ , que define los factores de convergencia.
- Suponiendo que el proceso estacionario asociado a la entrada es *ergódico*, es posible estimar  $\mathbf{R}$  con

$$\hat{\mathbf{R}}(n) = \frac{1}{n} \sum_{i=1}^n \mathbf{u}(i) \mathbf{u}^T(i)$$

conocida como *matriz autocorrelación muestral*. Los coeficientes de la DCT proveen una aproximación a la matriz  $\mathbf{Q}$  ( $M \times M$ ) formada por autovectores de  $\mathbf{R}$ . Si  $\hat{\mathbf{Q}}$  es esta aproximación, entonces el vector de salidas producida por la DCT

$C_0(n), C_1(n), \dots, C_{M-1}(n)$  puede expresarse como

$$\begin{aligned} \hat{\mathbf{v}}(n) &= [C_0(n), C_1(n), \dots, C_{M-1}(n)]^T \\ &= \hat{\mathbf{Q}} \mathbf{u}(n) \end{aligned}$$

## Filtrado adaptativo en el dominio frecuencia ...

### DCT desplazable: Estimación de autovalores ...

- Además, la aproximación de la DCT a una transformación ortogonal puede escribirse como

$$\begin{aligned}\hat{\Lambda}(n) &= \hat{\mathbf{Q}}\hat{\mathbf{R}}\hat{\mathbf{Q}}^T \\ &= \frac{1}{n} \sum_{i=1}^n \hat{\mathbf{Q}}\mathbf{u}(i)\mathbf{u}^T(i)\hat{\mathbf{Q}}^T = \frac{1}{n} \sum_{i=1}^n \hat{\mathbf{v}}(i)\hat{\mathbf{v}}^T(i)\end{aligned}$$

o en forma escalar

$$\hat{\lambda}_m(n) = \frac{1}{n} \sum_{i=1}^n C_m^2(i), \quad m = 0, 1, \dots, M-1$$

- Esta ecuación puede reescribirse en forma recursiva teniendo en cuenta que

$$\begin{aligned}\hat{\lambda}_m(n) &= \frac{1}{n} C_m^2(n) + \frac{1}{n} \sum_{i=1}^{n-1} C_m^2(i) \\ &= \frac{1}{n} C_m^2(n) + \frac{n-1}{n} \frac{1}{n-1} \sum_{i=1}^{n-1} C_m^2(i)\end{aligned}$$

## Filtrado adaptativo en el dominio frecuencia ...

### DCT desplazable: Estimación de autovalores ...

y como  $\hat{\lambda}_m(n-1) = \frac{1}{n-1} \sum_{i=1}^{n-1} C_m^2(i)$ , se tendrá que

$$\hat{\lambda}_m(n) = \hat{\lambda}_m(n-1) + \frac{1}{n}(C_m^2(i) - \hat{\lambda}_m(n-1))$$

- Esta ecuación se aplica al contexto de un proceso ESA. En el caso de filtrado adaptivo en un contexto no estacionario es posible usar el parámetro  $\gamma$  ( $0 < \gamma < 1$ ) lo que modifica la ecuación anterior a

$$\hat{\lambda}_m(n) = \gamma \hat{\lambda}_m(n-1) + \frac{1}{n}(C_m^2(i) - \gamma \hat{\lambda}_m(n-1)), \quad m = 0, 1, \dots, M-1$$

## Filtrado adaptativo en el dominio frecuencia ...

### Algoritmo LMS-DCT (usando 2 DFT)

---

Inicialización

Para  $m = 0, 1, \dots, M - 1$  hacer

$$A_m^{(1)}(0) = A_m^{(2)}(0) = 0$$

$$\hat{\lambda}_m(0) = 0, \hat{w}_m(0) = 0, k_m = \begin{cases} 1/\sqrt{2}, & m = 0 \\ 1, & \text{de otra forma} \end{cases}$$

Selección de parámetros

$$\alpha = \frac{1}{2M}, \beta = 0.99, 0 < \gamma < 1$$

Para  $m = 0, 1, \dots, M - 1$  y  $n = 1, 2, \dots$ , hacer

DCT desplazable

$$W_{2M} = \exp\left(-j \frac{2\pi}{2M}\right)$$

$$A_m^{(1)}(n) = \beta W_{2M}^m A_m^{(1)}(n-1) + u(n) - \beta(-1)^m u(n-M)$$

$$A_m^{(2)}(n) = \beta W_{2M}^m A_m^{(2)}(n-1) + W_{2M}^{-m}(u(n) - \beta(-1)^m u(n-M))$$

$$A_m(n) = A_m^{(1)}(n) + A_m^{(2)}(n)$$

$$C_m(n) = \frac{1}{2} k_m (-1)^m W_{2M}^{m/2} A_m(n),$$

Algoritmo LMS

$$y(n) = \sum_{m=0}^{M-1} C_m(n) \hat{w}_m(n)$$

$$e(n) = d(n) - y(n)$$

$$\hat{\lambda}_m(n) = \hat{\lambda}_m(n-1) + \frac{1}{n} (C_m^2(n) - \hat{\lambda}_m(n-1))$$

$$\hat{w}_m(n+1) = \hat{w}_m(n) + \frac{\alpha}{\hat{\lambda}_m(n)} C_m(n) e(n)$$

# Clasificación de algoritmos

En base a los algoritmos discutidos y adelantando un poco el material a ser discutido posteriormente, clasificaremos los algoritmos como mostrado en la siguiente tabla

| Clase                 | Adaptación por muestras | Adaptación por bloques |
|-----------------------|-------------------------|------------------------|
| Gradiente estocástico | LMS                     | LMS en bloques         |
| Con preprocesamiento  | LMS-DCT; GAL (*)        | SOBAF (**)             |
| Cuadrados mínimos     | RLS                     | LS en bloques          |

(\*) Gradient adaptive lattice (GAL)

(\*\*) Self-orthogonalizing block adaptive filter (SOBAF)

donde se han identificado dos clases de algoritmos de filtrado adaptativo:

- algoritmos de gradiente estocástico.
- algoritmos de cuadrados mínimos exactos.

## Clasificación de algoritmos ...

Los algoritmos de gradiente estocástico incluyen a los algoritmos con preprocesamiento como subclase. En cada caso, existen dos formas básicas de adaptar los parámetros del algoritmo:

- en base a muestras (secuencialmente).
- en base a bloques de datos.

El algoritmo LMS estándar (con adaptación en base a muestras) y el algoritmo LMS en bloques son algoritmos de tipo gradiente estocástico.

El uso de la *FFT para convolución* provee un método eficiente para implementar el algoritmo LMS en bloques. Esta es una de las formas en las cuales la DFT puede utilizarse para implementar filtrado adaptativo lineal.

## Clasificación de algoritmos ...

- Otra forma en la cual la DFT es útil es para ortogonalización, como en el algoritmo LMS-DCT. La DCT provee un método en el dominio frecuencia para aproximar un conjunto ortogonal de muestras, a través de una descomposición en autovalores. El algoritmo LMS-DCT utiliza una adaptación por muestras.
- En contraste, en el *filtro adaptivo en bloques ortogonalizador* (SOBAF), la adaptación es por bloques.

$$\hat{\mathbf{w}}(k+1) = \hat{\mathbf{w}}(k) + \frac{1}{2}\mu_B \mathbf{R}^{-1} \hat{\mathbf{\nabla}}(k), \quad \hat{\mathbf{\nabla}}(k) = -\frac{2}{L} \sum_{i=0}^{L-1} \mathbf{u}(kL+i)e(kL+i)$$

- En el algoritmo *lattice adaptivo de gradiente* (GAL), la ortogonalización de los datos de entrada se realiza en el dominio tiempo a través de la factorización de Cholesky.

## Clasificación de algoritmos ...

- Estos algoritmos aproximan una ortogonalización de los datos de entrada en diferentes formas pero son similares en el sentido de *imponer una matriz de estructura Toeplitz* (suposición ESA) sobre la estimación de  $R$ .
- Los algoritmos de filtrado adaptivo lineal asociados a la familia de Cuadrados Mínimos, ejemplificada por el algoritmo de *cuadrados mínimos recursivos* (RLS) con adaptación por muestras y el algoritmo de *cuadrados mínimos en bloques* se obtiene una ortogonalización *exacta* de los datos de entrada en el dominio tiempo.
- En otras palabras, en *RLS no se realiza ninguna aproximación en la obtención de esos algoritmos*, de donde puede concluirse la rápida velocidad de convergencia inicial y otras importantes propiedades que caracterizan a estos algoritmos.

# Menor Cuadrado Mínimo (LMS)

## Método de Steepest Descent

- Algoritmo Steepest Descent
- Estabilidad del algoritmo

## Algoritmo LMS

- Ajuste de los coeficientes
- Estabilidad y desempeño del algoritmo LMS
- El algoritmo LMS normalizado

## Filtrado adaptativo en el dominio frecuencia

- Filtrado adaptativo en bloques
- Algoritmo adaptativo con preprocesamiento
- Clasificación de algoritmos