

Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

Cuadrados Mínimos Recursivo (RLS)

Método de Cuadrados Mínimos

- Filtros lineales de cuadrados mínimos
- Cuadrados Mínimos Recursivo (RLS)
- Algoritmo RLS ponderado exponencialmente
- Análisis de convergencia

Método de cuadrados mínimos

- Se discutirá un procedimiento para resolver el problema de filtrado lineal, *dependiente del modelo*, sin invocar las suposiciones sobre la estadística de la entrada aplicada al filtro.
- El método de cuadrados mínimos puede verse como una alternativa a la teoría del filtro de Wiener. En los filtros de Wiener se obtiene (a partir de *promedios estadísticos*) un óptimo en *sentido estadístico*, para todas las realizaciones del entorno, suponiendo ESA.
- Por otro lado, el método de cuadrados mínimos es una *solución determinística*. Específicamente, involucra el uso de *promedios temporales*, con el resultado que el filtro depende del número de muestras utilizadas.

Método de cuadrados mínimos

- Se extenderá también el uso del método de cuadrados mínimos, a través de un algoritmo recursivo para el diseño de filtros adaptivos transversales. El algoritmo resultante se denomina *cuadrados mínimos recursivo* (RLS).
- El algoritmo RLS puede verse como un *caso especial del filtro de Kalman*.
- El desarrollo del algoritmo RLS se realizará analizando algunas relaciones básicas asociadas al método de cuadrados mínimos y el *lema de inversión de matrices*.
- Una característica importante del algoritmo RLS es que utiliza información que posee *memoria desde las condiciones iniciales*.

Método de cuadrados mínimos ...

Problema de cuadrados mínimos

- Consideremos un fenómeno físico caracterizado por dos conjuntos de variables, $d(i)$ y $u(i)$. Esta relación funcional, como *hipótesis*, se supone lineal.
- En particular, la respuesta $d(i)$ es modelada como

$$d(i) = \sum_{k=0}^{M-1} w_{ok}^* u(i-k) + e_o(i)$$

donde w_{ok} son los *parámetros desconocidos* del modelo, y $e_o(i)$ es el *error de medición* asociado a la naturaleza estadística del fenómeno.

Método de cuadrados mínimos ...

Problema de cuadrados mínimos


- El $e_o(i)$ es una variable aleatoria no observable que se introduce al modelo para tener en cuenta imprecisiones. Es usual suponer $e_o(i)$ blanco con media cero y varianza σ^2 . O sea,

$$E[e_o(i)] = 0, \quad \text{para todo } i \quad \text{y} \quad E[e_o(i)e_o^*(k)] = \begin{cases} \sigma^2, & i = k \\ 0, & i \neq k \end{cases}$$

lo que implica que

$$E[d(i)] = \sum_{k=0}^{M-1} w_{ok}^* u(i-k)$$

El modelado es realizado a través de un filtro transversal lineal.



Método de cuadrados mínimos ...

Problema de cuadrados mínimos

- Con el filtro lineal transversal se obtiene un error residual $e(i)$ dado por

$$e(i) = d(i) - y(i) = d(i) - \sum_{k=0}^{M-1} w_k^* u(i - k)$$

- En el método de cuadrados mínimos elegimos los coeficientes w_k para minimizar una función costo que consiste en la *suma de los errores al cuadrado*:

$$\mathcal{E}(w_0, \dots, w_{M-1}) = \sum_{i=i_1}^{i_2} |e(i)|^2$$

donde i_1 e i_2 definen los límites entre los cuales ocurre la minimización. Esta suma puede verse también como *energía del error*.

- Los valores asignados a esos límites dependen del tipo de *ventana de datos* utilizada. Se definirán 4 tipos o métodos diferentes de ventana.

Método de cuadrados mínimos ...

Ventanas de datos

1. **Método covarianza**, no hace ninguna suposición sobre los datos fuera de $[1, N]$. Definiendo los límites como $i_1 = M$ y $i_2 = N$, los datos de entrada pueden ordenarse en forma matricial

$$\begin{bmatrix} u(M) & u(M+1) & \cdots & u(N) \\ u(M-1) & u(M) & \cdots & u(N-1) \\ \vdots & \vdots & \ddots & \vdots \\ u(1) & u(2) & \cdots & u(N-M+1) \end{bmatrix}$$

2. **Método autocorrelación**, asume que los datos fuera de $[1, N]$ son cero. Así, usando $i_1 = 1$ y $i_2 = N + M - 1$, la matriz de datos de entrada toma la forma

$$\begin{bmatrix} u(1) & u(2) & \cdots & u(M) & u(M+1) & \cdots & u(N) & 0 & \cdots & 0 \\ 0 & u(1) & \cdots & u(M-1) & u(M) & \cdots & u(N-1) & u(N) & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u(1) & u(2) & \cdots & u(N-M+1) & u(N-M) & \cdots & u(N) \end{bmatrix}$$

Método de cuadrados mínimos ...

Ventanas de datos ...

3. *Método de pre-ventana*, asume que los datos previos a $i=1$ son cero, pero no hace suposiciones sobre los datos después de $i=N$. Así, usando $i_1 = 1$ y $i_2 = N$, la matriz de entradas toma la forma

$$\begin{bmatrix} u(1) & u(2) & \cdots & u(M) & u(M+1) & \cdots & u(N) \\ 0 & u(1) & \cdots & u(M-1) & u(M) & \cdots & u(N-1) \\ & & \vdots & & & & \\ 0 & 0 & \cdots & u(1) & u(2) & \cdots & u(N-M+1) \end{bmatrix}$$

4. *Método de post-ventana*, no hace suposiciones sobre los datos previos a $i_1 = 1$, pero asume que los datos posteriores a $i=N$ son cero. Así, con $i_1 = M$ y $i_2 = N + M - 1$, la matriz de entradas toma la forma

$$\begin{bmatrix} u(M) & u(M+1) & \cdots & u(N) & 0 & \cdots & 0 \\ u(M-1) & u(M) & \cdots & u(N-1) & u(N) & \cdots & 0 \\ & & & & & \vdots & \\ u(1) & u(2) & \cdots & u(N-M+1) & u(N-M) & \cdots & u(N) \end{bmatrix}$$

En adelante se usarán el método covarianza o el método de pre-ventana.

Método de cuadrados mínimos ...

Revisión principio de ortogonalidad

- Discutiremos el principio de ortogonalidad en forma similar a la que permitió obtener la base para los filtros de Wiener. El desarrollo se realizará usando el método covarianza de la matriz de datos (sin suposiciones fuera de la ventana de interés).

- La función costo para el método covarianza se define como

$$\mathcal{E}(w_0, \dots, w_{M-1}) = \sum_{i=M}^N e(i)e^*(i) = \sum_{i=M}^N |e(i)|^2$$

- Eligiendo los índices i así, es posible garantizar que todas las entradas del filtro transversal no tienen valores cero. Teniendo en cuenta que $w_k = a_k + jb_k$, $k=0, 1, \dots, M-1$, con

$$e(i) = d(i) - \sum_{k=0}^{M-1} (a_k - jb_k)u(i-k)$$

Método de cuadrados mínimos ...

Revisión principio de ortogonalidad ...

- El gradiente respecto al error $\nabla \mathcal{E}$, será

$$\begin{aligned}\nabla_k \mathcal{E} &= - \sum_{i=M}^N \left[e(i) \frac{\partial e^*(i)}{\partial a_k} + e^*(i) \frac{\partial e(i)}{\partial a_k} + j e(i) \frac{\partial e^*(i)}{\partial b_k} + j e^*(i) \frac{\partial e(i)}{\partial b_k} \right] \\ &= -2 \sum_{i=M}^N u(i-k) e^*(i) = 0, \quad k = 0, 1, \dots, M-1\end{aligned}$$

- Si $e_{min}(i)$ es el valor de $e(i)$ que minimiza $\mathcal{E}(w_0, \dots, w_{M-1})$, entonces

$$\sum_{i=M}^N u(i-k) e_{min}^*(i) = 0, \quad k = 0, 1, \dots, M-1$$

que es la descripción formal de la versión temporal del:

Principio de ortogonalidad: La secuencia $e_{min}(i)$ es ortogonal a la secuencia $u(i-k)$ aplicada al tap k de un filtro transversal de longitud M , $k=0, 1, \dots, M-1$, cuando el filtro está operando en su condición de cuadrados mínimos.

Método de cuadrados mínimos ...

Revisión principio de ortogonalidad ...

- *Corolario:* Suponiendo $\hat{w}_0, \dots, \hat{w}_{M-1}$ los coeficientes que optimizan el filtro transversal en su condición de cuadrados mínimos, la salida $y_{min}(i)$ será

$$y_{min}(i) = \sum_{k=0}^{M-1} \hat{w}_k^* u(i-k)$$

- Esta salida provee una *estimación de cuadrados mínimos* de la respuesta deseada $d(i)$. Si $\hat{d}(i|U_i)$ es la estimación de cuadrados mínimos de $d(i)$, entonces

$$\hat{d}(i|U_i) = \sum_{k=0}^{M-1} \hat{w}_k^* u(i-k) = y_{min}(i)$$

- Si ahora multiplicamos ambos lados de la ecuación de ortogonalidad por $\hat{w}_k^*$ y sumamos sobre el intervalo $[0, M-1]$, entonces

$$\sum_{i=M}^N \hat{d}(i|U_i) e_{min}^*(i) = 0$$

esta ecuación es *corolario del principio de ortogonalidad*.

Método de cuadrados mínimos ...

Suma mínima de los errores al cuadrado

- Para obtener el valor mínimo de la función costo es posible escribir

$$\underbrace{d(i)}_{\substack{\text{respuesta} \\ \text{deseada}}} = \underbrace{\hat{d}(i|U_n)}_{\substack{\text{estimación} \\ \text{de la} \\ \text{respuesta} \\ \text{deseada}}} + \underbrace{e_{min}(i)}_{\text{error de estimación}}$$

- De donde, evaluando la energía de $d(i)$ para valores de i en $[M,N]$ y usando el principio de ortogonalidad se tiene que

$$\mathcal{E}_d = \mathcal{E}_{est} + \mathcal{E}_{min} \quad \text{ó} \quad \sum_{i=M}^N |d(i)|^2 = \sum_{i=M}^N |\hat{d}(i|U_i)|^2 + \sum_{i=M}^N |e_{min}(i)|^2$$

de donde

$$\mathcal{E}_{min} = \mathcal{E}_d - \mathcal{E}_{est}$$

- Entonces, dado que $\mathcal{E}_{min}$ no es negativo, $\mathcal{E}_{est}$ *nunca puede ser mayor que $\mathcal{E}_d$.*

Método de cuadrados mínimos ...

Filtros lineales de cuadrados mínimos

- Una forma equivalente de describir la condición de cuadrados mínimos del filtro está representada por las *ecuaciones normales*.
- El principio de ortogonalidad usa el conjunto de entradas y $e_{min}(i)$. Como

$$e_{min}(i) = d(i) - \sum_{n=0}^{M-1} \hat{w}_n^* u(i-n)$$

entonces sustituyendo y reordenando se tiene un sistema de M ecuaciones simultáneas

$$\sum_{n=0}^{M-1} \hat{w}_n \sum_{i=M}^N u(i-k)u^*(i-n) = \sum_{i=M}^N u(i-k)d^*(i), \quad k = 0, \dots, M-1$$

Método de cuadrados mínimos ...

Filtros lineales de cuadrados mínimos ...

- Con las siguientes interpretaciones

1. *función autocorrelación de promedio temporal*

$$\phi(n, k) = \sum_{i=M}^N u(i-k)u^*(i-n), \quad 0 \leq (n, k) \leq M-1$$

2. *correlación cruzada*

$$z(-k) = \sum_{i=M}^N u(i-k)d^*(i), \quad 0 \leq k \leq M-1$$

- De esta forma

$$\sum_{n=0}^{M-1} \hat{w}_n \phi(n, k) = z(-k), \quad k = 0, 1, \dots, M-1$$

que representa el *sistema expandido de las ecuaciones normales* para el filtro lineal de cuadrados mínimos.

Método de cuadrados mínimos ...

Formulación matricial de las ecuaciones normales

- Es necesario introducir algunas definiciones. En particular:

1. La matriz de *correlación de promedios temporales* de $u(i)$, $u(i-1)$, ..., $u(i-M+1)$

$$\Phi = \begin{bmatrix} \phi(0,0) & \phi(1,0) & \cdots & \phi(M-1,0) \\ \phi(0,1) & \phi(1,1) & \cdots & \phi(M-1,1) \\ \vdots & \vdots & \ddots & \vdots \\ \phi(0,M-1) & \phi(1,M-1) & \cdots & \phi(M-1,M-1) \end{bmatrix}$$

2. El vector de *correlación cruzada de promedios temporales* entre las entradas $u(i)$, $u(i-1)$, ..., $u(i-M+1)$ y la respuesta deseada $d(i)$

$$z = [z(0), z(-1), \cdots, z(-M+1)]^T$$

3. El vector de coeficientes del filtro de cuadrados mínimos

$$\hat{w} = [\hat{w}_0, \hat{w}_1, \cdots, \hat{w}_{M-1}]^T$$

Método de cuadrados mínimos ...

Formulación matricial de las ecuaciones normales ...

- De esta forma las ecuaciones normales pueden escribirse como

$$\Phi \hat{w} = z$$

- Suponiendo que Φ no sea singular, el vector de coeficientes para el filtro de cuadrados mínimos lineal será

$$\hat{w} = \Phi^{-1} z$$

Método de cuadrados mínimos ...

Suma mínima de los errores al cuadrado

- Para completar la evaluación de $\mathcal{E}_{min}$, a partir de $\mathcal{E}_{min} = \mathcal{E}_d - \mathcal{E}_{est}$, es posible escribir para $\mathcal{E}_{est}$,

$$\begin{aligned}\mathcal{E}_{est} &= \sum_{i=M}^N |\hat{d}(i|U_i)|^2 = \sum_{i=M}^N \sum_{n=0}^{M-1} \sum_{k=0}^{M-1} \hat{w}_n \hat{w}_k^* u(i-k) u^*(i-n) \\ &= \sum_{n=0}^{M-1} \sum_{k=0}^{M-1} \hat{w}_n \hat{w}_k^* \sum_{i=M}^N u(i-k) u^*(i-n) = \sum_{n=0}^{M-1} \sum_{k=0}^{M-1} \hat{w}_n \phi(n, k) \hat{w}_k^* = \hat{\mathbf{w}}^H \mathbf{\Phi} \hat{\mathbf{w}}\end{aligned}$$

- Es posible simplificar esta ecuación si se tiene en cuenta las ecuaciones normales, o sea

$$\mathcal{E}_{est} = \hat{\mathbf{w}}^H \mathbf{z} = \mathbf{z}^H \hat{\mathbf{w}}$$

de forma que sustituyendo esta ecuación en $\mathcal{E}_{min} = \mathcal{E}_d - \mathcal{E}_{est}$ se tiene que

$$\mathcal{E}_{min} = \mathcal{E}_d - \mathbf{z}^H \hat{\mathbf{w}} = \mathcal{E}_d - \mathbf{z}^H \mathbf{\Phi}^{-1} \mathbf{z}$$

Método de cuadrados mínimos ...

Matriz correlación de promedios temporales

- La matriz de correlación Φ , con elementos $\phi(n, k)$, tal que los índices k y n indican fila y columna. Con el vector $\mathbf{u}(i)$ ($M \times 1$) definido por

$$\mathbf{u}(i) = [u(i), u(i-1), \dots, u(i-M+1)]^T$$

la matriz correlación puede escribirse como

$$\Phi = \sum_{i=M}^N \mathbf{u}(i) \mathbf{u}^H(i)$$

Propiedades

- La matriz correlación Φ es *Hermitiana*, o sea $\Phi^H = \Phi$.
- Φ es *no negativa definida*, o sea, para $\mathbf{x}$ ($M \times 1$): $\mathbf{x}^H \Phi \mathbf{x} \geq 0$.
- Los autovalores de Φ son todos reales y no negativos.
- La matriz correlación es el *producto de dos matrices rectangulares Toeplitz* que son la transpuesta Hermitiana una de otra.

Método de cuadrados mínimos ...

Matriz correlación de promedios temporales ...

- La matriz correlación no es en general Toeplitz. Sin embargo, está compuesta por el producto de dos matrices Toeplitz, ya que

$$\Phi = [\mathbf{u}(M), \mathbf{u}(M+1), \dots, \mathbf{u}(N)] \begin{bmatrix} \mathbf{u}^H(M) \\ \mathbf{u}^H(M-1) \\ \vdots \\ \mathbf{u}^H(N) \end{bmatrix}$$

- Por conveniencia de notación introducimos la *matriz de datos* $\mathbf{A}$ ($(N-M+1) \times M$), rectangular Toeplitz, cuya transpuesta Hermitiana es

$$\begin{aligned} \mathbf{A}^H &= [\mathbf{u}(M), \mathbf{u}(M+1), \dots, \mathbf{u}(N)] \\ &= \begin{bmatrix} u(M) & u(M+1) & \dots & u(N) \\ u(M-1) & u(M) & \dots & u(N-1) \\ \vdots & \vdots & \ddots & \vdots \\ u(1) & u(2) & \dots & u(N-M+1) \end{bmatrix} \end{aligned}$$

tal que

$$\Phi = \mathbf{A}^H \mathbf{A}$$

Método de cuadrados mínimos ...

Ecuaciones normales y matriz de datos

- El sistema de ecuaciones normales puede reformularse en términos de A .
- Para ello, introducimos un vector de datos *deseado* d , consistente en la respuesta deseada $d(i)$ para los valores de i en $[M, N]$, o sea

$$d^H = [d(M), d(M+1), \dots, d(N)]$$

- Con estas definiciones se tiene que $z = A^H d$
- Además, las ecuaciones normales serán $A^H A w = A^H d$
- Entonces la solución de cuadrados mínimos toma la forma $\hat{w} = (A^H A)^{-1} A^H d$
- De forma que $\mathcal{E}_{min} = d^H d - d^H A (A^H A)^{-1} A^H d$

La característica interesante es que está expresada exclusivamente por A y d .

Método de cuadrados mínimos ...

Operador proyección

- La ecuación anterior define $\hat{w}$ en términos de A y d .
- La estimación de cuadrados mínimos de d está dada por

$$\hat{d} = A\hat{w} = A(A^H A)^{-1} A^H d$$

- De acuerdo a esto, es posible interpretar el producto $A\hat{w} = A(A^H A)^{-1} A^H d$ como un *operador proyección* sobre el espacio lineal barrido por las columnas de A , el cual es el mismo espacio U_i , de la entrada para $i=N$.
- Si introducimos la notación P para este operador podemos escribir

$$P = A\hat{w} = A(A^H A)^{-1} A^H$$

Método de cuadrados mínimos ...

Operador proyección ...

- La diferencia de matrices

$$I - A\hat{w} = A(A^H A)^{-1} A^H = I - P$$

es el *operador complemento ortogonal*. Notar que el operador proyección y su complemento ortogonal están unívocamente determinados por la matriz de datos A .

- El operador proyección P , aplicado sobre el vector dato deseado d , produce la estimación correspondiente $\hat{d}$.
- $I - P$ aplicado al vector dato deseado d produce el vector de error de estimación $e_{min} = d - \hat{d}$.

Método de cuadrados mínimos ...

Operador proyección ...

Ejemplo: Consideremos un filtro de cuadrados mínimos con dos taps ($M=2$) y una entrada real de cuatro muestras ($N=4$), o sea $N-M+1=3$. La matriz de datos $\mathbf{A}$ y el vector dato deseado $\mathbf{d}$ son

$$\mathbf{A} = \begin{bmatrix} u(2) & u(1) \\ u(3) & u(2) \\ u(4) & u(3) \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 1 & 2 \\ -1 & 1 \end{bmatrix} \quad \mathbf{d} = \begin{bmatrix} d(2) \\ d(3) \\ d(4) \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 1/34 \end{bmatrix}$$

- El objetivo de este ejemplo es evaluar el operador proyección y su complemento ortogonal y utilizarlos para ilustrar el principio de ortogonalidad.
- El operador proyección será

$$\mathbf{P} = \mathbf{A}\hat{\mathbf{w}} = \mathbf{A}(\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H = \frac{1}{35} \begin{bmatrix} 26 & 15 & -2 \\ 15 & 10 & 5 \\ -3 & 5 & 34 \end{bmatrix}$$

Método de cuadrados mínimos ...

Operador proyección ...

El operador complemento ortogonal es

$$I - P = \frac{1}{35} \begin{bmatrix} 9 & -15 & 3 \\ -15 & 25 & -5 \\ 3 & -5 & 1 \end{bmatrix}$$

de forma que

$$\hat{d} = Pd = \begin{bmatrix} 1.91 \\ 1.15 \\ 0 \end{bmatrix} \quad e_{min} = (I - P)d = \begin{bmatrix} 0.09 \\ -0.15 \\ 0.03 \end{bmatrix}$$


Método de cuadrados mínimos ...

Operador proyección ...

Se muestra la representación de $\hat{d}$ y e_{min} , donde claramente esos dos vectores son normales.

Se muestra también d como la suma entre $\hat{d}$ y e_{min} .

e_{min} es ortogonal a el espacio barrido por las columnas de A , definido como el conjunto de todas las combinaciones lineales de vectores columna de A (en este caso un plano). La estimación $\hat{d}$ es solo un vector en ese espacio.



Método de cuadrados mínimos ...

Teorema de unicidad

- El problema de cuadrados mínimos siempre tiene solución. Es por eso importante saber en que condiciones la solución es *única*.
- Para ello introducimos el siguiente *teorema de unicidad*

La estimación de cuadrados mínimos $\hat{w}$ es única si y solo si la dimensión del espacio nulo de A , $\mathcal{N}(A)$, es cero.

- Sea C una matriz ($K \times M$) (para la matriz de datos $K=N-M+1$). Definimos el *espacio nulo* de C , $\mathcal{N}(C)$, como el espacio de los vectores x tal que $Cx = 0$.
- La dimensión del espacio nulo de C , $nulidad(C)$, verifica $nulidad(C) = K - r$ donde r es el rango (filas linealmente independientes).

Método de cuadrados mínimos ...

Teorema de unicidad ...

- Es posible una solución única al problema de cuadrados mínimos *solamente* cuando A tiene *columnas linealmente independientes*, o sea, cuando tiene *rango de columnas completo*. Esto implica que A tiene por los menos tantas filas como columnas, o de otra forma $N - M + 1 \geq M$.
- Esta condición significa que el sistema de ecuaciones $A\hat{w} = d$ sobredeterminado, porque tiene más ecuaciones que incógnitas. De esta forma, si A tiene rango de columnas completo, $A^H A$ ($M \times M$) *no es singular*, y la estimación de cuadrados mínimos tiene un único valor.
- Sin embargo, cuando A tiene *columnas linealmente dependientes*, o sea, es deficiente en rango, puede obtenerse un número infinito de soluciones.
- Dejaremos este caso de lado y supondremos en general que la solución de cuadrados mínimos $\hat{w}$ es única.

Método de cuadrados mínimos ...

Propiedades de la estimación

Las siguientes propiedades asumen que A es *conocida exactamente*.

1. La estimación de cuadrados mínimos $\hat{w}$ no es sesgada, siempre que el proceso de error de medición $e_o(i)$ tenga media cero.
2. Cuando $e_o(i)$ es blanco con media cero y varianza σ^2 , la matriz covarianza de la estimación de cuadrados mínimos de $\hat{w}$ es $\sigma^2 \Phi^{-1}$.
3. Cuando $e_o(i)$ es blanco de media cero, la estimación de cuadrados mínimos $\hat{w}$ es el mejor estimador lineal no sesgado (BLUE).
4. Cuando $e_o(i)$ es blanco y Gaussiano, con media cero, la estimación de cuadrados mínimos $\hat{w}$ alcanza el límite inferior de Cramér-Rao para estimaciones no sesgadas (CRLB).

Método de cuadrados mínimos recursivo (RLS)

- En implementaciones recursivas del método de cuadrados mínimos se comienza el cálculo con *condiciones iniciales conocidas* y se utiliza información en las muestras nuevas para *actualizar* las estimaciones pasadas. De esta forma encontramos que la longitud de los datos observables es variable.
- La *función costo* a ser minimizada $\mathcal{E}(n)$, donde n es la longitud variable de los datos observables, incluye también un *factor de ponderación*

$$\mathcal{E}(n) = \sum_{i=1}^n \beta(n, i) |e(i)|^2$$


donde

$$e(i) = d(i) - y(i) = d(i) - \mathbf{w}^H(n) \mathbf{u}(i)$$

para

$$\mathbf{u}(i) = [u(i), u(i-1), \dots, u(i-M+1)]^T$$

$$\mathbf{w}(n) = [w_0(n), w_1(n), \dots, w_{M-1}(n)]^T$$



Método de cuadrados mínimos recursivo (RLS) ...

- Notar que los coeficientes del filtro transversal permanecen *fijos* para el intervalo $1 \leq i \leq n$ para el cual la función costo $\mathcal{E}(n)$ está definida.
- El factor de ponderación $\beta(n, i)$ tiene la propiedad $0 < \beta(n, i) \leq 1, i=1, 2, \dots, n$. Tiene como objetivo *atenuar los datos pasados* para, de esta manera, permitir el seguimiento de las variaciones estadísticas de los datos observables cuando el filtro opera en un contexto no estacionario.
- Una forma especial de ponderación, conocida como *factor de ponderación exponencial* o *factor de olvido* está definida por

$$\beta(n, i) = \lambda^{n-i}, \quad i = 1, 2, \dots, n$$

donde λ es una constante positiva próxima, pero menor que 1. Cuando $\lambda = 1$ se obtiene el método de cuadrados mínimos ordinario. La inversa de $1 - \lambda$, es una medida de la *memoria* del algoritmo. El caso especial de $\lambda = 1$ corresponde a *infinita memoria*.

Método de cuadrados mínimos recursivo (RLS) ... RLS ponderado exponencialmente

- En el *método de cuadrados mínimos ponderado exponencialmente*, la función costo a minimizar es

$$\mathcal{E}(n) = \sum_{i=1}^n \lambda^{n-i} |e(i)|^2$$

- El óptimo de $\hat{\mathbf{w}}(n)$ para minimizar la anterior está definido por las ecuaciones normales, dadas por

$$\Phi(n) \hat{\mathbf{w}}(n) = \mathbf{z}(n)$$

donde la matriz de correlación $\Phi(n)$ ($M \times M$) es $\Phi(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) \mathbf{u}^H(i)$

y el vector de correlación cruzada $\mathbf{z}(n)$ es $\mathbf{z}(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) d^*(i)$

Método de cuadrados mínimos recursivo (RLS) ...

RLS ponderado exponencialmente ...

- La matriz correlación $\Phi(n)$ así definida difiere de la versión de promedios temporales $A^H A$, en dos aspectos:
 1. La matriz producto $u(n)u^H(n)$ en su definición está ponderada por el factor exponencial λ^{n-i} , que aparece naturalmente de la función costo.
 2. Se supone la utilización del *método pre-ventana*, por lo cual los datos de entrada previos a $i=1$ son cero, de ahí el límite inferior de la sumatoria.
- Consideraciones similares se aplican al vector de correlación cruzada $z(n)$ comparado con su contraparte de promedios temporales.

Método de cuadrados mínimos recursivo (RLS) ...

RLS ponderado exponencialmente ...

- Separando el término correspondiente a $i=n$ del resto de la sumatoria de $\Phi(n)$, es posible escribir

$$\begin{aligned}\Phi(n) &= \lambda \left[\sum_{i=1}^{n-1} \lambda^{n-1-i} \mathbf{u}(i) \mathbf{u}^H(i) \right] + \mathbf{u}(n) \mathbf{u}^H(n) \\ &= \lambda \Phi(n-1) + \mathbf{u}(n) \mathbf{u}^H(n)\end{aligned}$$

donde $\Phi(n-1)$ es el valor antiguo de la matriz correlación y el producto $\mathbf{u}(n) \mathbf{u}^H(n)$ juega el papel de término de corrección en la operación de adaptación.

- En forma similar es posible obtener para $\mathbf{z}(n)$,

$$\mathbf{z}(n) = \lambda \mathbf{z}(n-1) + \mathbf{u}(n) \mathbf{d}^*(n)$$

- Para obtener la estimación de cuadrados mínimos $\hat{\mathbf{w}}(n)$ es necesaria la inversa de $\Phi(n)$. Es posible evitar esa operación usando el *lema de inversión de matrices*.

Método de cuadrados mínimos recursivo (RLS) ...

Lema de inversión de matrices

Para A y B dos matrices de $(M \times M)$ positivas definidas por

$$A = B^{-1} + CD^{-1}C^H$$

donde D es otra matriz positiva definida de $(N \times N)$ y C es una matriz de $(M \times N)$. De acuerdo al *lema de inversión de matrices*, es posible expresar la inversa de la matriz A como

$$A^{-1} = B - BC(D + C^H BC)^{-1}C^H B$$

La prueba de este lema es constructiva, o sea, multiplicando las ecuaciones anteriores para obtener la matriz identidad.

Método de cuadrados mínimos recursivo (RLS) ...

RLS ponderado exponencialmente ...

- Con $\Phi(n)$ supuesta positiva definida (o sea, no singular), es posible aplicar el *lema de inversión de matrices* a la forma recursiva.

- Relacionaremos primero las siguientes variables:

$$\mathbf{A} = \Phi(n) \quad \mathbf{B}^{-1} = \lambda \Phi(n-1) \quad \mathbf{C} = \mathbf{u}(n) \quad \mathbf{D} = 1$$

- Sustituyendo estas definiciones en el lema de inversión de matrices obtenemos la siguiente ecuación recursiva para la matriz correlación

$$\Phi^{-1}(n) = \lambda^{-1} \Phi^{-1}(n-1) - \frac{\lambda^{-2} \Phi^{-1}(n-1) \mathbf{u}(n) \mathbf{u}^H(n) \Phi^{-1}(n-1)}{1 + \lambda^{-1} \mathbf{u}^H(n) \Phi^{-1}(n-1) \mathbf{u}(n)}$$

Método de cuadrados mínimos recursivo (RLS) ... RLS ponderado exponencialmente ...

- Por conveniencia de notación definimos $\mathbf{P}(n) = \Phi^{-1}(n)$, la *matriz correlación inversa*, y el *vector de ganancia*

$$\mathbf{k}(n) = \frac{\lambda^{-1} \mathbf{P}(n-1) \mathbf{u}(n)}{1 + \lambda^{-1} \mathbf{u}^H(n) \mathbf{P}(n-1) \mathbf{u}(n)}$$

- De esta manera la recursión en la inversa se simplifica a

$$\mathbf{P}(n) = \lambda^{-1} \mathbf{P}(n-1) - \lambda^{-1} \mathbf{k}(n) \mathbf{u}^H(n) \mathbf{P}(n-1)$$

(ecuación de Riccati para el RLS).

- Sustituyendo el vector de ganancia en esta se obtiene

$$\begin{aligned} \mathbf{k}(n) &= \lambda^{-1} \mathbf{P}(n-1) \mathbf{u}(n) - \lambda^{-1} \mathbf{k}(n) \mathbf{u}^H(n) \mathbf{P}(n-1) \mathbf{u}(n) \\ &= \mathbf{P}(n) \mathbf{u}(n) \end{aligned}$$

o sea, el vector ganancia puede interpretarse como el vector $\mathbf{u}(n)$ transformado por la inversa de la matriz correlación $\Phi(n)$.

- Método de cuadrados mínimos recursivo (RLS) ...
Adaptación (temporal) del vector de coeficientes

- Para desarrollar una forma recursiva de la ecuación de adaptación de la estimación de cuadrados mínimos de $\hat{\mathbf{w}}(n)$, usamos la ecuación del óptimo, la recursión en $\mathbf{z}(n)$ y $\mathbf{P}(n) = \Phi^{-1}(n)$ para obtener para la iteración n :

$$\begin{aligned}\hat{\mathbf{w}}(n) &= \Phi^{-1}(n)\mathbf{z}(n) = \mathbf{P}(n)\mathbf{z}(n) \\ &= \lambda\mathbf{P}(n)\mathbf{z}(n-1) + \mathbf{P}(n)\mathbf{u}(n)d^*(n)\end{aligned}$$

- Sustituyendo $\mathbf{P}(n)$ por la ecuación de Riccati del RLS se obtiene

$$\begin{aligned}\hat{\mathbf{w}}(n) &= \mathbf{P}(n-1)\mathbf{z}(n-1) - \mathbf{k}(n)\mathbf{u}^H(n)\mathbf{P}(n-1)\mathbf{z}(n-1) + \mathbf{P}(n)\mathbf{u}(n)d^*(n) \\ &= \hat{\mathbf{w}}(n-1) - \mathbf{k}(n)\mathbf{u}^H(n)\hat{\mathbf{w}}(n-1) + \mathbf{P}(n)\mathbf{u}(n)d^*(n)\end{aligned}$$

- Método de cuadrados mínimos recursivo (RLS) ...
Adaptación (temporal) del vector de coeficientes ...

- Finalmente, teniendo en cuenta que $\mathbf{k}(n) = \mathbf{P}(n)\mathbf{u}(n)$, se tiene que

$$\begin{aligned}\hat{\mathbf{w}}(n) &= \hat{\mathbf{w}}(n-1) + \mathbf{k}(n)[d^*(n) - \mathbf{u}^H(n)\hat{\mathbf{w}}(n-1)] \\ &= \hat{\mathbf{w}}(n-1) + \mathbf{k}(n)\xi^*(n)\end{aligned}$$

donde $\xi(n)$ es el *error de estimación a priori* dado por


$$\begin{aligned}\xi(n) &= d(n) - \mathbf{u}^T(n)\hat{\mathbf{w}}^*(n-1) \\ &= d(n) - \hat{\mathbf{w}}^H(n-1)\mathbf{u}(n)\end{aligned}$$

que difiere del *error a posteriori* dado por

$$e(n) = d(n) - \hat{\mathbf{w}}^H(n)\mathbf{u}(n)$$

- Notar que en la optimización de cuadrados mínimos que conducen al algoritmo recursivo anterior, la función costo está basada en $e(n)$ y no en $\xi(n)$.

- Método de cuadrados mínimos recursivo (RLS) ...
Representación del esquema completo



a) Diagrama en bloques; b) diagrama de flujo de señal.

- Método de cuadrados mínimos recursivo (RLS) ...
Algoritmo completo

Inicialización

$$\mathbf{P}(0) = \delta^{-1} \mathbf{I}, \delta \text{ una constante positiva pequeña.}$$
$$\hat{\mathbf{w}}(0) = \mathbf{0}$$

Para cada n , $n = 1, 2, \dots$, calcular

$$\mathbf{k}(n) = \frac{\lambda^{-1} \mathbf{P}(n-1) \mathbf{u}(n)}{1 + \lambda^{-1} \mathbf{u}^H(n) \mathbf{P}(n-1) \mathbf{u}(n)}$$
$$\xi(n) = d(n) - \hat{\mathbf{w}}^H(n-1) \mathbf{u}(n)$$
$$\hat{\mathbf{w}}(n) = \hat{\mathbf{w}}(n-1) + \mathbf{k}(n) \xi^*(n)$$
$$\mathbf{P}(n) = \lambda^{-1} \mathbf{P}(n-1) - \lambda^{-1} \mathbf{k}(n) \mathbf{u}^H(n) \mathbf{P}(n-1)$$

- Método de cuadrados mínimos recursivo (RLS) ...
Inicialización del algoritmo RLS

- El algoritmo RLS requiere la inicialización de la recursión de $P(n)$ mediante la elección del valor inicial de $P(0)$ que asegure la no singularidad de $\Phi(n)$.

- Es posible realizar esto evaluando la inversa de $\left[\sum_{i=-n_0}^0 \lambda^{-i} \mathbf{u}(i) \mathbf{u}(i)^H \right]^{-1}$
donde $\mathbf{u}(i)$ se obtiene del bloque inicial de datos para $-n_0 \leq i \leq 0$.

- Un procedimiento más simple es modificar la expresión de $\Phi(n)$ levemente escribiendo

$$\Phi(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) \mathbf{u}(i)^H + \delta \lambda^n \mathbf{I}$$

donde δ es una constante positiva pequeña.

- Método de cuadrados mínimos recursivo (RLS) ...
Inicialización del algoritmo RLS ...

- Así para $n=0$ en la ecuación anterior, tenemos

$$\Phi(0) = \delta \mathbf{I} \quad \text{tal que} \quad \mathbf{P}(0) = \delta^{-1} \mathbf{I}$$

δ es el único parámetro requerido. Su elección debería ser pequeño comparado con $0.01 \sigma_u^2$, donde σ_u^2 es la varianza de la entrada.

- Esta inicialización es equivalente a forzar que las primeras muestras de datos desconocidos tengan el valor $\lambda^{(-M+1)/2} \delta^{1/2}$ en lugar de cero. En otras palabras, debido al período de inicialización modificamos el método de pre-ventana escribiendo

$$u(n) = \begin{cases} \lambda^{(-M+1)/2} \delta^{1/2}, & n = -M + 1 \\ 0, & n < 0, n \neq -M + 1 \end{cases}$$

- Método de cuadrados mínimos recursivo (RLS) ...
Inicialización del algoritmo RLS ...

- Solo falta elegir el valor inicial del vector de coeficientes, lo que usualmente se hace con $\hat{\mathbf{w}}(0) = \mathbf{0}$.
- Es importante notar que usando el procedimiento de inicialización anterior no se está obteniendo la solución que minimiza la función costo exactamente.

En su lugar, se está calculando la solución que minimiza

$$\mathcal{E}(n) = \delta \lambda^n \|\mathbf{w}(n)\| + \sum_{i=1}^n \lambda^{n-i} |e(i)|^2$$

En otras palabras, el algoritmo de la tabla produce la solución recursiva exacta de

$$\min_{\mathbf{w}(n)} [\delta \lambda^n \|\mathbf{w}(n)\|^2 + \sum_{i=1}^n \lambda^{n-i} |e(i)|^2]$$

Método de cuadrados mínimos recursivo (RLS) ...

Aspectos adicionales

- El valor mínimo de la suma de errores al cuadrado ponderada $\mathcal{E}_{min}$, resulta cuando el vector de coeficientes es igual a la estimación de cuadrados mínimos $\hat{\mathbf{w}}(n)$.
- Para calcular $\mathcal{E}_{min}(n)$ es necesario usar la relación

$$\mathcal{E}(n) = \mathcal{E}_d(n) - \mathbf{z}^H(n)\hat{\mathbf{w}}(n)$$

donde $\mathcal{E}_d(n)$ está definido por

$$\mathcal{E}_d(n) = \sum_{i=1}^n \lambda^{n-i} |d(i)|^2 = \lambda \mathcal{E}_d(n-1) + |d(n)|^2$$

Método de cuadrados mínimos recursivo (RLS) ...

Aspectos adicionales

- De forma que

$$\begin{aligned}\mathcal{E}_{min}(n) &= \lambda[\mathcal{E}_d(n-1) - \mathbf{z}^H(n-1)\hat{\mathbf{w}}(n-1)] \\ &\quad + d(n)[d^*(n) - \mathbf{u}^H(n)\hat{\mathbf{w}}(n-1)] - \mathbf{z}^H(n)\mathbf{k}(n)\xi^*(n)\end{aligned}$$

- Por definición, la expresión dentro del 1er. [.] es $\mathcal{E}(n-1)$. También, la expresión dentro del 2do. [.] es $\xi^*(n)$. Para el último término, usamos la definición de $\mathbf{k}(n)$ para escribir

$$\mathbf{z}^H \mathbf{k}(n) = \mathbf{z}^H(n) \Phi^{-1}(n) \mathbf{u}(n) = [\Phi^{-1}(n) \mathbf{z}(n)]^H \mathbf{u}(n) = \hat{\mathbf{w}}^H(n) \mathbf{u}(n)$$

- Entonces $\mathcal{E}_{min}(n)$ puede escribirse como

$$\begin{aligned}\mathcal{E}_{min}(n) &= \lambda \mathcal{E}_{min}(n-1) + d(n)\xi^*(n) - \hat{\mathbf{w}}^H(n) \mathbf{u}(n) \xi^*(n) \\ &= \lambda \mathcal{E}_{min}(n-1) + \xi^*(n)[d(n) - \hat{\mathbf{w}}^H(n) \mathbf{u}(n)] \\ &= \lambda \mathcal{E}_{min}(n-1) + \xi^*(n)e(n)\end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Factor de conversión

- La fórmula anterior involucra dos errores de estimación diferentes: el *error a priori* $\xi(n)$ y el *error a posteriori* $e(n)$.

- Para establecer una relación entre ellos, tengamos en cuenta que

$$\begin{aligned}e(n) &= d(n) - [\hat{\mathbf{w}}(n-1) + \mathbf{k}(n)\xi^*(n)]^H \mathbf{u}(n) \\&= d(n) - \hat{\mathbf{w}}^H(n-1)\mathbf{u}(n) - \mathbf{k}^H(n)\mathbf{u}(n)\xi(n) \\&= (1 - \mathbf{k}^H(n)\mathbf{u}(n))\xi(n)\end{aligned}$$

- Esta relación entre los errores $e(n)$ y $\xi(n)$ se denomina *factor de conversión*

$$\gamma(n) = \frac{e(n)}{\xi(n)} = 1 - \mathbf{k}^H(n)\mathbf{u}(n)$$

Método de cuadrados mínimos recursivo (RLS) ...

Análisis de convergencia

- Consideraremos el análisis de convergencia del algoritmo RLS operando en un ambiente estacionario, para lo que se utilizará la teoría de independencia también usada para el análisis del algoritmo LMS.
- Supondremos que $d(n)$ y el vector $\mathbf{u}(n)$ están relacionados por el *modelo de regresión lineal múltiple*, al que podemos escribir como

$$d(n) = \mathbf{w}_o^H \mathbf{u}(n) + e_o(n)$$

donde $\mathbf{w}_o$ es el vector de parámetros de regresión (constante) y $e_o(n)$ es el error de medición, blanco, con media cero y varianza σ^2 .

- La suposición de $\mathbf{w}_o$ constante implica decir que el filtro adaptivo transversal opera en un ambiente estacionario con $\lambda = 1$.

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en media

- Inicia con $\Phi(0) = 0$ que corresponde a $\mathbf{u}(0) = 0$ (o sea pre-ventana de los datos de entrada), y el procedimiento de inicialización, $\hat{\mathbf{w}}(n)$ obtenido por el RLS coincide casi exactamente con el método LS para $n \geq M$, donde M es el orden del filtro adaptivo.
- De acuerdo a esto, con las ecuaciones normales

$$\hat{\mathbf{w}}(n) = \Phi^{-1}(n)\mathbf{z}(n), \quad n \geq M$$

donde, para $\lambda = 1$,

$$\Phi(n) = \sum_{i=1}^n \mathbf{u}(i)\mathbf{u}^H(i) \quad \text{y} \quad \mathbf{z}(n) = \sum_{i=1}^n \mathbf{u}(i)d^*(i)$$

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en media ...

- Sustituyendo el modelo de regresión en la ecuación anterior, se obtiene

$$\begin{aligned} \mathbf{z}(n) &= \sum_{i=1}^n \mathbf{u}(i) \mathbf{u}^H(i) \mathbf{w}_o + \sum_{i=1}^n \mathbf{u}(i) e_o^*(i) \\ &= \mathbf{\Phi}(n) \mathbf{w}_o + \sum_{i=1}^n \mathbf{u}(i) e_o^*(i) \end{aligned}$$

- Así, la solución óptima puede reescribirse como

$$\begin{aligned} \hat{\mathbf{w}}(n) &= \mathbf{\Phi}^{-1}(n) \mathbf{\Phi}(n) \mathbf{w}_o + \mathbf{\Phi}^{-1}(n) \sum_{i=1}^n \mathbf{u}(i) e_o^*(i) \\ &= \mathbf{w}_o + \mathbf{\Phi}^{-1}(n) \sum_{i=1}^n \mathbf{u}(i) e_o^*(i) \end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en media ...

- Utilizaremos ahora la propiedad de esperanza estadística de una variable aleatoria

$$E[x] = E[E[x|y]]$$

donde $E[x|y]$ es la esperanza condicional de una variable aleatoria x dada por otra variable y . La esperanza restante en el lado derecho de esta ecuación es respecto a y .

- Utilizando esta propiedad en la reformulación del óptimo anterior, se obtiene

$$\begin{aligned} E[\hat{\mathbf{w}}(n)] &= \mathbf{w}_o + E\left[\Phi^{-1}(n) \sum_{i=1}^n \mathbf{u}(i) e_o^*(n)\right] \\ &= \mathbf{w}_o + E\left[E\left[\Phi^{-1}(n) \sum_{i=1}^n \mathbf{u}(i) e_o^*(i) \mid \mathbf{u}(i), i = 1, 2, \dots, n\right]\right] \end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en media ...

- Teniendo en cuenta que:

- a) $\Phi(n)$ está unívocamente definida por $u(1), u(2), \dots, u(n)$.
- b) $e_o(i)$ es independiente de $u(i)$, para todo i .
- c) $e_o(i)$ tiene media cero.

- Entonces

$$E[\hat{\mathbf{w}}(n)] = \mathbf{w}_o, \quad n \geq M$$

de forma que el algoritmo RLS converge en media para $n \geq M$, donde M es el número de coeficientes del filtro adaptativo.

- Notar que a diferencia del LMS, el RLS no requiere esperar que $n \rightarrow \infty$ para que la convergencia en media sea alcanzada.

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en MSE de $\hat{\mathbf{w}}(n)$

- Para analizar la convergencia del MSE del vector de coeficientes $\hat{\mathbf{w}}(n)$, es posible expresar el error en los coeficientes como

$$\begin{aligned}\boldsymbol{\epsilon} &= \hat{\mathbf{w}}(n) - \mathbf{w}_o \\ &= \boldsymbol{\Phi}^{-1}(n) \sum_{i=1}^n \mathbf{u}(i) e_o^*(i)\end{aligned}$$

- Luego usando la definición de matriz correlación del error en los coeficientes se tiene que

$$\begin{aligned}\mathbf{K}(n) &= E[\boldsymbol{\epsilon}(n) \boldsymbol{\epsilon}^H(n)] \\ &= E \left[\boldsymbol{\Phi}^{-1} \sum_{i=1}^n \sum_{j=1}^n \mathbf{u}(i) e_o^*(i) e_o(j) \mathbf{u}^H(j) \boldsymbol{\Phi}^{-1}(n) \right]\end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en MSE de $\hat{\mathbf{w}}(n)$...

- Invocando ahora la propiedad $E[x] = E[E[x|y]]$

$$\mathbf{K}(n) = E \left[\mathbf{\Phi}^{-1}(n) \sum_{i=1}^n \sum_{j=1}^n \mathbf{u}(i) E[e_o^*(i) e_o(j)] \mathbf{u}^H(n) \mathbf{\Phi}^{-1}(n) \right]$$

- Dado que el error de medición $e_o(i)$ se supone ruido blanco de varianza σ^2 , se tiene que

$$\begin{aligned} \mathbf{K}(n) &= \sigma^2 E \left[\mathbf{\Phi}^{-1}(n) \sum_{i=1}^n \sum_{j=1}^n \mathbf{u}(i) \mathbf{u}^H(n) \mathbf{\Phi}^{-1}(n) \right] \\ &= \sigma^2 E[\mathbf{\Phi}^{-1}(n) \mathbf{\Phi}(n) \mathbf{\Phi}^{-1}(n)] \\ &= \sigma^2 E[\mathbf{\Phi}^{-1}(n)] \end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en MSE de $\hat{\mathbf{w}}(n)$...

- Luego, en base a las siguientes suposiciones de la teoría de independencia
 1. $\mathbf{u}(1), \mathbf{u}(2), \dots, \mathbf{u}(n)$ son independientes y de distribución idéntica (i.i.d.).
 2. $\mathbf{u}(1), \mathbf{u}(2), \dots, \mathbf{u}(n)$ se obtienen de un proceso estocástico con *distribución Gaussiana multivariable* de media cero y matriz correlación $\mathbf{R}$.
- El resultado interesante es que $\Phi(n)$ está descrita por una *distribución compleja de Wishart*. En particular para esa distribución se verifica que

$$E[\Phi^{-1}(n)] = \frac{1}{n - M - 1} \mathbf{R}^{-1}, \quad n > M + 1$$

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en MSE de $\hat{\mathbf{w}}(n)$...

- Sustituyendo en la ecuación anterior se obtiene

$$\mathbf{K}(n) = \frac{\sigma^2}{n - M - 1} \mathbf{R}^{-1}, \quad n > M + 1$$

para la cual

$$\begin{aligned} E[\epsilon^H(n)\epsilon(n)] &= \text{tr}[\mathbf{K}(n)] = \frac{\sigma^2}{n - M - 1} \text{tr}[\mathbf{R}^{-1}] \\ &= \frac{\sigma^2}{n - M - 1} \sum_{i=1}^M \frac{1}{\lambda_i}, \quad n > M + 1 \end{aligned}$$

donde λ_i son los autovalores de $\mathbf{R}$.

Método de cuadrados mínimos recursivo (RLS) ...

Convergencia en MSE de $\hat{w}(n)$...

- En base a esta ecuación es posible realizar las siguientes observaciones
 1. El MSE en los coeficientes *se amplifica por la inversa del menor autovalor λ_{min}* , de donde, como una primera aproximación, la sensibilidad del algoritmo RLS a la dispersión de los autovalores es inversamente proporcional al menor autovalor. En consecuencia, *problemas de cuadrados mínimos mal condicionados pueden conducir a malas propiedades de convergencia.*
 2. El MSE en los coeficientes decae casi linealmente con el número de iteraciones n . En consecuencia, la *estimación producida por el RLS converge en media cuadrática a w_o del modelo de regresión lineal casi linealmente con el tiempo.*

Método de cuadrados mínimos recursivo (RLS) ...

Curva de aprendizaje

- Existen en el algoritmo RLS dos errores de estimación: el error a priori $\xi(n)$ y el error a posteriori $e(n)$.
- En base a las condiciones iniciales discutidas, el valor medio cuadrático para esos errores puede ser muy diferente en el tiempo.
- Para $n=1$, el valor medio cuadrático de $\xi(n)$ toma valores grandes (el valor medio cuadrático de $d(n)$) y decae después cuando n se incrementa.
- El valor medio cuadrático de $e(n)$, por otro lado, tiene valores pequeños para $n=1$ y luego aumenta con n .
- De esta forma, la elección de $\xi(n)$ como el error de interés produce una curva de aprendizaje para el algoritmo RLS con una forma general similar a la del algoritmo LMS. Para comparar estas curvas analizaremos entonces el algoritmo RLS sobre la base de $\xi(n)$.

Método de cuadrados mínimos recursivo (RLS) ...

Curva de aprendizaje ...

- Eliminando la respuesta deseada de la definición de $\xi(n)$, se obtiene

$$\begin{aligned}\xi(n) &= e_o(n) - [\hat{\mathbf{w}}(n-1) - \mathbf{w}_o]^H \mathbf{u}(n) \\ &= e_o(n) - \boldsymbol{\epsilon}^H(n-1) \mathbf{u}(n)\end{aligned}$$

- Como un índice de *desempeño estadístico* para el algoritmo RLS es conveniente utilizar el *error medio cuadrático a priori* definido por

$$J'(n) = E[|\xi(n)|^2]$$

- Reemplazando la anterior en esta ecuación se obtiene

$$\begin{aligned}J'(n) &= E[|e_o|^2] + E[\mathbf{u}^H \boldsymbol{\epsilon}(n-1) \boldsymbol{\epsilon}^H(n-1) \mathbf{u}(n)] \\ &\quad - E[\boldsymbol{\epsilon}^H(n-1) \mathbf{u}(n) e_o^*(n)] - E[e_o(n) \mathbf{u}^H(n) \boldsymbol{\epsilon}(n-1)]\end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Curva de aprendizaje ...

- Con $e_o(n)$ supuesto de media cero, el 1er término de la ecuación anterior es simplemente su varianza, σ^2 . Para los siguientes términos (con las suposiciones de la teoría de independencia discutidas) se obtiene:

1. $\hat{\mathbf{w}}(n-1)$ y $\boldsymbol{\epsilon}(n-1)$ son independientes de $\mathbf{u}(n)$, este último obtenido de un proceso ESA de media cero. Usando la independencia estadística, junto con resultados conocidos de álgebra, es posible obtener para el 2do término

$$E[\mathbf{u}^H(n)\boldsymbol{\epsilon}(n-1)\boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)] = \text{tr}[\mathbf{R}\mathbf{K}(n-1)]$$

2. $e_o(n)$ depende de $\mathbf{u}(n)$. En consecuencia, $\boldsymbol{\epsilon}(n-1)$ es independiente de $\mathbf{u}(n)$ y $e_o(n)$. Así, el 3er término es cero teniendo en cuenta que

$$E[\boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)e_o^*(n)] = E[\boldsymbol{\epsilon}^H(n-1)]E[\mathbf{u}(n)e_o^*(n)] = 0$$

por el principio de ortogonalidad. Lo mismo para el 4to. término.

Método de cuadrados mínimos recursivo (RLS) ...

Curva de aprendizaje ...

- Usando estos resultados es posible reescribir la ecuación del MSE a priori como sigue

$$J'(n) = \sigma^2 + \text{tr}[\mathbf{R}\mathbf{K}(n-1)]$$

- y usando lo obtenido para $\mathbf{K}(n)$ (con $\lambda = 1$)

$$J'(n) = \sigma^2 + \frac{M\sigma^2}{n - M - 1}, \quad n \geq M + 1$$

Método de cuadrados mínimos recursivo (RLS) ...

Curva de aprendizaje ...

- Con base en este resultado es posible hacer las siguientes observaciones
 1. La curva de aprendizaje promedio del RLS converge en alrededor de $2M$ iteraciones, o sea, la velocidad de convergencia del RLS es **típicamente un orden de magnitud más rápida que la del LMS**.
 2. Para $n \rightarrow \infty$, $J'(n)$ tiende a σ^2 , la varianza de $e_o(n)$. En otras palabras, el RLS teóricamente **produce un exceso de MSE cero** (ó desajuste cero) cuando opera en un ambiente estacionario.
 3. La convergencia del algoritmo RLS en media cuadrática es **independiente de los autovalores de R** .
- Debe enfatizarse que la mencionada mejora en la velocidad de convergencia del RLS en relación al LMS se mantiene solamente cuando $e_o(n)$ es pequeño en comparación con $d(n)$, o sea cuando la relación señal a ruido es alta. También, la propiedad de desajuste cero supone que $\lambda = 1$ (memoria infinita).

Método de cuadrados mínimos recursivo (RLS) ... Formulación por variables de estado

- El algoritmo RLS exponencialmente ponderado fue obtenido a partir del lema de inversión de matrices, fundamentalmente *en base a un modelo matemático determinístico*.
- El algoritmo RLS puede también obtenerse en *forma exacta* directamente del algoritmo de filtrado Kalman tipo covarianza.
- *Este análisis alternativo de la solución del problema de RLS es importante porque nos permite establecer una importante lista de correspondencias entre el algoritmo RLS y el filtro de Kalman.*

Método de cuadrados mínimos recursivo (RLS) ... Formulación por variables de estado

Una comparación de modelos estocásticos y determinísticos

- Considerando el modelo dinámico no forzado

$$\begin{aligned} \mathbf{x}(n+1) &= \lambda^{-1/2} \mathbf{x}(n) \\ y(n) &= \mathbf{u}^H(n) \mathbf{x}(n) + \nu(n) \end{aligned}$$

- De la primera ecuación es simple concluir $\mathbf{x}(n) = \lambda^{-n/2} \mathbf{x}(0)$
- Evaluando la 2da ecuación para $n=0,1, \dots$ y utilizando la solución anterior, es posible obtener el siguiente sistema de ecuaciones estocásticas lineales

$$\begin{aligned} y(0) &= \mathbf{u}^H(0) \mathbf{x}(0) + \nu(0) \\ y(1) &= \lambda^{-1/2} \mathbf{u}^H(1) \mathbf{x}(0) + \nu(1) \\ &\vdots \\ y(n) &= \lambda^{-n/2} \mathbf{u}^H(n) \mathbf{x}(0) + \nu(n) \end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Formulación por variables de estado ...

- O en forma equivalente

$$\begin{aligned}y(0) &= \mathbf{u}^H(0)\mathbf{x}(0) + \nu(0) \\ \lambda^{1/2}y(1) &= \mathbf{u}^H(1)\mathbf{x}(0) + \nu(1) \\ &\vdots \\ \lambda^{n/2}y(n) &= \mathbf{u}^H(n)\mathbf{x}(0) + \nu(n)\end{aligned}$$

- Este sistema representa una caracterización estocástica del *modelo dinámico no forzado* asociado desde el punto de vista de filtrado de Kalman.
- Considerando ahora la formulación determinística del problema desde el punto de vista del RLS y adecuando el modelo de regresión lineal múltiple es posible escribir

$$\begin{aligned}d^*(0) &= \mathbf{u}^H(0)\mathbf{w}_o + e_o^*(0) \\ d^*(1) &= \mathbf{u}^H(1)\mathbf{w}_o + e_o^*(1) \\ &\vdots \\ d^*(n) &= \mathbf{u}^H(n)\mathbf{w}_o + e_o^*(n)\end{aligned}$$

Método de cuadrados mínimos recursivo (RLS) ...

Formulación por variables de estado ...

- Se tiene entonces dos sistemas de ecuaciones lineales simultaneas para resolver esencialmente el mismo problema. Es de esperar que ambos conduzcan exactamente a la misma solución del problema.
- Además, teniendo en cuenta que esos dos sistemas tienen la misma forma matemática, es razonable hacer $x(0) = w_o$.
- Sobre esta base y los sistemas anteriores es posible concluir las siguientes correspondencias

$$y(n) = \lambda^{-n/2} d^*(n) \quad \nu(n) = \lambda^{-n/2} e_o^*(n)$$

Método de cuadrados mínimos recursivo (RLS) ... Formulación por variables de estado ...

Una comparación del filtrado de Kalman y el algoritmo RLS

- La comparación de las tablas que resumen los algoritmos de Kalman y RLS arrojan las siguientes correspondencias

$$\begin{aligned} \mathbf{K}(n-1) &= \lambda^{-1} \mathbf{P}(n-1) \\ \mathbf{g}(n) &= \lambda^{-1/2} \mathbf{k}(n) \\ \alpha(n) &= \lambda^{-n/2} \xi^*(n) \\ \hat{\mathbf{x}}(n+1|Y_n) &= \lambda^{-(n+1)/2} \hat{\mathbf{w}}(n) \end{aligned}$$

- Además, es posible concluir que el factor de conversión $r^{-1}(n)$ en la forma especializada del filtro de Kalman tipo covarianza y el factor de conversión $\gamma(n)$ para el algoritmo RLS coinciden, o sea $r^{-1}(n) = \gamma(n)$.

Método de cuadrados mínimos recursivo (RLS) ... Formulación por variables de estado ...

Una comparación del filtrado de Kalman y el algoritmo RLS

Kalman		RLS	
Descripción	Variable	Descripción	Variable
Estado inicial	$\mathbf{x}(0)$	Coeficientes de regresión	$\mathbf{w}_o$
Estados	$\mathbf{x}(n)$	Coeficientes de regresión exponencialmente ponderados	$\lambda^{-n/2}\mathbf{w}_o$
Observaciones	$y(n)$	Respuesta deseada	$\lambda^{-n/2}d^*(n)$
Ruido de medición	$\nu(n)$	Error de medición	$\lambda^{-n/2}e_o^*(n)$
Estados del predictor de un paso	$\hat{\mathbf{x}}(n+1 Y_n)$	Coeficientes estimados	$\lambda^{-(n+1)/2}\hat{\mathbf{w}}(n)$
Correlación del error de predicción de estados	$\mathbf{K}(n)$	Inversa de la correlación de la entrada	$\lambda^{-1}\mathbf{P}(n)$
Ganancia Kalman	$\mathbf{g}(n)$	Vector ganancia	$\lambda^{-1/2}\mathbf{k}(n)$
Innovación	$\alpha(n)$	Error a priori	$\lambda^{-n/2}\xi^*(n)$
Factor de conversión	$r^{-1}(n)$	Factor de conversión	$\gamma(n)$
Condiciones iniciales	$\hat{\mathbf{x}}(1 y_0) = \mathbf{0}$ $\mathbf{K}(0)$	Condiciones iniciales	$\hat{\mathbf{w}}(0) = \mathbf{0}$ $\lambda^{-1}\mathbf{P}(0)$

Cuadrados Mínimos Recursivo (RLS)

Método de Cuadrados Mínimos

- Filtros lineales de cuadrados mínimos
- Cuadrados Mínimos Recursivo (RLS)
- Algoritmo RLS ponderado exponencialmente
- Análisis de convergencia