

Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

Tracking e implementación

Seguimiento de sistemas variantes en el tiempo

- Grado de no estacionariedad
- Criterios de seguimiento
- Desempeño de seguimiento en RLS y LMS
- Comparación de algoritmos LMS y RLS

Efectos de precisión finita

- Errores de cuantización en algoritmos LMS y RLS

Seguimiento de sistemas variantes en el tiempo

- Se analizaron las familias de LMS y RLS operando en un ambiente ESA: la superficie de MSE fija y se busca, paso a paso, el mínimo MSE para asegurar desempeño óptimo o casi óptimo.
- Estudiaremos esos algoritmos en un *contexto no estacionario*, donde la solución de Wiener es variante en el tiempo. El *mínimo de la superficie de MSE ya no es fijo*.
- El algoritmo de filtrado adaptativo tiene que adicionar la *tarea de seguimiento (tracking) del mínimo* de la superficie de MSE, i.e., el algoritmo debe seguir las variaciones estadísticas de la entrada (supuestas "suficientemente" lentas para que el seguimiento sea posible).

Seguimiento de sistemas variantes en el tiempo ...

- El *seguimiento es un fenómeno estacionario*. Esto está en contraste con la *convergencia que es un fenómeno transitorio*.
- Para que un filtro adaptativo ejecute el seguimiento debe *pasar del estado de operación transitorio al estacionario* a través del ajuste de los coeficientes del filtro.
- En general estas dos tareas, *convergencia y seguimiento*, son características bien diferentes de un algoritmo.

Seguimiento de sistemas variantes en el tiempo ...

Causas y características de no estacionariedad

- Un ambiente no estacionario puede encontrarse en la práctica como:
 1. *El marco de referencia que provee la respuesta deseada puede ser variante en el tiempo*, por ej., en identificación de un sistema variante en el tiempo. En este caso, R (como en un ambiente ESA), mientras que p es variante en el tiempo.
 2. *El proceso estocástico que provee la entrada del filtro adaptativo es no estacionario*, por ej., en ecualización de un canal variante en el tiempo. En este caso tanto R como p son variantes en el tiempo.
- De esta forma, las características de seguimiento de un sistema variante en el tiempo *dependen del tipo de filtro adaptativo empleado y del problema específico*.

Seguimiento de sistemas variantes en el tiempo ...

Causas y características de no estacionariedad ...

- Para estudiar adaptación en un ambiente no estacionario con énfasis en seguimiento (tracking) se estudiarán dos aspectos fundamentales:
 1. *¿Cómo elegir entre los algoritmos LMS y RLS como base para el seguimiento?*
 2. *¿Cómo ajustar automáticamente el parámetro de adaptación del algoritmo de seguimiento para obtener el mejor rendimiento posible?*

Seguimiento de sistemas variantes en el tiempo ...

Modelo de variación para identificación de sistemas

- Discutiremos un modelo de sistema variante en el tiempo *para la aplicación de identificación de sistemas*, con tres ecuaciones básicas
- 1. *Proceso de Markov de primer orden*. La variación del sistema de dinámica desconocida se modela con un filtro de coeficientes $w_o(n)$, definidos por

$$w_o(n+1) = a w_o(n) + \omega(n)$$

donde a es un parámetro constante y $\omega(n)$ es un proceso de ruido de modelado, de media cero y matriz correlación R_ω .

Es como un pasabajos $H(z) = 1/(1 - az^{-1})$ donde, cuando a es próximo a 1, su ancho de banda es mucho menor que la velocidad de los datos de entrada (se requerirán varias iteraciones para producir un cambio significativo en los coeficientes).

Seguimiento de sistemas variantes en el tiempo ...

Modelo de variación para identificación de sistemas ...

2. *Respuesta deseada*. Está definida por

$$d(n) = \mathbf{w}_o^H(n) \mathbf{u}(n) + \nu(n)$$


donde $\nu(n)$ es el *ruido de medición*, supuesto blanco, de media cero y varianza σ^2 . La respuesta deseada $d(n)$ es un proceso *no estacionario*, dado que $\mathbf{w}_o(n)$ varia en el tiempo (R es constante, la superficie de MSE no cambia, pero el mínimo estará continuamente variando).

3. *Señal de error*. La señal de error $e(n)$ está definida por

$$e(n) = d(n) - y(n) = \mathbf{w}_o^H(n) \mathbf{u}(n) + \nu(n) - \hat{\mathbf{w}}^H(n) \mathbf{u}(n)$$

Se supone además que el filtro adaptativo tiene el mismo número de coeficientes que el sistema a identificar desconocido.

Seguimiento de sistemas variantes en el tiempo ... Modelo de variación para identificación de sistemas ...



Modelo dinámico lineal para un ambiente no estacionario

Seguimiento de sistemas variantes en el tiempo ...

Suposiciones

- Típicamente, las variaciones de $\omega(n)$ en el modelo de Markov son lentas, tal que el filtrado adaptativo puede *seguir* las variaciones estadísticas del comportamiento dinámico del sistema desconocido a identificar.
- Para el análisis de seguimiento se realizarán las siguientes hipótesis (*suposiciones de independencia*)
 1. El proceso de ruido $\omega(n)$ es independiente de $u(n)$ y el ruido de medición $\nu(n)$.
 2. $u(n)$ y el ruido de medición $\nu(n)$ son independientes.
 3. $\nu(n)$ es blanco, de media cero y varianza $\sigma_\nu^2 < \infty$.
- Dado que las tres cantidades aleatorias asociadas al fenómeno físico no se relacionan en forma simple, la primera suposición permite un análisis accesible.

Seguimiento de sistemas variantes en el tiempo ...

Grado de no estacionariedad ...

- Para discutir una definición clara de la noción, algo ambigua, de variaciones estadísticas lentas o rápidas del modelo, introduciremos el *grado de no estacionariedad* α .

$$\alpha = \left(\frac{E[|\boldsymbol{\omega}^H(n)\mathbf{u}(n)|^2]}{E[|\nu(n)|^2]} \right)^{1/2}$$

Interpretación: una *medida de la potencia de señal no modelada a la del ruido en el modelo de sistema a identificar*.

- Es una característica asociada del *modelo de sistema variante en el tiempo* y no tiene nada que ver con el filtro adaptativo.

Seguimiento de sistemas variantes en el tiempo ...

Grado de no estacionariedad ...

- El grado de no estacionariedad α se puede relacionar con el desajuste del filtro adaptativo $\mathcal{M}$.
- El menor MSE J_{min} que el filtro puede alcanzar es σ_v^2 .
- Por otro lado, lo mejor que puede realizar un filtro adaptativo en un contexto variante en el tiempo es producir un vector de error en los coeficientes $\epsilon(n)$ igual al proceso de ruido $\omega(n)$.
- O, en forma equivalente, es posible hacer que su matriz correlación asociada $\mathbf{K}(n) = E[\epsilon^H(n)\epsilon(n)]$ sea igual a $\mathbf{R}_\omega = E[\omega^H(n)\omega(n)]$.

Seguimiento de sistemas variantes en el tiempo ...

Grado de no estacionariedad ...

- Teniendo en cuenta el exceso de MSE $J_{ex}(n) = tr[\mathbf{R}\mathbf{K}(n)]$, es posible establecer que el exceso de MSE a ser alcanzado por el filtro nunca puede ser menor que $tr[\mathbf{R}\mathbf{R}_\omega]$. Con la definición de desajuste se tiene que

$$\mathcal{M} = \frac{J_{ex}(\infty)}{J_{min}} \geq \frac{tr[\mathbf{R}\mathbf{R}_\omega]}{\sigma_v^2} = \alpha^2$$

o en otras palabras, *la raíz cuadrada del desajuste impone un límite superior al grado de no estacionariedad*.

- En base a esta ecuación es posible concluir que
 1. Para variaciones estadísticas pequeñas, α es pequeño. Esto significa que *es posible* construir un filtro adaptativo que pueda seguir al sistema variante en el tiempo.
 2. Para variaciones estadísticas grandes, $\alpha > 1$. El desajuste producido por el filtro adaptativo excede 100%. Entonces, *no existe ventaja* en usar un filtro adaptativo para resolver el problema de seguimiento.

Seguimiento de sistemas variantes en el tiempo ...

Criterios de seguimiento

- Cuando el sistema dinámico desconocido se modela con un filtro FIR $w_o(n)$ y se utiliza un filtro adaptativo $\hat{w}(n)$, es posible usar como base de análisis el vector de error en los coeficientes

$$\epsilon(n) = \hat{w}(n) - w_o(n)$$

- Dos figuras de mérito para establecer la capacidad de seguimiento de un filtro adaptativo:
 1. Desviación media cuadrática (asociada al seguimiento de coeficientes).
 2. Desajuste (asociada al seguimiento del MSE).

Seguimiento de sistemas variantes en el tiempo ...

Criterios de seguimiento: Desviación media cuadrática

- Definida por

$$\mathcal{D}(n) = E[\|\hat{\mathbf{w}}(n) - \mathbf{w}_o(n)\|^2] = E[\|\boldsymbol{\epsilon}(n)\|^2] = \text{tr}[\mathbf{K}(n)]$$

donde n se supone suficientemente grande como para que el filtro adaptativo se encuentre en estado estacionario. Claramente $\mathcal{D}(n)$ debería ser pequeña para un buen desempeño.

- El vector de error en los coeficientes $\boldsymbol{\epsilon}(n)$ puede expresarse como la suma de dos componentes

$$\boldsymbol{\epsilon}(n) = \boldsymbol{\epsilon}_1(n) + \boldsymbol{\epsilon}_2(n) \quad \boldsymbol{\epsilon}_1(n) = \hat{\mathbf{w}}(n) - E[\hat{\mathbf{w}}(n)] \quad \boldsymbol{\epsilon}_2(n) = E[\hat{\mathbf{w}}(n)] - \mathbf{w}_o(n)$$

donde $\boldsymbol{\epsilon}_1(n)$ y $\boldsymbol{\epsilon}_2(n)$ son las componentes debidas *al ruido de estimación* y al *retardo de seguimiento*, respectivamente.

- En base a las suposiciones anteriores $E[\boldsymbol{\epsilon}_1^H(n)\boldsymbol{\epsilon}_2(n)] = 0$, tal que

$$\mathcal{D}(n) = \mathcal{D}_1(n) + \mathcal{D}_2(n) = E[\|\boldsymbol{\epsilon}_1(n)\|^2] + E[\|\boldsymbol{\epsilon}_2(n)\|^2]$$

Seguimiento de sistemas variantes en el tiempo ...

Criterios de seguimiento: Desajuste

- Definido por $\mathcal{M}(n) = J_{ex}(n)/\sigma_v^2$ (con n grande para que el transitorio se haya extinguido). Para un desempeño de seguimiento adecuado es posible concluir que $\mathcal{M}(n)$ debería ser pequeño comparado con la unidad.
- De la misma forma que para $\mathcal{D}(n)$, es posible expresar $J_{ex}(n)$ en términos de dos componentes, J_{ex_1} y $J_{ex_2}(n)$, una asociada al ruido de estimación y la otra asociada al retardo de seguimiento, tal que

$$\mathcal{M}(n) = \mathcal{M}_1(n) + \mathcal{M}_2(n)$$

Ambos desajustes dependen de la cantidad de iteraciones n asociadas al algoritmo utilizado.

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del LMS

- En el contexto no estacionario descripto es posible considerar que el filtro adaptativo se implementa usando un algoritmo LMS. En ese caso

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \mu \mathbf{u}(n) e^*(n)$$

donde teniendo en cuenta la señal de error con el modelo de regresión lineal se obtiene

$$\hat{\mathbf{w}}(n+1) = [\mathbf{I} - \mu \mathbf{u}(n) \mathbf{u}^H(n)] \hat{\mathbf{w}}(n) + \mathbf{u}(n) \mathbf{u}^H(n) \mathbf{w}_o(n) + \mu \mathbf{u}(n) \nu^*(n)$$

o equivalentemente

$$\begin{aligned} \bar{\epsilon}(n+1) &= \hat{\mathbf{w}}(n+1) - \mathbf{w}_o(n+1) \\ &= [\mathbf{I} - \mu \mathbf{u}(n) \mathbf{u}^H(n)] \bar{\epsilon}(n) + (1 - a) \mathbf{w}_o(n) - \mu \mathbf{u}(n) \nu^*(n) + \boldsymbol{\omega}(n) \end{aligned}$$

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del LMS ...

- Con la suposición de a próximo a 1, la anterior se simplifica a

$$\bar{\epsilon}(n+1) = [\mathbf{I} - \mu \mathbf{u}(n) \mathbf{u}^H(n)] \bar{\epsilon}(n) - \mu \mathbf{u}(n) \nu^*(n) + \omega(n)$$

- Con μ suficientemente pequeño es posible resolver, utilizando el *método de promediación directa* y del análisis del LMS

$$\epsilon_0(n+1) = [\mathbf{I} - \mu \mathbf{R}] \epsilon_0(n) - \mu \mathbf{u}(n) \nu^*(n) + \omega(n)$$

donde $\epsilon_0(n)$ es la aproximación de pequeño μ de $\epsilon(n)$.

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del LMS ...

- En ese caso

$$\begin{aligned}\mathbf{K}_0(n+1) &= E[\boldsymbol{\epsilon}_0(n+1)\boldsymbol{\epsilon}_0^H(n+1)] \\ &= [\mathbf{I} - \mu\mathbf{R}]\mathbf{K}_0(n)[\mathbf{I} - \mu\mathbf{R}] + \mu\sigma_v^2\mathbf{R} + \mathbf{R}_\omega\end{aligned}$$

- Para obtener la *solución de estado estacionario*, para n suficientemente grande, consideramos $\mathbf{K}_0(n+1) = \mathbf{K}_0(n)$. Además, suponiendo que μ es pequeño como para eliminar el término $\mu^2\mathbf{R}\mathbf{K}_0(n)\mathbf{R}$ en comparación con $\mathbf{I}$, es posible obtener la aproximación

$$\mathbf{R}\mathbf{K}_0(n) + \mathbf{K}_0(n)\mathbf{R} \cong \mu\sigma_v^2\mathbf{R} + \frac{1}{\mu}\mathbf{R}_\omega$$

Seguimiento de sistemas variantes en el tiempo ...

Desviación media cuadrática del LMS

- Premultiplicando la ecuación anterior por $\mathbf{R}^{-1}$ y aplicando la traza del resultado,

$$\text{tr}[\mathbf{K}_0(n)] + \text{tr}[\mathbf{R}^{-1}\mathbf{K}_0(n)\mathbf{R}] \cong \mu M \sigma_\nu^2 + \frac{1}{\mu} \text{tr}[\mathbf{R}^{-1}\mathbf{R}_\omega]$$

- Como $\mathbf{K}_0(n)$ y $\mathbf{R}$ tienen las mismas dimensiones:

$$\text{tr}[\mathbf{R}^{-1}\mathbf{K}_0(n)\mathbf{R}] = \text{tr}[\mathbf{K}_0(n)\mathbf{R}\mathbf{R}^{-1}] = \text{tr}[\mathbf{K}_0(n)].$$

- Entonces,

$$\mathcal{D}(n) \cong E[\epsilon_0^H(n)\epsilon_0(n)] = \frac{\mu}{2} M \sigma_\nu^2 + \frac{1}{2\mu} \text{tr}[\mathbf{R}^{-1}\mathbf{R}_\omega]$$

donde: el 1er término es la varianza de estimación debido al *ruido de medición* $\nu(n)$ (varia linealmente con μ), y el 2do término es la varianza del *retardo debido al proceso de ruido* $\omega(n)$ (varia en forma inversa con μ).

Seguimiento de sistemas variantes en el tiempo ...

Desviación media cuadrática del LMS ...

- Si μ_{opt} es el valor óptimo del factor de convergencia para el cual la desviación media cuadrática alcanza el mínimo $\mathcal{D}_{min}$, es simple verificar que

$$\mu_{opt} \cong \frac{1}{\sigma_v \sqrt{M}} (tr[\mathbf{R}^{-1} \mathbf{R}_\omega])^{1/2}$$

$$\mathcal{D}_{min} \cong \sigma_v \sqrt{M} (tr[\mathbf{R}^{-1} \mathbf{R}_\omega])^{1/2}$$

Seguimiento de sistemas variantes en el tiempo ...

Desajuste del LMS

- En base a la traza de la *solución de estado estacionario*, es posible escribir

$$tr[\mathbf{R}\mathbf{K}_0(n)] + tr[\mathbf{K}_0(n)\mathbf{R}] \cong \mu\sigma_\nu^2 tr[\mathbf{R}] + \frac{1}{\mu} tr[\mathbf{R}_\omega]$$

- Teniendo en cuenta que la traza de $\mathbf{R}\mathbf{K}_0(n)$ y $\mathbf{K}_0(n)\mathbf{R}$ es igual, entonces usando la definición,

$$\mathcal{M}(n) \cong \frac{\mu}{2} tr[\mathbf{R}] + \frac{1}{2\mu\sigma_\nu^2} tr[\mathbf{R}_\omega]$$

donde, en este caso, el 1er término es el desajuste de *ruido* $\nu(n)$, y tiene una forma similar que para un ambiente estacionario. El 2do término es el desajuste del *retardo causado por* $\omega(n)$, el cual es representativo del contexto no estacionario.

Seguimiento de sistemas variantes en el tiempo ...

Desajuste del LMS ...

- El desajuste de ruido varia linealmente con μ mientras que el desajuste del retardo varía inversamente con μ . De esta forma, optimizando para un desajuste mínimo se obtiene

$$\mu_{opt} \cong \frac{1}{\sigma_v} \left(\frac{\text{tr}[\mathbf{R}_\omega]}{\text{tr}[\mathbf{R}]} \right)^{1/2}$$
$$\mathcal{M}_{min} \cong \frac{1}{\sigma_v} (\text{tr}[\mathbf{R}_\omega] \text{tr}[\mathbf{R}])^{1/2}$$

- Esto pone en evidencia que el μ_{opt} es diferente al obtenido con la desviación media cuadrática, ya que son medidas de desempeño diferentes.

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del RLS

- Teniendo en cuenta el mismo modelo de no estacionariedad que en el caso anterior, es posible tener en cuenta ahora el RLS aplicado a un filtro adaptativo FIR, dado por

$$\hat{\mathbf{w}}(n) = \hat{\mathbf{w}}(n-1) + \Phi^{-1}(n)\mathbf{u}(n)\xi^*(n)$$

donde $\Phi(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i)\mathbf{u}^H(i)$ y $\xi(n) = d(n) - \hat{\mathbf{w}}(n-1)\mathbf{u}(n)$

- Entonces, considerando que

$$\mathbf{w}_o(n) = a\mathbf{w}_o(n-1) + \boldsymbol{\omega}(n) \quad \text{y} \quad d(n) = \mathbf{w}_o^H(n-1)\mathbf{u}(n) + \nu(n)$$

la ecuación de adaptación del error en el vector de coeficientes para el RLS será

$$\bar{\boldsymbol{\epsilon}}(n) = [\mathbf{I} - \Phi^{-1}(n)\mathbf{u}(n)\mathbf{u}^H(n)]\bar{\boldsymbol{\epsilon}}(n-1) + \Phi^{-1}(n)\mathbf{u}(n)\nu^*(n) - (1-a)\mathbf{w}_o(n-1) + \boldsymbol{\omega}(n)$$

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del RLS ...

- Realizando una simplificación similar que en el caso del LMS, suponiendo α próximo a 1, esa ecuación se reduce a

$$\epsilon(n) = [\mathbf{I} - \Phi^{-1}(n)\mathbf{u}(n)\mathbf{u}^H(n)]\epsilon(n-1) - \Phi^{-1}(n)\mathbf{u}(n)\nu^*(n) + \omega(n)$$

- En este punto, es útil obtener una aproximación de la matriz $\Phi^{-1}(n)$ para permitir el análisis.

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del RLS ...

- Aplicando la esperanza en la expresión de la matriz $\Phi(n)$

$$\begin{aligned} E[\Phi(n)] &= \sum_{i=1}^n \lambda^{n-i} E[\mathbf{u}(i)\mathbf{u}^H(i)] = \sum_{i=1}^n \lambda^{n-i} \mathbf{R} \\ &= \mathbf{R}(1 + \lambda + \lambda^2 + \dots + \lambda^{n-1}) = \frac{\mathbf{R}}{1 - \lambda} \quad \text{para } n \text{ grande} \end{aligned}$$

donde se asume que ($\overline{\Phi}$ es una matriz perturbación Hermitiana)

$$\Phi(n) \cong \frac{\mathbf{R}}{1 - \lambda} + \overline{\Phi}, \quad \text{para } n \text{ grande}$$

Si se cumple $E[\|\overline{\Phi}\|^2] \ll E[\|\Phi\|^2]$ es posible introducir la aproximación (*no trivial*)

$$\Phi(n) \cong \frac{\mathbf{R}}{1 - \lambda} \quad \Phi^{-1}(n) \cong (1 - \lambda)\mathbf{R}^{-1}, \quad \text{para } n \text{ grande}$$

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del RLS ...

- Volviendo a la ecuación obtenida, y usando la aproximación anterior

$$\epsilon(n) \cong [\mathbf{I} - (1 - \lambda)\mathbf{R}\mathbf{u}(n)\mathbf{u}^H(n)]\epsilon(n-1) + (1 - \lambda)\mathbf{R}^{-1}\mathbf{u}(n)\nu^*(n) - \omega(n)$$

para n grande

- Típicamente λ es próximo a la unidad, de forma que $1 - \lambda$ tiene un valor pequeño. De esta forma, invocando el *método de promediación directa*

$$\epsilon_0(n) \cong \lambda\epsilon_0(n-1) + (1 - \lambda)\mathbf{R}^{-1}\mathbf{u}(n)\nu^*(n) - \omega(n)$$

para n grande

- Evaluando ahora la matriz correlación de $\epsilon(n)$

$$\mathbf{K}_0(n) \cong \lambda^2\mathbf{K}_0(n-1) + (1 - \lambda)^2\sigma_\nu^2\mathbf{R}^{-1} + \mathbf{R}_\omega$$

para n grande

Seguimiento de sistemas variantes en el tiempo ...

Desempeño de seguimiento del RLS ...

- Para obtener una *solución de estado estacionario*, para n suficientemente grande, hacemos $\mathbf{K}_0(n-1) = \mathbf{K}_0(n)$, tal que

$$(1 - \lambda^2)\mathbf{K}_0(n) \cong (1 - \lambda)^2\sigma_\nu^2\mathbf{R}^{-1} + \mathbf{R}_\omega$$

y usando para $\lambda \cong 1$ que $1 - \lambda^2 = (1 + \lambda)(1 - \lambda) \cong 2(1 - \lambda)$, es posible llegar finalmente a

$$\mathbf{K}_0(n) \cong \frac{(1 - \lambda)}{2}\sigma_\nu^2\mathbf{R}^{-1} + \frac{1}{2(1 - \lambda)}\mathbf{R}_\omega$$

Seguimiento de sistemas variantes en el tiempo ...

Desviación media cuadrática del RLS

- Aplicando la ecuación anterior a la definición de desviación media cuadrática se obtiene

$$\mathcal{D}(n) \cong \frac{(1 - \lambda)}{2} \sigma_\nu^2 \operatorname{tr}[\mathbf{R}^{-1}] + \frac{1}{2(1 - \lambda)} \operatorname{tr}[\mathbf{R}_\omega]$$

tal que, el 1er término es la varianza de estimación debida al **ruido** $\nu(n)$ y el 2do término es la varianza del **retardo debida al proceso de ruido** $\omega(n)$.

Estas dos contribuciones varían en proporción a $(1 - \lambda)$ y $(1 - \lambda)^{-1}$. El valor óptimo del factor de ponderación y la desviación media cuadrática mínima para el algoritmo RLS están dadas por

$$\lambda_{opt} \cong 1 - \frac{1}{\sigma_\nu} \left(\frac{\operatorname{tr}[\mathbf{R}_\omega]}{\operatorname{tr}[\mathbf{R}^{-1}]} \right)^{1/2} \quad \mathcal{D}_{min} \cong \sigma_\nu (\operatorname{tr}[\mathbf{R}^{-1}] \operatorname{tr}[\mathbf{R}_\omega])^{1/2}$$

Seguimiento de sistemas variantes en el tiempo ...

Desajuste del RLS ...

- Multiplicando la expresión obtenida para $\mathbf{K}_0(n)$ por $\mathbf{R}$, se tiene que

$$\mathbf{R}\mathbf{K}_0(n) \cong \frac{(1-\lambda)}{2}\sigma_\nu^2\mathbf{I} + \frac{1}{2(1-\lambda)}\mathbf{R}\mathbf{R}_\omega$$

y en base a la traza de esta ecuación

$$\text{tr}[\mathbf{R}\mathbf{K}_0(n)] \cong \frac{(1-\lambda)}{2}\sigma_\nu^2 M + \frac{1}{2(1-\lambda)} \text{tr}[\mathbf{R}\mathbf{R}_\omega]$$

- tal que aplicando la definición, el desajuste asociado al algoritmo RLS será

$$\mathcal{M}(n) \cong \frac{1-\lambda}{2}M + \frac{1}{2(1-\lambda)\sigma_\nu^2} \text{tr}[\mathbf{R}\mathbf{R}_\omega]$$

Seguimiento de sistemas variantes en el tiempo ...

Desajuste del RLS ...

- El 1er término representa el desajuste del algoritmo RLS debido a $\nu(n)$, que varía linealmente con $1 - \lambda$ y depende también de M .
- El 2do término representa el desajuste de retardo del algoritmo RLS debido al proceso de ruido $\omega(n)$. Este término varía inversamente con $1 - \lambda$.
- El valor óptimo del factor de ponderación exponencial y el valor mínimo del desajuste están dados por

$$\lambda_{opt} \cong 1 - \frac{1}{\sigma_\nu} \left(\frac{1}{M} \text{tr}[\mathbf{R}\mathbf{R}_\omega] \right)^{1/2}$$
$$\mathcal{M}_{min} \cong \frac{1}{\sigma_\nu} (M \text{tr}[\mathbf{R}\mathbf{R}_\omega])^{1/2}$$

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento

- Teniendo en cuenta que los algoritmos LMS y RLS se formulan de forma totalmente diferente, no es sorprendente que exhiban propiedades de convergencia diferentes y también propiedades de seguimiento diferentes.
- En el algoritmo RLS el vector de entrada está premultiplicado por una estimación de $\mathbf{R}^{-1}$, lo que indica la diferencia fundamental entre los algoritmos RLS y LMS.

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

- $(1 - \lambda)$ en el algoritmo RLS juega el papel de μ en el algoritmo LMS. Teniendo en cuenta esta analogía, pero además que λ es adimensional, en tanto que μ tiene dimensiones de potencia, se harán algunas consideraciones:
 - a) Para el algoritmo LMS definimos el *factor de convergencia normalizado*, dado por $\nu = \mu \sigma_u^2$ donde σ_u^2 es la varianza de la señal de entrada $u(n)$.
 - b) Para el algoritmo RLS definimos la *velocidad de olvido*, $\beta = 1 - \lambda$.

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

- Con el objetivo de realizar la comparación, consideraremos la relación entre la desviación media cuadrática obtenida para ambos métodos y también la relación entre sus desajustes, dados por

$$\frac{\mathcal{D}_{min}^{LMS}}{\mathcal{D}_{min}^{RLS}} \cong \left(\frac{M \operatorname{tr}[\mathbf{R}^{-1} \mathbf{R}_\omega]}{\operatorname{tr}[\mathbf{R}^{-1}] \operatorname{tr}[\mathbf{R}_\omega]} \right)^{1/2}$$
$$\frac{\mathcal{M}_{min}^{LMS}}{\mathcal{M}_{min}^{RLS}} \cong \left(\frac{\operatorname{tr}[\mathbf{R}] \operatorname{tr}[\mathbf{R}_\omega]}{M \operatorname{tr}[\mathbf{R} \mathbf{R}_\omega]} \right)^{1/2}$$

- Claramente, la comparación entre los algoritmos LMS y RLS sobre esta base es función de $\mathbf{R}$ y $\mathbf{R}_\omega$, de forma que será importante considerar algunos casos particulares.

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

Ejemplo 1: $R_\omega = \sigma_\omega^2 I$.

Consideremos el caso de un proceso de ruido $\omega(n)$ del modelo de primer orden de Markov originado de una fuente de ruido blanco de media cero y varianza σ_ω^2 . Su matriz correlación será

$$R_\omega = \sigma_\omega^2 I$$

Luego usando las relaciones anteriores es posible concluir que

$$\begin{aligned} \mathcal{D}_{min}^{LMS} &\cong \mathcal{D}_{min}^{RLS} \\ \mathcal{M}_{min}^{LMS} &\cong \mathcal{M}_{min}^{RLS} \end{aligned}$$

tal que el comportamiento para ese tipo de no estacionariedad es similar en ambos algoritmos.

En ese caso general, más allá de una convergencia inicial más rápida (transitorio), no es útil la mayor complejidad del RLS para seguimiento.

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

Ejemplo 2: $\mathbf{R}_\omega = c_1 \mathbf{R}$.

Se introduce la constante c_1 con dos objetivos:

1. Para tener en cuenta que el proceso de ruido $\omega(n)$ y $\mathbf{u}(n)$ el vector de entradas, se miden en unidades diferentes.
2. Para asegurar que el μ óptimo para el algoritmo LMS y el λ óptimo para el algoritmo RLS tengan valores equivalentes.

Los resultados de la comparación,

	$\mathbf{R}_\omega = c_1 \mathbf{R}$	$\mathbf{R}_\omega = c_2 \mathbf{R}^{-1}$
$\frac{\mathcal{D}_{min}^{LMS}}{\mathcal{D}_{min}^{RLS}}$	$\frac{M}{(tr[\mathbf{R}^{-1}] tr[\mathbf{R}])^{1/2}}$	$\frac{(M tr[\mathbf{R}^{-2}])^{1/2}}{tr[\mathbf{R}^{-1}]}$
$\frac{\mathcal{M}_{min}^{LMS}}{\mathcal{M}_{min}^{RLS}}$	$\frac{tr[\mathbf{R}]}{(M tr[\mathbf{R}^2])^{1/2}}$	$\frac{1}{M} (tr[\mathbf{R}] tr[\mathbf{R}^{-1}])^{1/2}$

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

Ejemplo 3: $R_\omega = c_2 R^{-1}$.

La constante c_2 de proporcionalidad es utilizada por las mismas razones que en el ejemplo anterior. Los resultados de la comparación se incluyeron en la tabla anterior.

Los resultados de la tabla muestran *simetría recíproca*.

	$R_\omega = c_1 R$	$R_\omega = c_2 R^{-1}$
$\frac{\mathcal{D}_{min}^{LMS}}{\mathcal{D}_{min}^{RLS}}$	$\frac{M}{(tr[\mathbf{R}^{-1}] tr[\mathbf{R}])^{1/2}}$	$\frac{(M tr[\mathbf{R}^{-2}])^{1/2}}{tr[\mathbf{R}^{-1}]}$
$\frac{\mathcal{M}_{min}^{LMS}}{\mathcal{M}_{min}^{RLS}}$	$\frac{tr[\mathbf{R}]}{(M tr[\mathbf{R}^2])^{1/2}}$	$\frac{1}{M} (tr[\mathbf{R}] tr[\mathbf{R}^{-1}])^{1/2}$

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

Los resultados de los términos en la antidiagonal de esa tabla conducen a la aplicación de la *desigualdad de Schwartz*, lo cual implica las siguientes cotas

$$\begin{aligned}\mathcal{M}_{min}^{LMS} &\leq \mathcal{M}_{min}^{RLS} && \text{para } \mathbf{R}_\omega = c_1 \mathbf{R} \\ \mathcal{D}_{min}^{RLS} &\leq \mathcal{D}_{min}^{LMS} && \text{para } \mathbf{R}_\omega = c_2 \mathbf{R}^{-1}\end{aligned}$$

lo que conduce a las siguientes proposiciones

1. Para $\mathbf{R}_\omega = c_1 \mathbf{R}$, el algoritmo LMS tiene mejor desempeño que el RLS, ya que produce el menor desajuste mínimo.
2. Para $\mathbf{R}_\omega = c_2 \mathbf{R}^{-1}$, el algoritmo RLS tiene mejor desempeño que el LMS ya que produce la menor desviación media cuadrática.

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

- No es posible ser tan conclusivos en relación a los términos de la diagonal de la tabla, aunque en función de la simetría recíproca comentada es posible establecer que si, para $\mathbf{R}_\omega = c_1 \mathbf{R}$, $\mathcal{D}_{min}^{LMS} \leq \mathcal{D}_{min}^{RLS}$, entonces es cierto que, para $\mathbf{R}_\omega = c_2 \mathbf{R}^{-1}$, $\mathcal{M}_{min}^{RLS} \leq \mathcal{M}_{min}^{LMS}$.
- Para ilustrar la validez de esta proposición consideraremos el caso especial de un filtro adaptativo de orden $M=2$, tal que

$$\mathbf{R} = \begin{bmatrix} r_{11} & r_{21} \\ r_{21} & r_{22} \end{bmatrix}$$

- Para ese caso particular

	$\mathbf{R}_\omega = c_1 \mathbf{R}$	$\mathbf{R}_\omega = c_2 \mathbf{R}^{-1}$
$\frac{\mathcal{D}_{min}^{LMS}}{\mathcal{D}_{min}^{RLS}}$	$\frac{2\sqrt{r_{11}r_{22}-r_{12}^2}}{r_{11}+r_{22}}$	$\frac{\sqrt{2(r_{11}^2+2r_{21}^2+r_{22}^2)}}{r_{11}+r_{22}}$
$\frac{\mathcal{M}_{min}^{LMS}}{\mathcal{M}_{min}^{RLS}}$	$\frac{r_{11}+r_{22}}{\sqrt{2(r_{11}^2+2r_{21}^2+r_{22}^2)}}$	$\frac{r_{11}+r_{22}}{2\sqrt{r_{11}r_{22}-r_{12}^2}}$

Seguimiento de sistemas variantes en el tiempo ...

Comparación de desempeños de seguimiento ...

Teniendo en cuenta que $(r_{11} - r_{22})^2 + (2r_{21})^2 \geq 0$, esta tabla permite establecer las siguientes conclusiones


1. Para $\mathbf{R}_\omega = c_1 \mathbf{R}$, el algoritmo LMS se desempeña mejor que el algoritmo RLS de forma que produce los menores valores de $\mathcal{D}_{min}$ y $\mathcal{M}_{min}$.
2. Para $\mathbf{R}_\omega = c_2 \mathbf{R}^{-1}$, el algoritmo RLS se desempeña mejor que el algoritmo LMS de forma que produce los menores valores de $\mathcal{D}_{min}$ y $\mathcal{M}_{min}$.

Estos dos últimos ejemplos muestran que los algoritmos LMS y RLS no tienen un completo dominio de buen desempeño en seguimiento.

Más bien, uno u otro algoritmo será preferido para el seguimiento en un ambiente no estacionario *dependiendo del contexto de variación dominante*.

Seguimiento de sistemas variantes en el tiempo ... Ajuste de los parámetros de adaptación

- Hasta ahora se ha estudiado características comparativas de los algoritmos LMS y RLS, excepto la cuestión de cómo **elegir sus parámetros de adaptación**.
- Estudiaremos un segundo nivel de adaptación, a través de un **esquema de aprendizaje dentro del aprendizaje**. Esto incorpora 2 mecanismos de control independientes:
 - a) El mecanismo de control principal, para controlar los ajustes del filtro FIR en el algoritmo tradicional.
 - b) El mecanismo de control secundario, para aplicar ajustes apropiados al parámetro de adaptación.



Seguimiento de sistemas variantes en el tiempo ... Ajuste de los parámetros de adaptación..

Dos enfoques para implementar el esquema de aprendizaje dentro del aprendizaje:

Escalamiento. El parámetro de adaptación es un factor de escala variable en el tiempo. Por ejemplo, en el algoritmo LMS, se usa $\mu(n+1)$ en lugar del valor fijo:

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \mu(n+1)(\mathbf{u}(n)e^*(n))$$

Vectorización. El parámetro de adaptación es un vector variable en el tiempo, cada elemento del cual está correlacionado con alguna característica del vector de datos de entrada $\mathbf{u}(n)$. Por ejemplo para el algoritmo LMS,

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \boldsymbol{\mu}(n+1) \circ [(\mathbf{u}(n)e^*(n))]$$

donde el operador $\circ[\cdot]$ es el producto de elemento por elemento, que involucra $\boldsymbol{\mu}(n+1)$ y $\mathbf{u}(n)$.

Seguimiento de sistemas variantes en el tiempo ... Ajuste de los parámetros de adaptación..

- En el esquema de escalamiento se asume el MSE de forma cuadrática, con su punto mínimo (óptimo de Wiener) que varía con el tiempo. Por otro lado, el esquema de vectorización tiene la ventaja que asume una superficie de MSE con diferentes curvaturas en distintas direcciones.
- Dada la complejidad del algoritmo RLS, utilizar un esquema como el de vectorización incrementaría el problema. Por esta razón, al trabajar con *big data* (datos cuyo volumen crece continuamente), la simplicidad es esencial, de ahí la necesidad de *optar por el algoritmo LMS como base para la modificación algorítmica*.
- En esa algorítmica se usará el factor de convergencia μ para el mecanismo de control principal y κ , para el mecanismo de control secundario.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo Delta-Barra-Delta incremental (IDBD)

- El algoritmo IDBD es un esquema de **meta-aprendizaje** incremental. Está compuesto de dos partes:
 1. La primera parte se basa en el algoritmo LMS, con el uso de un parámetro de tamaño de paso variable en el tiempo, usando el esquema de vectorización.
 2. La segunda parte está compuesta por 3 ecuaciones: dos implican el uso de parámetros relacionados con la memoria y la tercera es un parámetro de meta-aprendizaje que se ajusta manualmente.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD: Parte asociada al LMS

Siguiendo la forma tradicional del algoritmo LMS,

$$e(n) = d(n) - \sum_{i=0}^{M-1} \hat{w}_i^*(n) u(n-i) \quad \text{y} \quad \hat{w}_i(n+1) = \hat{w}_i(n) + \mu_i(n+1) u(n-i) e^*(n)$$

El parámetro de tamaño de paso variable en el tiempo se define por:

$$\mu_i(n) = \exp(\alpha_i(n))$$

donde $\alpha_i(n)$ es uno de los dos parámetros de memoria del algoritmo IDBD. Esta relación ofrece dos ventajas:

1. Garantiza que $\mu(n)$ sea positivo para todos los valores i y n , como debería ser para el descenso de gradiente estocástico.
2. Proporciona un mecanismo simple para producir pasos “geométricos” en $\alpha_i(n)$.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD: 2da parte

El mecanismo de control secundario, asociado a $\alpha_i(n)$ es

$$\alpha_i(n+1) = \alpha_i(n) + \kappa u(n-i)e^*(n)h_i(n), \quad i = 0, 1, \dots, M-1$$

donde κ es el tamaño de paso (constante positiva), o **tasa de meta-aprendizaje** en el algoritmo IDBD.

El nuevo parámetro $h_i(n)$, es el **segundo parámetro de memoria** del algoritmo IDBD, que se actualiza con

$$h_i(n+1) = (1 - \mu_i(n+1)|u(n-i)|^2)^+ h_i(n) + \mu_i(n+1)u(n-i)e^*(n)$$

donde $(x)^+ = \begin{cases} x, & \text{si } x > 0, \\ 0, & \text{en otro caso.} \end{cases}$

El parámetro de memoria $h_i(n)$, actúa como una muestra decreciente asociada a la suma acumulada de los cambios recientes realizados en $\hat{w}_i(n)$.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD: 2da parte ...

Interpretación del ajuste de $\alpha_i(n)$:

es posible considerar el producto $u(n-i)e^*(n)h_i(n)$ como la correlación entre dos términos:

1. El producto $u(n-i)e^*(n)$, que representa el **cambio incremental** en $\hat{w}_i(n)$.
2. El término $h_i(n)$, que representa una **traza acumulada** de los cambios en $\hat{w}_i(n)$.

En consecuencia, si esta correlación es positiva, entonces el efecto acumulativo de los ciclos de adaptación pasados resulta en un aumento en $\alpha_i(n)$.

Si, por otro lado, la correlación tiene un efecto negativo (opuesto), el resultado final es una disminución en $\alpha_i(n)$.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD: 2da parte ...

Interpretación del ajuste de $h_i(n)$.

$$h_i(n+1) = (1 - \mu_i(n+1)|u(n-i)|^2)^+ h_i(n) + \mu_i(n+1)u(n-i)e^*(n)$$

El primer término es de decaimiento porque $\mu_i(n+1)|u(n-i)|^2$ es una cantidad positiva pequeña o, de lo contrario, es cero.

El segundo término, cambia $h_i(n)$ en una cantidad igual al cambio incremental realizado en $\hat{w}_i(n)$.

Por lo tanto, concluimos que cualquier cambio realizado en $h_i(n)$ será incrementalmente pequeño en cada ciclo de adaptación.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD: desarrollo ...

En términos algorítmicos, se analizará la ecuación de ajuste de $\alpha_i(n)$, siguiendo similar metodología que para el LMS,

$$\alpha_i(n+1) = \alpha_i(n) - \frac{1}{2} \kappa \frac{\partial |e(n)|^2}{\partial \alpha_i}$$

Luego, por la regla de la cadena $\frac{\partial |e(n)|^2}{\partial \alpha_i} = \sum_{j=0}^{M-1} \frac{\partial |e(n)|^2}{\partial \hat{w}_j(n)} \frac{\partial \hat{w}_j(n)}{\partial \alpha_i}$

Con la suposición que el efecto principal de un cambio pequeño en α_i está centrado en $w_i(n)$, entonces $\partial \hat{w}_j(n) / \partial \alpha_i = 0, i \neq j$, y la anterior se reduce a

$$\frac{\partial |e(n)|^2}{\partial \alpha_i} = \frac{\partial |e(n)|^2}{\partial \hat{w}_i(n)} \frac{\partial \hat{w}_i(n)}{\partial \alpha_i} = (-2u(n-i)e^*(n))h_i(n)$$

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD: desarrollo ...

Para el 2do parámetro de memoria $h_i(n)$, se tiene que

$$\begin{aligned}h_i(n+1) &= \frac{\partial \hat{w}_i(n+1)}{\partial \alpha_i} = \frac{\partial}{\partial \alpha_i} (\hat{w}_i(n) + \mu_i(n+1)u(n-i)e^*(n)) \\&= h_i(n) + u(n-i) \frac{\partial}{\partial \alpha_i} (\mu_i(n+1)e^*(n))\end{aligned}$$

Usando la regla de derivación del producto y la definición de $\mu_i(n)$,

$$\frac{\partial}{\partial \alpha_i} (\mu_i(n+1)e^*(n)) = \mu_i(n+1)e^*(n) - \mu(n+1)u^*(n-i)h_i(n)$$

que reemplazada en la anterior conduce a la ecuación de ajuste de $h_i(n)$.

Seguimiento de sistemas variantes en el tiempo ...

Algoritmo IDBD

Parámetros:

M = número de coeficientes

$\mu_i(n)$ factor de convergencia primario (para $w_i(n)$)

κ factor de convergencia secundario (constante positiva pequeña)

Datos:

$\mathbf{u}(n)$ vector de entradas ($M \times 1$).

$d(n)$ respuesta deseada en el instante n .

Inicialización

$$\hat{w}_i(0) = 0$$

$$h_i(0) = 0$$

$$\mu_i(0) \cong 0.1/\lambda_{max}$$

Para cada n , $n = 1, 2, \dots$, calcular

$$e(n) = d(n) - \hat{\mathbf{w}}^H(n)\mathbf{u}(n)$$

Para $i = 0, \dots, M - 1$, calcular

$$\alpha_i(n+1) = \log(\mu_i(n)) + \kappa u(n-i)e^*(n)h_i(n)$$

$$\mu_i(n+1) = \exp(\alpha_i(n+1))$$

$$\hat{w}_i(n+1) = \hat{w}_i(n) + \mu_i(n+1)u(n-i)e^*(n)$$

$$h_i(n+1) = (1 - \mu_i(n+1)|u(n-i)|^2)^+ h_i(n) + \mu_i(n+1)u(n-i)e^*(n)$$

Tracking e implementación

Seguimiento de sistemas variantes en el tiempo

- Grado de no estacionariedad
- Criterios de seguimiento
- Desempeño de seguimiento en RLS y LMS
- Comparación de algoritmos LMS y RLS

Efectos de precisión finita

- Errores de cuantización en algoritmos LMS y RLS