

Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

Efectos de precisión finita

Seguimiento de sistemas variantes en el tiempo

- Grado de no estacionaridad
- Criterios de seguimiento
- Desempeño de seguimiento en LMS y RLS
- Comparación de algoritmos LMS y RLS

Efectos de precisión finita

- Errores de cuantización
- Análisis para el algoritmo LMS
- Análisis para el algoritmo RLS

Efectos de precisión finita

- La teoría de filtrado adaptativo discutida supone la utilización de un *modelo analógico* (o sea, de precisión infinita) para las muestras de los datos de entrada y los cálculos internos de los algoritmos.
- En una implementación digital de un algoritmo de filtrado adaptativo, los datos de entrada y los cálculos internos del algoritmo se realizan con *precisión finita*.
- El proceso de cuantización desvía el desempeño de la implementación digital de la versión teórica, y está influenciado por:
 - a) El diseño del algoritmo de filtrado adaptativo adoptado.
 - b) La dispersión de autovalores de la matriz correlación de entrada.
 - c) La forma de realizar los cálculos numéricos (punto fijo o punto flotante).


Efectos de precisión finita ...

- Es importante conocer las *propiedades numéricas de los algoritmos de filtrado adaptativo*, dado que esto ayudará en la búsqueda de cumplimiento de especificaciones de diseño.
- Además, el costo de la implementación digital de un algoritmo está influenciado por el *número de bits* (o sea, la precisión) disponible para efectuar los cálculos numéricos asociados al algoritmo.
- Genéricamente, el costo de la *implementación aumenta con el número de bits* empleados.

Efectos de precisión finita ...

Errores de cuantización: conversión analógica - digital

- Suponiendo los datos disponibles en forma analógica, es posible utilizar un conversor A/D para obtener su representación numérica.
- Suponemos que el proceso de cuantización tiene un *tamaño de paso uniforme δ* y un conjunto de *niveles de cuantización*, posicionados en $0, \pm\delta, \pm2\delta, \dots$.
- Consideramos una muestra particular en la entrada del cuantizador, con una amplitud en el rango $i\delta - (\delta/2)$ a $i\delta + (\delta/2)$, donde i es un entero (positivo o negativo, incluyendo el cero) y $i\delta$ define la *salida del cuantizador*.



Efectos de precisión finita ...

Errores de cuantización: conversión analógica – digital ...

- El proceso de cuantización introduce una *región de incertidumbre* de ancho δ , centrada en $i\delta$.
- Si η es el *error de cuantización*, la salida del cuantizador es $i\delta + \eta$, donde η está acotado entre $-(\delta/2) \leq \eta \leq (\delta/2)$.
- Cuando la cuantización es suficientemente fina (o sea, el número de niveles de cuantización es mayor a 64) y si el espectro de la señal es suficientemente rico, la distorsión producida por el proceso de cuantización puede *modelarse como una fuente independiente de ruido blanco* de media cero y varianza determinada por el tamaño del paso del cuantizador δ .

Efectos de precisión finita ...

Errores de cuantización: conversión analógica – digital ...

- Si el error de cuantización η está *uniformemente distribuido* en un rango dado por $-\delta/2 \leq \eta \leq \delta/2$, la *varianza del error de cuantización* será

$$\sigma^2 = \int_{-\delta/2}^{\delta/2} \frac{1}{\delta} \eta^2 d\eta = \frac{\delta^2}{12}$$

- Suponemos que la entrada al cuantizador está apropiadamente escalada tal que esté dentro del intervalo $(-1, +1]$, con cada nivel de cuantización representado por B bits más signo, el *tamaño del paso del cuantizador* es

$$\delta = 2^{-B}$$

- La *varianza del error de cuantización* resultante de la representación digital de los datos analógicos es

$$\sigma^2 = \frac{2^{-2B}}{12}$$

Efectos de precisión finita

Errores de cuantización: aritmética de longitud finita de palabra

- Los *cálculos aritméticos internos* en una máquina digital se almacenan comúnmente con una *longitud de palabra finita*.
- Suponiendo que no existe overflow durante el transcurso de un cálculo, las *sumas no introducen error* (si se utiliza aritmética de punto fijo), mientras que *cada multiplicación introduce un error* después que el producto ha sido truncado.
- Los errores aritméticos de longitud finita de palabra pueden ser totalmente diferentes a los de conversión AD. Los errores de aritmética de longitud finita de palabra pueden tener *media no nula* (por redondeo o truncamiento de la salida de un multiplicador) para alcanzar la longitud de palabra preestablecida.

Efectos de precisión finita

Errores de cuantización: aritmética de longitud finita de palabra

- La presencia de aritmética de longitud finita de palabra introduce un problema serio en la implementación digital de un filtro adaptativo, particularmente cuando los *coeficientes del filtro se adaptan en forma continua*.
- La versión digital del filtro exhibe una respuesta específica o *propagación de tales errores*, haciendo que el desempeño se desvíe de la forma ideal (de precisión infinita).
- Además, es posible que la *desviación sea de naturaleza catastrófica* en el sentido que los errores resultantes del uso de aritmética de precisión finita se acumulen sin límite.

Efectos de precisión finita


Errores de cuantización: aritmética de longitud finita de palabra

- Si tal situación persiste el filtro entrará en una condición de saturación (overflow) y el algoritmo se comportará en forma *numéricamente inestable*. Un filtro adaptativo se dice *numéricamente estable* si la utilización de aritmética de precisión finita resulta en *desviaciones acotadas* de la forma de precisión infinita.
- *La estabilidad numérica es una característica inherente al filtro adaptativo*. Si un filtro adaptativo es numéricamente estable, entonces incrementar el número de bits no cambiará la condición de estabilidad de la implementación.
- Otro aspecto de un filtro adaptativo es la *precisión numérica*. Está determinada por el número de bits utilizados para implementar los cálculos internos. Cuanto mayor es el número de bits usados, menor será la desviación del desempeño ideal y más precisa será entonces la implementación digital del filtro.
- En términos prácticos es *pertinente hablar de precisión numérica de un filtro adaptativo si es numéricamente estable*.

Efectos de precisión finita

Algoritmo LMS

- Para simplificar se supondrá que la entrada y en consecuencia los coeficientes del filtro son *reales*.



Q representa un cuantizador que introduce error de redondeo.

Efectos de precisión finita

Algoritmo LMS ...

Es posible describir las relaciones entrada - salida de los cuantizadores como sigue:

1. Para el cuantizador de la entrada: $\mathbf{u}_q(n) = Q[\mathbf{u}(n)] = \mathbf{u}(n) + \boldsymbol{\eta}_u(n)$
donde $\boldsymbol{\eta}_u(n)$ es el vector de *error de cuantización de la entrada*.
2. Para el cuantizador de la $d(n)$: $d_q(n) = Q[d(n)] = d(n) + \eta_d(n)$
donde $\eta_d(n)$ es el vector de *error de cuantización de la respuesta deseada*.
3. Para el cuantizador de los coeficientes: $\hat{\mathbf{w}}_q(n) = Q[\hat{\mathbf{w}}(n)] = \hat{\mathbf{w}}(n) + \Delta\hat{\mathbf{w}}(n)$
donde $\Delta\hat{\mathbf{w}}(n)$ es el vector de *error de cuantización de los coeficientes*.
4. Para el cuantizador de la salida del filtro FIR se tiene que
$$\mathbf{y}_q(n) = Q[\mathbf{u}_q^T(n)\hat{\mathbf{w}}_q(n)] = \mathbf{u}_q^T(n)\hat{\mathbf{w}}_q(n) + \eta_y(n)$$
donde $\eta_y(n)$ es el vector de *error de cuantización de la salida del filtro*.

Efectos de precisión finita

Algoritmo LMS ...

- El algoritmo LMS de precisión finita se describe por

$$\begin{aligned}e_q(n) &= d_q(n) - y_q(n) \\ \hat{\mathbf{w}}_q(n+1) &= \hat{\mathbf{w}}_q(n) + Q[\mu e_q(n) \mathbf{u}_q(n)]\end{aligned}$$

- a) El producto $\mu e_q(n) \mathbf{u}_q(n)$ representa una versión escalada de la estimación del vector gradiente, está cuantizado *antes* de la suma al vector de coeficientes.
- b) Debido a restricciones de hardware, esta forma de implementación digital es preferible antes que el método de operar con el acumulador de coeficientes en precisión doble y luego la cuantización del mismo en precisión simple.

Efectos de precisión finita

Algoritmo LMS ...

- En el análisis estadístico de precisión finita es posible realizar las siguientes suposiciones:
 1. La entrada está escalada apropiadamente para *prevenir overflow* de los elementos de $\hat{w}_q(n)$ y la salida cuantizada $y_q(n)$, durante la operación del filtro.
 2. Cada muestra se representa por B_D bits más signo, y cada coeficiente se representa por B_W bits más signo. Así, el error de cuantización asociado con un número de B_D bits más signo, tiene como varianza

$$\sigma_D^2 = \frac{2^{-2B_D}}{12}$$

y en forma similar, el error de cuantización asociado a un número de B_W bits más signo tiene como varianza

$$\sigma_W^2 = \frac{2^{-2B_W}}{12}$$

Efectos de precisión finita

Algoritmo LMS ...

3. Los elementos de $\eta_u(n)$ y $\eta_d(n)$ son *ruido blanco*, independientes de las respectivas señales y entre sí. Además tienen media cero y varianza σ_D^2 .
4. $\eta_y(n)$ es una secuencia de ruido blanco, independiente de las señales de entrada y otros ruidos de cuantización. Tiene media cero y varianza $c\sigma_D^2$, donde c es una constante que depende como se calcule $\mathbf{u}_q^T(n)\hat{\mathbf{w}}_q(n)$:
 - Si los productos escalares individuales de $\mathbf{u}_q^T(n)\hat{\mathbf{w}}_q(n)$ se calculan sin cuantización, luego se suman y el resultado final se cuantiza con B_D bits más signo, entonces: $c = 1$ y $\eta_y(n) = \sigma_D^2$.
 - Si los productos escalares individuales de $\mathbf{u}_q^T(n)\hat{\mathbf{w}}_q(n)$ se cuantizan y luego se suman, entonces: $c = M$ y $\eta_y(n) = M\sigma_D^2$, donde M es el orden del filtro adaptativo.
5. Se asumirá la teoría de independencia del LMS con precisión infinita.

Efectos de precisión finita

Algoritmo LMS: MSE de salida

- El *error total de salida* es igual a

$$\begin{aligned}e_{total}(n) &= d(n) - y_q(n) \\ &= d(n) - \mathbf{u}_q^T(n) \hat{\mathbf{w}}_q(n) - \eta_y(n)\end{aligned}$$

- Sustituyendo la descripción de los vectores cuantizados, e ignorando términos de error de cuantización mayores de primer orden, se tiene que

$$e_{total}(n) = \underbrace{[d(n) - \mathbf{u}^T(n) \hat{\mathbf{w}}(n)]}_{\text{LMS precisión infinita}} - \underbrace{[\Delta \hat{\mathbf{w}}^T(n) \mathbf{u}(n) + \boldsymbol{\eta}_u^T(n) \hat{\mathbf{w}}(n) - \eta_y(n)]}_{\text{errores de cuantización}}$$

Efectos de precisión finita

Algoritmo LMS: MSE de salida ...

- Con las suposiciones anteriores, y μ suficientemente pequeño, el *error medio cuadrático (MSE) total* producido por el algoritmo de precisión finita tiene la siguiente forma de estado estacionario

$$E[e_{total}^2(n)] = \underbrace{J_{min}(1 + \mathcal{M})}_{\text{MSE precisión infinita}} + \underbrace{\xi_1(\sigma_w^2, \mu)}_{\text{debido a } \Delta \hat{\mathbf{w}}} + \underbrace{\xi_2(\sigma_D^2)}_{\text{debido a } \boldsymbol{\eta}_u(n) \text{ y } \eta_y(n)}$$

donde

J_{min} es el *MMSE* del filtro de Wiener óptimo y $\mathcal{M}$ es el *desajuste* del algoritmo LMS de precisión infinita.

$\xi_1(\sigma_w^2, \mu)$ es *inversamente proporcional al factor de convergencia* μ .

$\xi_2(\sigma_D^2)$ es básicamente *independiente de* μ .

Efectos de precisión finita

Algoritmo LMS: Desviaciones durante la convergencia

- Durante el período de convergencia (transitorio) la situación es compleja.
- Las propiedades del transitorio de adaptación pueden analizarse a través de una ecuación general del desajuste de los coeficientes ó *perturbación* con respecto a la solución obtenida con el algoritmo de precisión infinita.
- El desajuste de los coeficientes se define por

$$\mathcal{W}(n) = E[\Delta\hat{\mathbf{w}}^T(n)\Delta\hat{\mathbf{w}}(n)]$$

donde: el vector de error de los coeficientes es $\Delta\hat{\mathbf{w}}(n) = \hat{\mathbf{w}}_q(n) - \hat{\mathbf{w}}(n)$, con $\hat{\mathbf{w}}_q(n)$ y $\hat{\mathbf{w}}(n)$ los coeficientes de precisión finita e infinita, obtenidos con el LMS.

- Para determinar $\mathcal{W}(n)$, la ecuación de adaptación se puede escribir como

$$\hat{\mathbf{w}}_q(n+1) = \hat{\mathbf{w}}_q(n) + \mu e_q(n)\mathbf{u}_q(n) + \boldsymbol{\eta}_w(n)$$

donde $\boldsymbol{\eta}_w(n)$ es el *vector de error de cuantización del gradiente*, resultante de la cuantización de $\mu e_q(n)\mathbf{u}_q(n)$. Las componentes de $\boldsymbol{\eta}_w(n)$ se suponen no correlacionadas en tiempo y entre sí y con varianza σ_w^2 .

Efectos de precisión finita

Algoritmo LMS: Desviaciones durante la convergencia

- Utilizando la transformación de coordenadas típica de análisis a $\hat{w}_q$, las características del vector de desajuste $\mathcal{W}(n)$ durante la adaptación y el estado estacionario pueden resumirse en:
 1. Los *coeficientes en el algoritmo LMS son los más sensibles* de todos los parámetros a la cuantización. Para el caso de *datos de entrada no correlacionados*, la varianza σ_w^2 es proporcional a $\frac{1}{r(0)\mu}$. Para el caso de *datos de entrada correlacionados*, la varianza σ_w^2 es proporcional a $\frac{1}{\lambda_{min}\mu}$.
 2. Para datos de entrada no correlacionados, las constantes de tiempo de adaptación del vector de desajuste $\mathcal{W}(n)$ son fuertemente dependientes de μ .
 3. Para datos de entrada correlacionados, las constantes de tiempo de adaptación del vector de desajuste $\mathcal{W}(n)$ son fuertemente dependientes de la interacción entre μ y λ_{min} .

Efectos de precisión finita

Algoritmo LMS con pérdidas

- Para hacer más robusta la implementación digital del algoritmo LMS es posible utilizar una técnica denominada *pérdidas* (leakage).
- Básicamente, el leakage evita la ocurrencia de overflow en un contexto de precisión finita introduciendo un compromiso entre minimizar el MSE y limitar la energía de la respuesta impulsiva del filtro adaptativo.
- Para el algoritmo LMS *leaky* (con pérdidas)

$$J(n) = e^2(n) + \alpha \|\hat{\mathbf{w}}(n)\|^2$$

donde α es un parámetro positivo de control. Para datos reales la ecuación de adaptación será

$$\hat{\mathbf{w}}(n+1) = (1 - \mu\alpha)\hat{\mathbf{w}}(n) + \mu e(n)\mathbf{u}(n)$$

donde $0 \leq \alpha < \frac{1}{\mu}$.

- La inclusión $(1 - \mu\alpha)$ es equivalente de sumar a la entrada $u(n)$ una secuencia de ruido blanco de media cero y varianza α .

Efectos de precisión finita

Algoritmo LMS: Fenómeno de cerrojo (stalling)

- Este fenómeno ocurre cuando la estimación del gradiente no es suficientemente ruidosa. Específicamente, una implementación digital del algoritmo LMS *para de adaptar* siempre que $\mu e_q(n)u_q(n-i)$ es menor en magnitud que el *bit menos significativo* (LSB) del coeficiente,

$$|\mu e_q(n_0)u_q(n_0-i)| \leq LSB$$

donde n_0 es el instante en el cual el i -ésimo coeficiente deja de adaptar.

- Suponiendo que esta condición es satisfecha, es posible aproximar, $u_q(n_0-i)$ por su valor *rms*, A_{rms} . Usando este valor la adaptación cesa en

$$|e_q(n)| \leq \frac{LSB}{\mu A_{rms}} = e_D(\mu)$$

que se denomina *error digital residual*.

Efectos de precisión finita

Algoritmo LMS: Fenómeno de cerrojo

- Para evitar el fenómeno de cerrojo debido a la implementación digital, $e_D(\mu)$ debe hacerse lo más pequeño posible, lo que puede satisfacerse de dos formas:
 1. Reducir el valor del bit menos significativo (LSB) (cantidad suficientemente grande de bits).
 2. Incrementar el factor de convergencia μ tanto cuanto sea posible.

Efectos de precisión finita


Algoritmo LMS: Deriva de parámetros

- Ciertos tipos de señales de entrada pueden provocar una *deriva de parámetros (coeficientes del filtro adaptativo)*. Es decir, las estimaciones en el algoritmo LMS pueden alcanzar valores arbitrariamente grandes, a pesar de que las entradas, las perturbaciones y los errores de estimación estén acotados.
- Si bien este comportamiento no acotado puede resultar inesperado, *es posible que las estimaciones converjan a infinito, mientras que todas las señales observables en el algoritmo convergen a cero*.
- La deriva de parámetros en el algoritmo LMS puede considerarse una *forma oculta de inestabilidad*, ya que los coeficientes representan variables internas del algoritmo. Por lo tanto, puede generar nuevos problemas numéricos y una mayor sensibilidad a las perturbaciones no modeladas.

Efectos de precisión finita

Algoritmo LMS: Deriva de parámetros

Para comprender mejor la problemática de la deriva de parámetros, es necesario introducir una clasificación que relaciona la entrada al filtro adaptativo y el *espacio de parámetros*.



Efectos de precisión finita

Algoritmo LMS: Deriva de parámetros ...

- En la discusión sobre el problema de la deriva de parámetros en el algoritmo LMS, observamos que, en el caso de *excitaciones acotadas*, y para subespacios persistentemente excitados, las *estimaciones de parámetros obtenidas mediante el algoritmo LMS también están acotadas*.
- Sin embargo, en los casos de *excitación decreciente o de otro tipo, puede producirse una deriva de parámetros*.
- Una forma común de contrarrestar este problema es introducir un factor de fuga en la ecuación de actualización de los pesos del algoritmo LMS. Este es otro motivo para *utilizar la versión del algoritmo LMS con pérdidas*.

Efectos de precisión finita

Algoritmo RLS

- El RLS ofrece una alternativa al LMS. Está caracterizado por una velocidad de convergencia rápida y es relativamente insensible a la dispersión de autovalores de $\mathbf{R}(n)$, y tiene un desajuste acotado (nulo para un ambiente estacionario sin perturbaciones).
- Además, a pesar que es computacionalmente más complejo $O(M^2)$, la formulación y la implementación del algoritmo RLS es relativamente simple.
- Sin embargo, existe un problema de inestabilidad numérica a ser considerado cuando se implementa este algoritmo con aritmética de precisión finita.

Efectos de precisión finita

Algoritmo RLS

- La *inestabilidad numérica* ó *divergencia explosiva* del algoritmo RLS es de la misma naturaleza que la experimentada por el filtro Kalman.
- El problema se asocia a que $P(n)$ se calcula como la diferencia entre dos matrices definidas no negativas. La divergencia explosiva del algoritmo ocurre cuando esa matriz pierde la propiedad de ser positiva definida o Hermitiana simétrica.

Efectos de precisión finita

Algoritmo RLS

- Una solución eficiente que mantiene la simetría de $\mathbf{P}(n)$ se muestra en la tabla.

Inicialización

$$\mathbf{P}(0) = \delta^{-1} \mathbf{I}, \delta \text{ una constante positiva pequeña.}$$

$$\hat{\mathbf{w}}(0) = \mathbf{0}$$

Para cada n , $n = 1, 2, \dots$, calcular

$$\boldsymbol{\pi}(n) = \mathbf{P}(n-1) \mathbf{u}(n)$$

$$r(n) = \frac{1}{\lambda + \mathbf{u}^H(n) \boldsymbol{\pi}(n)}$$

$$\mathbf{k}(n) = r(n) \boldsymbol{\pi}(n)$$

$$\xi(n) = d(n) - \hat{\mathbf{w}}^H(n-1) \mathbf{u}(n)$$

$$\hat{\mathbf{w}}(n) = \hat{\mathbf{w}}(n-1) + \mathbf{k}(n) \xi^*(n)$$

$$\mathbf{P}(n) = \text{Tri}\{\lambda^{-1} [\mathbf{P}(n-1) - r(n) \boldsymbol{\pi}(n)]\}$$

- La eficiencia de este algoritmo se logra porque calcula solo la parte triangular inferior/superior de $\mathbf{P}(n)$, definida por el operador $\text{Tri}\{\cdot\}$ y luego completa el resto de la matriz para preservar la simetría.

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- De acuerdo al algoritmo de la tabla anterior, las ecuaciones asociadas a cálculo de $\mathbf{P}(n)$ son

$$\begin{aligned}\boldsymbol{\pi}(n) &= \mathbf{P}(n-1)\mathbf{u}(n) \\ r(n) &= \frac{1}{\lambda + \mathbf{u}^H(n)\boldsymbol{\pi}(n)} \\ \mathbf{k}(n) &= r(n)\boldsymbol{\pi}(n) \\ \mathbf{P}(n) &= \text{Tri}\{\lambda^{-1}[\mathbf{P}(n-1) - r(n)\boldsymbol{\pi}(n)]\}\end{aligned}$$

- Consideremos la propagación de un *único error de cuantización* en el instante $n-1$ hacia los cálculos siguientes y suponemos que no existen otros errores de cuantización. En particular, es posible modelar esto como

$$\mathbf{P}_q(n-1) = \mathbf{P}(n-1) + \boldsymbol{\eta}_p(n-1)$$

donde $\boldsymbol{\eta}_p(n-1)$ es la *matriz de error* asociada a la cuantización de $\mathbf{P}(n-1)$.

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- y además $\pi_q(n) = \pi(n) + \eta_p(n-1)\mathbf{u}(n)$

es el valor cuantizado de $\pi(n)$. Si $r_q(n)$ es el valor cuantizado de $r(n)$, usando la definición de $r(n)$ es posible escribir

$$\begin{aligned} r_q(n) &= \frac{1}{\lambda + \mathbf{u}^H(n)\pi_q(n)} \\ &= \frac{1}{\lambda + \mathbf{u}^H(n)\pi(n) + \mathbf{u}^H(n)\eta_p(n-1)\mathbf{u}(n)} \\ &= \frac{1}{\lambda + \mathbf{u}^H(n)\pi(n)} \left(1 + \frac{\mathbf{u}^H(n)\eta_p(n-1)\mathbf{u}(n)}{\lambda + \mathbf{u}^H(n)\pi(n)} \right)^{-1} \\ &= \frac{1}{\lambda + \mathbf{u}^H(n)\pi(n)} - \frac{\mathbf{u}^H(n)\eta_p(n-1)\mathbf{u}(n)}{(\lambda + \mathbf{u}^H(n)\pi(n))^2} + O(\eta_p^2) \\ &= r(n) - \frac{\mathbf{u}^H(n)\eta_p(n-1)\mathbf{u}(n)}{(\lambda + \mathbf{u}^H(n)\pi(n))^2} + O(\eta_p^2) \end{aligned}$$

donde $O(\eta_p^2)$ es el orden de magnitud $\|\eta_p\|^2$.

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- En una situación práctica, la cantidad escalar $r(n)$ de precisión infinita es *no negativa* y toma valores entre cero y $1/\lambda$.
- Por otro lado, si $\mathbf{u}^H(n)\boldsymbol{\pi}(n)$ es pequeño comparado con λ ($\lambda \ll 1$), entonces de acuerdo a las ecuaciones anteriores es posible que en un contexto de precisión finita $r_q(n)$ tome valores *negativos* mayores que $1/\lambda$. Cuando esto sucede, el algoritmo RLS *podría exhibir divergencia explosiva*.
- El valor cuantizado del vector de ganancia $\mathbf{k}(n)$ puede escribirse como

$$\mathbf{k}_q(n) = r_q(n)\boldsymbol{\pi}_q(n) = \mathbf{k}(n) + \boldsymbol{\eta}_k(n)$$

donde $\boldsymbol{\eta}_k(n)$ es el *error de cuantización del vector ganancia*, definido por

$$\boldsymbol{\eta}_k(n) = r(n)(\mathbf{I} - \mathbf{k}(n)\mathbf{u}^H(n))\boldsymbol{\eta}_p(n-1)\mathbf{u}(n) + O(\boldsymbol{\eta}_p^2)$$

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- Finalmente, usando la expresión de $r_q(n)$ anterior, es posible obtener el error de cuantización obtenido al calcular $P(n)$,

$$\boldsymbol{\eta}_p(n) = \lambda^{-1}(\mathbf{I} - \mathbf{k}(n)\mathbf{u}^H(n))\boldsymbol{\eta}_p(n-1)(\mathbf{I} - \mathbf{k}(n)\mathbf{u}^H(n))^H$$

donde se ha despreciado el término $O(\boldsymbol{\eta}_p^2)$.

- Por esta expresión, si es posible asumir que $\boldsymbol{\eta}_p^H(n-1) = \boldsymbol{\eta}_p(n-1)$, entonces el algoritmo anterior conserva la propiedad de simetría, o lo que es lo mismo, es estable numéricamente.
- Esa ecuación define el *mecanismo de propagación del error* para el RLS sobre la base de un único error de cuantización en $P(n-1)$. La matriz $\mathbf{I} - \mathbf{k}(n)\mathbf{u}^H(n)$ describe como se propaga el error de cuantización $\boldsymbol{\eta}_p(n-1)$.

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- Usando la definición original del vector ganancia se tiene que $\mathbf{k}(n) = \Phi^{-1}(n)\mathbf{u}(n)$ y es posible escribir

$$\mathbf{I} - \mathbf{k}(n)\mathbf{u}^H(n) = \mathbf{I} - \Phi^{-1}(n)\mathbf{u}(n)\mathbf{u}^H(n)$$

- Por otro lado, teniendo en cuenta además que $\Phi(n) = \lambda\Phi(n-1) + \mathbf{u}(n)\mathbf{u}^H(n)$, que multiplicada por $\Phi^{-1}(n)$ y reordenando permite obtener

$$\mathbf{I} - \Phi^{-1}(n)\mathbf{u}(n)\mathbf{u}^H(n) = \lambda\Phi^{-1}(n)\Phi(n-1)$$

Comparando estas dos ecuaciones, es posible deducir que

$$\mathbf{I} - \mathbf{k}(n)\mathbf{u}^H(n) = \lambda\Phi^{-1}(n)\Phi(n-1)$$

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- Considerando el efecto del error de cuantización $\boldsymbol{\eta}_p(n_0)$ inducido en el instante $n_0 \leq n$, cuando se utiliza el RLS de la tabla y de acuerdo al modelo de propagación del error, se tiene que

$$\boldsymbol{\eta}_p(n) = \lambda^{-(n-n_0)} \boldsymbol{\varphi}(n, n_0) \boldsymbol{\eta}_p(n_0) \boldsymbol{\varphi}^H(n, n_0), \quad n \geq n_0$$

donde $\boldsymbol{\varphi}(n, n_0)$ es una *matriz de transición* definida por

$$\boldsymbol{\varphi}(n, n_0) = (\mathbf{I} - \mathbf{k}(n) \mathbf{u}^H(n)) \cdots (\mathbf{I} - \mathbf{k}(n_0 + 1) \mathbf{u}^H(n_0 + 1))$$

de donde es posible obtener

$$\boldsymbol{\varphi}(n, n_0) = \lambda^{(n-n_0)} \boldsymbol{\Phi}^{-1}(n) \boldsymbol{\Phi}(n_0)$$

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- En base a $\Phi(n) = \sum_{i=1}^n \lambda^{n-i} \mathbf{u}(i) \mathbf{u}^H(i)$, $\mathbf{u}(n)$ se dice de *excitación persistente uniforme* si, para n grande, existe algún $a > 0$ y $n > 0$ tal que

$$\Phi(n) \geq a\mathbf{I}, \quad \text{para } n \geq N$$

lo que es equivalente a decir que $\Phi(n)$ es positiva definida.

- La condición de excitación persistente no solo garantiza la positividad de $\Phi(n)$ sino también que la norma de la matriz está uniformemente acotada para $n \geq N$,

$$\|\Phi^{-1}(n)\| \leq \frac{1}{a}, \quad \text{para } n \geq N$$

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- Volviendo a $\varphi(n, n_0)$, y como $\|AB\| \leq \|A\|\|B\|$, se tiene que

$$\begin{aligned}\|\varphi(n, n_0)\| &\leq \lambda^{(n-n_0)} \|\Phi^{-1}(n)\| \|\Phi(n_0)\| \\ &\leq \frac{\lambda^{(n-n_0)}}{a} \|\Phi^{-1}(n)\|\end{aligned}$$

- Finalmente, usando la ecuación de propagación del error, es posible usar la norma de $\eta_p(n)$ como

$$\|\eta_p(n)\| \leq \lambda^{-(n-n_0)} \|\varphi(n, n_0)\| \|\eta_p(n-1)\| \|\varphi^H(n, n_0)\|$$

la que puede reescribirse como

$$\|\eta_p(n)\| \leq \lambda^{-(n-n_0)} M, \quad n \geq n_0$$

donde M es un número positivo definido por $M = \frac{1}{a^2} \|\Phi(n_0)\|^2 \|\eta_p(n-1)\|$

Efectos de precisión finita

Algoritmo RLS: Modelo de propagación del error ...

- La ecuación anterior determina que el RLS de la tabla es *exponencialmente estable*, ya que un único error de cuantización $\eta_p(n_0)$ en la estimación de $P(n_0)$ decae exponencialmente con $\lambda < 1$ (o sea tiene memoria finita).
- Sin embargo, la propagación de error de propagación único para el caso de memoria creciente (o sea $\lambda = 1$) *no es contractiva*.
- La razón de esto último es que cuando $\lambda = 1$, ni $\varphi(n, n_0) \leq \mathbf{I}$, ni $\|\varphi(n, n_0)\| \leq 1$ se mantienen, aún si $u(n)$ es de excitación persistente.
- En consecuencia, la acumulación de errores numéricos puede causar que el algoritmo se haga inestable.

Efectos de precisión finita

Algoritmo RLS: Fenómeno de cerrojo

- En forma similar al caso del algoritmo LMS, una segunda forma de divergencia, denominada como *fenómeno de cerrojo*, ocurre cuando los coeficientes del algoritmo RLS dejan de adaptar.
- En particular, esto ocurre cuando los elementos cuantizados de $P(n)$ se vuelven muy pequeños, tal que la multiplicación por $P(n)$ es equivalente a la multiplicación por una matriz cero.
- Claramente, este fenómeno es independiente de la forma de implementación del algoritmo RLS.

Efectos de precisión finita

Algoritmo RLS: Fenómeno de cerrojo ...

- El fenómeno de cerrojo está directamente relacionado con λ y σ_u^2 .
- Suponiendo que λ es próximo a 1, ya se discutió que

$$E[\Phi(n)] \cong \frac{\mathbf{R}}{1 - \lambda}, \quad n \text{ grande}$$

entonces

$$E[\mathbf{P}(n)] = E[\Phi^{-1}(n)] \cong (E[\Phi(n)])^{-1}$$

de donde

$$E[\mathbf{P}(n)] \cong (1 - \lambda)\mathbf{R}^{-1}$$

Efectos de precisión finita

Algoritmo RLS: Fenómeno de cerrojo ...

- Si $u(n)$ es ESA, es posible definir la *matriz correlación normalizada* $\mathcal{R}$, con elementos en la diagonal iguales a 1 y elementos fuera de la diagonal menores que 1 y σ_u^2 la varianza, donde

$$E[\mathbf{P}(n)] \cong \left(\frac{1 - \lambda}{\sigma_u^2} \right) \mathcal{R}^{-1}, \quad \text{para } n \text{ grande}$$

- Esto muestra que el RLS puede no llegar a la convergencia si λ es próximo a 1 y/o σ_u^2 es grande.
- En consecuencia, puede evitarse el fenómeno de cerrojo en el algoritmo RLS estándar utilizando un número suficientemente grande de bits de representación para el cálculo de $\mathbf{P}(n)$.

Efectos de precisión finita

Seguimiento de sistemas variantes en el tiempo

- Grado de no estacionaridad
- Criterios de seguimiento
- Desempeño de seguimiento en RLS y LMS
- Comparación de algoritmos LMS y RLS

Efectos de precisión finita

- Errores de cuantización
- Análisis para el algoritmo LMS
- Análisis para el algoritmo RLS