

Procesamiento Adaptativo de Señales

Juan E. Cousseau

Departamento de Ingeniería Eléctrica y Computadoras

Universidad Nacional del Sur

Contenidos

- **Conceptos básicos.**
- **Filtro de Wiener.**
- **Filtro de Kalman.**
- **Menor cuadrado mínimo (LMS)**
- **Cuadrados mínimos recursivo (RLS)**
- **Tracking e implementación.**
- **Aprendizaje automático.**

Aprendizaje Automático

- Algoritmos de Aprendizaje
- Capacidad, sobremodelado y submodelado
- Hiperparámetros y datos de validación
- Estimadores, Sesgo y Varianza
- Algoritmos de Aprendizaje Supervisado y No Supervisado
- Desarrollo de un Algoritmo de Aprendizaje Automático

Aprendizaje automático (AA)

- El área de **Aprendizaje Automático (Machine Learning)** es una extensión de procesamiento adaptivo en varios sentidos.
- Un aspecto en particular es que, más allá del entrenamiento, no se busca exactamente el funcionamiento optimizando un criterio específico, sino un desempeño adecuado en la etapa de **generalización**.
- La mayoría de los algoritmos de AA tienen configuraciones llamadas **hiperparámetros** que deben determinarse externamente al algoritmo de aprendizaje en sí; se analizará cómo configurarlos utilizando datos adicionales.
- La clasificación básica de algoritmo de AA está asociada al **aprendizaje supervisado** y al **aprendizaje no supervisado**.

Aprendizaje automático ...

Algoritmos de aprendizaje

Aprendizaje, una definición:

Se dice que un algoritmo aprende de la experiencia E con respecto a alguna clase de tareas T y medida de desempeño P , si su desempeño en las tareas en T , medido por P , mejora con la experiencia E ”.

Aprendizaje automático ...

Algoritmos de aprendizaje: La tarea T

Las tareas de aprendizaje automático suelen describirse en términos de cómo el sistema de AA debe procesar un ejemplo.

Un ejemplo es un conjunto de características medidas cuantitativamente de algún objeto o evento que queremos que el sistema de AA procese.

Normalmente representamos un ejemplo como un vector $\mathbf{x} \in \mathbb{R}^n$, donde cada entrada x_i del vector es una característica.

Aprendizaje automático ...

Algoritmos de aprendizaje: La tarea T ...

Algunas tareas típicas:

- Clasificación
- Clasificación eficiente (rala)
- Regresión (interpolación, extrapolación)
- Detección de anomalías (outliers)
- Reducción de ruido
- Estructuración (transcripción, traducción)
- Estimación de una distribución

Aprendizaje automático ...

Algoritmos de aprendizaje: La medida de desempeño P

Normalmente, una medida de rendimiento P es **específica para la tarea T** que realiza el sistema.

Para clasificación y clasificación eficiente a menudo se mide la **precisión** del modelo (por ejemplo, tasa de error).

La elección de P no siempre es sencilla y objetiva, ya que debe tener **correspondencia con el comportamiento deseado del sistema** (por ejemplo, para regresión, ¿penalizar más errores medios frecuentes o errores grandes poco frecuentes?)

Aprendizaje automático ...

Algoritmos de aprendizaje: La experiencia E

Los algoritmos de AA se pueden clasificar en términos generales como **supervisados** o **no supervisados** según el tipo de experiencia disponible durante el proceso de aprendizaje.

Las tareas de AA suelen describirse en términos de cómo el sistema de AA debe procesar un **ejemplo** (conjunto de características medidas de algún objeto o evento).

Al conjunto de ejemplos se lo denomina **dataset** o **data points**.

Aprendizaje automático ...

Algoritmos de aprendizaje: La experiencia E ...

- Los algoritmos de **aprendizaje no supervisado** experimentan un conjunto de datos que contiene muchas características y luego aprenden propiedades útiles de la estructura de este dataset (por ejemplo, estimar la estadística de los datos, o realizar un agrupamiento por similitud o clustering).
- Los algoritmos de **aprendizaje supervisado** experimentan un conjunto de datos que contiene características, pero cada ejemplo también está asociado con una **etiqueta u objetivo**.
- El aprendizaje no supervisado implica observar varios ejemplos de un vector aleatorio x e intentar aprender implícita o explícitamente la distribución de probabilidad $p(x)$, o algunas propiedades interesantes de esa distribución.
- El aprendizaje supervisado implica observar varios ejemplos de un vector aleatorio x y un valor asociado o vector y , y aprender a predecir y a partir de x , generalmente estimando $p(y|x)$.

Aprendizaje automático ...

Algoritmos de aprendizaje: La experiencia E ...

- El aprendizaje no supervisado y el supervisado **no son conceptos completamente formales ni distintos** (sí ayudan a categorizar las tareas de AA).
- Tradicionalmente, se denomina **aprendizaje supervisado** a los problemas de **regresión, clasificación** y salida estructurada (transcripción, traducción). La estimación de densidad para apoyar otras tareas suele considerarse aprendizaje no supervisado.
- Algunos algoritmos de AA no se limitan a experimentar con un conjunto de datos fijo. Por ejemplo, los algoritmos de **aprendizaje por refuerzo (reinforcement learning)** interactúan con un entorno, por lo que existe un ciclo de retroalimentación entre el sistema de aprendizaje y sus experiencias.

Aprendizaje automático ...

Algoritmos de aprendizaje: La experiencia E ...

- La mayoría de los algoritmos de AA simplemente utilizan un dataset, que a su vez puede describirse de muchas maneras. En todos los casos, un dataset es una colección de ejemplos, que a su vez son colecciones de características.
- En el caso del aprendizaje supervisado, el **ejemplo contiene una etiqueta u objetivo, así como un conjunto de características**. Por ejemplo, si queremos usar un algoritmo de AA para reconocer objetos a partir de fotografías, necesitamos especificar qué objeto aparece en cada una de ellas. Podríamos hacerlo con un código numérico: 0 significa una persona, 1 un coche, 2 un gato, etc.
- A menudo, al trabajar con un dataset que contiene una **matriz de diseño** de observaciones X (diferentes ejemplos en cada fila y diferentes características en cada columna), también se provee de un **vector de etiquetas** y , donde y_i proporciona la etiqueta i .

Aprendizaje automático ...

Algoritmos de aprendizaje: Ejemplo

Ejemplo: Regresión lineal

- La definición de la tarea T es: predecir $y \in R$ a partir de m ejemplos $x \in R^n$, con $\hat{y} = w^T x$, donde w son las características que afectan la predicción (podría incluirse un término constante b : transformación afín).
- En relación a la medida de desempeño P, es posible tener en cuenta un dataset de validación (o generalización), formado por X^{test}, y^{test} , tal que la medida de desempeño sea el error medio cuadrático:

$$MSE_{test} = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{test}_i - y^{test}_i)^2$$


- Para diseñar un algoritmo que reduzca MSE_{test} cuando se lo entrena con un conjunto X^{train}, y^{train} , es posible minimizar en forma equivalente MSE_{train} .

Aprendizaje automático ...

Algoritmos de aprendizaje: Ejemplo ...

Esa minimización (derivando e igualando a 0) conduce a las conocidas ecuaciones normales como solución

$$\mathbf{w} = \left(\mathbf{X}^{trainT} \mathbf{X}^{train} \right)^{-1} \mathbf{X}^{trainT} \mathbf{y}^{train}$$



Ejemplo 1: Un problema de regresión lineal con un conjunto de entrenamiento compuesto por diez puntos de datos. Hay una característica a aprender: w_1 . La línea $y = w_1 x$ pasa lo más cerca posible de todos los puntos de entrenamiento. También, la minimización de MSE_{train}

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado

- Minimizar el error de entrenamiento se reduce a un problema de optimización.
- El principal desafío del AA reside en que debemos obtener buenos resultados con datos nuevos e inéditos, no solo con aquellos con los que se entrenó nuestro modelo: **generalización**.
- La teoría del aprendizaje estadístico ofrece algunas respuestas. Por ejemplo, elegir un **proceso común de generación de datos entre el dataset de generalización (test) y el de entrenamiento**, y que sean i.i.d (datos independientes e idénticamente distribuidos).

Los factores que determinan el comportamiento de un algoritmo de AA son:

1. **hacer el error de entrenamiento pequeño y**
2. **hacer la diferencia de errores de entrenamiento y generalización (test) pequeña.**

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

- Estos dos factores corresponden a los dos desafíos centrales de AA: el **submodelado** y el **sobremodelado**.
- El **submodelado** ocurre cuando el modelo no puede obtener un error suficientemente bajo en el dataset de entrenamiento.
- El **sobremodelado** ocurre cuando la diferencia entre el error de entrenamiento y el error de generalización (test) es demasiado grande.
- Es posible controlar la característica de sobremodelado o submodelado de un modelo modificando su **capacidad**. Informalmente, la capacidad de un modelo es su habilidad para adaptarse a una amplia variedad de funciones.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

- Una forma de controlar la capacidad de un algoritmo de AA es eligiendo su **espacio de hipótesis** (conjunto de modelos que el algoritmo de AA puede seleccionar como solución).
- Ejemplo, para regresión lineal, es posible extender el modelo e incluir polinomios,

$$\hat{y} = b + w_1x + w_2x^2$$


- Los algoritmos de AA generalmente funcionan mejor cuando su capacidad es adecuada a la complejidad real de la tarea que deben realizar y a la cantidad de datos de entrenamiento que se les proporcionan.
- Los modelos con capacidad insuficiente no pueden resolver tareas complejas. Los modelos con alta capacidad pueden resolver tareas complejas, pero cuando es mayor que la necesaria, se sobremodela.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

Ejemplo 2: Se ajustan 3 modelos a un conjunto de entrenamiento. Los datos de entrenamiento se generaron sintéticamente, muestreando aleatoriamente los valores de x y seleccionando y de forma determinística mediante una función cuadrática.

- Una **función lineal** ajustada a los datos presenta submodelado: no puede capturar la curvatura presente en ellos.
- Una **función cuadrática** ajustada a los datos se generaliza correctamente a puntos no visibles. No presenta un grado significativo de sobremodelado ni submodelado.
- Un **polinomio de grado 9** ajustado a los datos presenta sobremodelado. La solución pasa por todos los puntos de entrenamiento con exactitud, pero no se obtiene la estructura correcta.



Aprendizaje automático ...

Capacidad, sobremodelado y submodelado

- El modelo especifica qué familia de funciones usa el algoritmo de AA al variar los parámetros para reducir un objetivo de entrenamiento. Se denomina capacidad representacional del modelo.
- El algoritmo adoptado generalmente logra una *capacidad efectiva* menor.
- *Principio de parsimonia*: establece que entre diferentes hipótesis de modelado en competencia que explican observaciones conocidas igualmente bien, se debe elegir la “más simple”.
- La *teoría del aprendizaje estadístico* proporciona medios para cuantificar la capacidad del modelo:

La diferencia entre el error de entrenamiento y el de generalización está acotada por encima por una cantidad que aumenta con la capacidad del modelo, pero se reduce con el número de ejemplos de entrenamiento.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...


- Si bien las funciones más simples tienen mayor probabilidad de generalizarse (con una pequeña diferencia entre el error de entrenamiento y el de generalización), se debe elegir un modelo de complejidad suficiente para lograr un error de entrenamiento bajo.
- Normalmente, el error de entrenamiento disminuye hasta alcanzar asintóticamente el valor mínimo de error posible a medida que aumenta la capacidad del modelo (suponiendo que la medida del error tiene un valor mínimo).
- Típicamente, el error de generalización presenta una curva en forma de U en función de la capacidad del modelo.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

Ejemplo 3: *Relación típica entre capacidad de modelado y errores.*

- Los errores de entrenamiento y de test se comportan de forma diferente. A la izquierda, tanto el error de entrenamiento como el de generalización son altos: *régimen de submodelado*.
- Al aumentar la capacidad, el error de entrenamiento disminuye, pero la diferencia entre el error de entrenamiento y el de generalización aumenta.
- Finalmente, la diferencia supera la disminución del error de entrenamiento, y resulta el régimen de sobremodelado (capacidad mayor que la óptima).



Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

- Para una capacidad arbitrariamente alta, es posible usar **modelos no paramétricos**.
- Se ejemplificó modelos paramétricos, como la regresión lineal. Los modelos paramétricos aprenden una función descrita por un *vector de parámetros cuyo tamaño es finito y fijo* antes de observar los datos.
- Los modelos no paramétricos no tienen esta limitación.

Ejemplo: *regresión del vecino más próximo.*

Este modelo simplemente almacena los valores $\mathbf{X}$ e $\mathbf{y}$ de entrenamiento. Para clasificar un ejemplo $\mathbf{x}$, el modelo busca la entrada más cercana en el conjunto de entrenamiento y devuelve el objetivo de regresión asociado. En otras palabras, $\hat{y} = y_i$, donde

$$i = \arg \min \|\mathbf{X}_i - \mathbf{x}\|_2^2.$$

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

- El **modelo ideal** está asociado a conocer la **distribución de probabilidad real** que genera los datos.
- Incluso un modelo no paramétrico incurrirá en errores en muchos problemas, debido a que aún puede haber ruido en la distribución.
- En el caso del aprendizaje supervisado, la función que mapea x a y puede ser estocástica, o y puede ser una función determinística que involucra otras variables además de las incluidas en x .
- El error que comete el modelo ideal al realizar predicciones con la distribución real $p(x, y)$ se denomina **error de Bayes**.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

- Los errores de entrenamiento y generalización varían según el tamaño del dataset. El error de generalización esperado nunca puede aumentar con el aumento del número de ejemplos de entrenamiento.

Ejemplo: Efecto del tamaño del dataset de entrenamiento en el error de entrenamiento y de generalización, así como en la capacidad óptima del modelo.


- Problema de **regresión basado en la adición de ruido a un polinomio de grado 5**. Se genera un único dataset y, a continuación, se generan conjuntos de entrenamiento de diferentes tamaños.
- Para cada tamaño, se generan 40 conjuntos de entrenamiento diferentes para trazar barras de error que muestran **intervalos de confianza del 95 %**.
- Se evalúa el MSE en los dataset de entrenamiento y de generalización para dos modelos diferentes: un modelo cuadrático y un modelo con un grado elegido para minimizar el error de generalización.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

Ejemplo 4:

- Para el modelo cuadrático, el error de entrenamiento aumenta a medida que aumenta el tamaño del dataset de entrenamiento (dataset más grandes son más difíciles de ajustar).
- Simultáneamente, el error de generalización disminuye (menos hipótesis incorrectas consistentes con los datos de entrenamiento).
- El modelo cuadrático no tiene suficiente capacidad para resolver la tarea, por lo que su error de generalización presenta asíntotas a un valor alto.
- El error de generalización con capacidad óptima es asíntótico al error de Bayes.




Aprendizaje automático ...

Capacidad, sobremodelado y submodelado ...

Ejemplo 4 ...

A medida que aumenta el tamaño del conjunto de entrenamiento, aumenta la capacidad óptima (mostrada aquí como el grado del regresor polinomial óptimo). La capacidad óptima se estabiliza tras alcanzar la complejidad suficiente para resolver la tarea.



Aprendizaje automático ...

Capacidad, sobremodelado y submodelado: Regularización

- La teoría del aprendizaje afirma que un algoritmo de AA puede generalizar correctamente a partir de un conjunto finito de ejemplos de entrenamiento. Esto parece contradecir algunos principios básicos de la lógica. El **razonamiento inductivo** (o la inferencia de reglas generales a partir de un conjunto limitado de ejemplos) **no es lógicamente válido**.
- El **teorema de la ausencia de recursos gratuitos** (no free lunch theorem) para el AA establece que, promediando **todas** las posibles distribuciones generadoras de datos, todos los *algoritmos de clasificación* tienen la misma tasa de error al clasificar puntos no observados previamente. En otras palabras, en cierto sentido, **ningún algoritmo de AA es universalmente mejor que otro**.
- Si se asumen solo los tipos de distribuciones de probabilidad encontradas en aplicaciones del mundo real, **es posible diseñar algoritmos de AA que funcionen bien con esas distribuciones**.

Aprendizaje automático ...

Capacidad, sobremodelado y submodelado: Regularización ...

- El método simple visto para modificar algoritmos de AA es aumentar la capacidad representacional del modelo (aumentando o disminuyendo el grado de un polinomio en el problema de regresión).
- También se podría modificar para tratar de dar alguna preferencia a un tipo de solución antes que a otra. Por ejemplo, es posible incluir en el criterio de entrenamiento la **ponderación de los pesos**:

$$J(\mathbf{w}) = MSE_{train} + \lambda \mathbf{w}^T \mathbf{w}$$

donde λ se elige para controlar la preferencia de $\mathbf{w}$.


Aprendizaje automático ...

Capacidad, sobremodelado y submodelado: Regularización ...

Ejemplo 5:

Se ajusta un modelo de regresión polinómica de grado 9 al dataset de entrenamiento del ejemplo 2. La función real es cuadrática. Se varía la ponderación de pesos para evitar el sobremodelado.

- λ muy grande, podemos forzar al modelo a aprender una función sin pendiente. Esto submodela porque solo puede representar una función constante.
- Valor medio de λ , el algoritmo de aprendizaje recupera una curva con la forma general correcta. Aunque el modelo es capaz de representar funciones con una forma mucho más compleja, el decaimiento de peso lo ha impulsado a utilizar una función más simple descrita por coeficientes más pequeños.
- λ cercano a 0 (utilizando la pseudoinversa para resolver el problema subdeterminado con regularización mínima), el polinomio de grado 9 sobremodela significativamente, como vimos en el ejemplo 2.



Aprendizaje automático ...

Capacidad, sobremodelado y submodelado: Regularización

- En general, es posible *regularizar* un modelo que aprende una función $f(x; \theta)$ añadiendo una penalización llamada regularizador a la función de costo. En el caso de la disminución de peso, el regularizador es $\Omega(w) = w^T w$.
- Existen muchas otras maneras de expresar preferencias por diferentes soluciones, tanto implícita como explícitamente. En conjunto, estos diferentes enfoques se conocen como *regularización*.
- La regularización es cualquier *modificación* que realizamos en un algoritmo de aprendizaje con el *objetivo de reducir su error de generalización*, pero no su error de entrenamiento.
- La *regularización* es una de las preocupaciones centrales del aprendizaje automático, solo superada en importancia por la optimización.

Aprendizaje automático ...

Hiperparámetros y conjuntos de validación

- La mayoría de los algoritmos de AA tienen varias configuraciones que podemos usar para controlar su comportamiento. Estas configuraciones se denominan **hiperparámetros**.
- Los valores de los hiperparámetros no son adaptados por el propio algoritmo de aprendizaje. Esto aplica especialmente a todos los hiperparámetros que controlan la capacidad de modelado.
- En el ejemplo de regresión polinómica, hay un solo hiperparámetro: el grado del polinomio, que actúa como hiperparámetro de capacidad. El valor λ , utilizado para controlar la intensidad de la disminución del peso, es otro ejemplo de hiperparámetro.

Aprendizaje automático ...

Hiperparámetros y conjuntos de validación ...

- Para estimar hiperparámetros es necesario un **conjunto de validación** de ejemplos que el algoritmo de entrenamiento no observa.
- Es clave que el dataset de generalización no se utilice para el entrenamiento, incluyendo la estimación de sus hiperparámetros.
- Entonces, usualmente se utiliza una proporción del dataset de entrenamiento (20%) para estimar hiperparámetros (el conjunto de validación).
- Cuando el dataset de entrenamiento y generalización es pequeño, dividir los datos puede no ser trivial (técnicas de validación cruzada).

Aprendizaje automático ...

Estimadores: sesgo y varianza

Sea $\{x_1, \dots, x_m\}$ un conjunto de m puntos de datos i.i.d. **un estimador puntual o estadística** es cualquier función de los datos:

$$\hat{\theta}_m = g(x_1, \dots, x_m)$$

El parámetro real θ es fijo pero desconocido, mientras que la estimación puntual $\hat{\theta}$ es una función de los datos.

Dado que los datos se extraen de un proceso aleatorio, cualquier función de los datos es aleatoria. Por lo tanto, $\hat{\theta}$ es una variable o un proceso aleatorio.

El estimador puntual también puede referirse a la estimación de la relación entre las variables de entrada y las variables objetivo: **función estimación**.

Aprendizaje automático ...

Estimadores: Sesgo

El **sesgo** de un estimador está definido por $b(\hat{\theta}_m) = E(\hat{\theta}_m) - \theta$. Un estimador es no sesgado si $b(\hat{\theta}_m) = 0$ y asintóticamente no sesgado si

$$\lim_{m \rightarrow \infty} b(\hat{\theta}_m) = 0, \text{ ó } \lim_{m \rightarrow \infty} E(\hat{\theta}_m) = \theta$$

Ejemplo: Para un conjunto i.i.d. $\{x_1, \dots, x_m\}$ la distribución de Bernoulli con media θ es

$$P(x_i; \theta) = \theta^{x_i} (1 - \theta)^{(1-x_i)}$$

Un estimador de la media es

$$\hat{\theta}_m = \frac{1}{m} \sum_{i=1}^m x_i$$

Y el sesgo será

$$b(\hat{\theta}_m) = \frac{1}{m} \sum_{i=1}^m E[x_i] - \theta = \frac{1}{m} \sum_{i=1}^m \sum_{x_i=0}^1 \left(\theta^{x_i} (1 - \theta)^{(1-x_i)} \right) - \theta = \frac{1}{m} \sum_{i=1}^m (\theta) - \theta = 0$$

Aprendizaje automático ...

Estimadores: Sesgo ...

Ejemplo: Estimador de la media de la distribución Gaussiana. Ahora $\{x_1, \dots, x_m\}$ son i.i.d. con

$$p(x_i : \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}\right)$$

Un estimador de la media es

$$\hat{\mu}_m = \frac{1}{m} \sum_{i=1}^m x_i$$

Y el sesgo será

$$b(\hat{\mu}_m) = \frac{1}{m} \sum_{i=1}^m E[x_i] - \mu = \left(\frac{1}{m} \sum_{i=1}^m \mu\right) - \mu = 0$$

Aprendizaje automático ...

Estimadores: Sesgo ...

Ejemplo: Estimadores de la varianza de una distribución Gaussiana. Un posible estimador de la varianza, utilizando el estimador de $\hat{\mu}_m$ anterior, es

$$\hat{\sigma}_m^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \hat{\mu}_m)^2$$

El sesgo será

$$b(\hat{\sigma}_m^2) = E \left[\frac{1}{m} \sum_{i=1}^m (x_i - \hat{\mu}_m)^2 \right] - \sigma^2 = \frac{m-1}{m} \sigma^2 - \sigma^2 = -\sigma^2/m$$

Otro estimador de la varianza es

$$\tilde{\sigma}_m^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \hat{\mu}_m)^2$$

cuyo sesgo

$$b(\tilde{\sigma}_m^2) = E \left[\frac{1}{m-1} \sum_{i=1}^m (x_i - \hat{\mu}_m)^2 \right] - \sigma^2 = \frac{m}{m-1} E[\hat{\sigma}_m^2] - \sigma^2 = 0$$

Aprendizaje automático ...

Estimadores: Varianza

La **varianza o el error estándar** de un estimador proporcionan una medida de cómo se espera que varíe la estimación a partir del proceso de generación de datos subyacente.

El error estándar de la media es

$$SE(\hat{\mu}_m) = \sqrt{\text{Var} \left[\frac{1}{m} \sum_{i=1}^m x_i \right]} = \frac{\sigma}{\sqrt{m}}$$

que, para pequeña cantidad de muestras, es usualmente sesgado.

Aprendizaje automático ...

Estimadores: Varianza ...

El error estándar de la media es muy útil en experimentos de AA.

Por el teorema del límite central, la media se distribuirá aproximadamente con una distribución normal. Entonces, se puede usar el error estándar para calcular la probabilidad de que el valor verdadero se encuentre en el intervalo elegido.

Por ejemplo, el intervalo de confianza del 95 % centrado en la media $\hat{\mu}_m$ es (para la distribución normal)

$$(\ell_i, \ell_s) = (\hat{\mu}_m - 1.96 SE(\hat{\mu}_m), \hat{\mu}_m + 1.96 SE(\hat{\mu}_m))$$

En experimentos de AA, el algoritmo A es dice mejor que el algoritmo B si $\ell_s^A < \ell_i^B$

Aprendizaje automático ...

Estimadores: Varianza ...

Ejemplo: Varianza de la distribución de Bernoulli.

La idea es obtener ahora la varianza del estimador

$$\hat{\theta}_m = \frac{1}{m} \sum_{i=1}^m x_i$$

Entonces

$$\text{Var}(\hat{\theta}_m) = \text{Var}\left(\frac{1}{m} \sum_{i=1}^m x_i\right) = \frac{1}{m^2} \sum_{i=1}^m \text{Var}(x_i) = \frac{1}{m^2} \sum_{i=1}^m \theta(1 - \theta) = \frac{1}{m} \theta(1 - \theta)$$

y la varianza del estimador disminuye en función del número de muestras del dataset.

Aprendizaje automático ...

Estimadores: Compromiso entre sesgo y varianza

¿Cómo se selecciona entre dos estimadores, uno con mayor sesgo y otro con mayor varianza?

Por ejemplo, para el caso de aproximar la función del ejemplo 2 (capacidad de modelado) y solo se tiene disponible la opción entre un modelo con un sesgo importante y uno con una varianza importante. ¿Cómo elegimos entre ellos?

Una alternativa, es comparar el error cuadrático medio (MSE) de las estimaciones.

$$MSE = E[(\hat{\theta} - \theta_m)^2] = Var(\hat{\theta}_m) - b(\hat{\theta}_m)^2$$


El MSE mide la desviación estándar esperada (en sentido del error cuadrático) entre el estimador y el valor real del parámetro θ .

Aprendizaje automático ...

Estimadores: Compromiso entre sesgo y varianza ...

Ejemplo: A medida que aumenta la capacidad (eje x), el sesgo (línea azul) tiende a disminuir y la varianza (verde) a aumentar, lo que genera otra curva en forma de U para el error de generalización (rojo).

Si variamos la capacidad a lo largo de un eje, se observa una capacidad óptima, con submodelado cuando la capacidad está por debajo de este óptimo y sobremodelado cuando está por encima (similar a la encontrada en los ejemplos 2 y 3 anteriores).



Aprendizaje automático ...

Estimadores: Consistencia

Se analizó las propiedades de varios estimadores para un conjunto de entrenamiento de tamaño fijo. También interesa el comportamiento de un estimador a medida que aumenta la cantidad de datos de entrenamiento.

En particular, es deseable que, a medida que aumenta el número de puntos de datos m , las estimaciones puntuales converjan al valor real de los parámetros correspondientes. Más formalmente, nos gustaría que

$$\text{plim}_{m \rightarrow \infty} \hat{\theta}_m = \theta$$

donde plim indica **convergencia en probabilidad**. O sea, $\forall \epsilon > 0$, $P(|\hat{\theta}_m - \theta| > \epsilon) \rightarrow 0$ para $m \rightarrow \infty$. Esta propiedad se denomina **consistencia** (débil).

La consistencia garantiza que el sesgo inducido por el estimador disminuya a medida que aumenta el número de datos (el dual no es cierto: el no sesgo asintótico no implica consistencia).

Aprendizaje automático ...

Estimación de Máxima Verosimilitud (ML)

¿Cómo diseñar un estimador?

En lugar de suponer una función y analizar su sesgo y varianza, es posible derivar funciones específicas que sean buenos estimadores para diferentes modelos.

El principio más común es **Máxima Verosimilitud (ML)**.

Consideremos un conjunto de m ejemplos independientes $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ extraídos de la distribución de los datos $p_{data}(x)$ desconocida.

Sea $p_{model}(x; \theta)$ una familia paramétrica de distribuciones de probabilidad sobre el mismo espacio de θ . El estimador ML de θ se define como

$$\theta_{ML} = \arg \max_{\theta} p_{model}(\mathbf{X}; \theta) = \arg \max_{\theta} \prod_{i=1}^m p_{model}(\mathbf{x}_i; \theta)$$

Aprendizaje automático ...

Estimación ML ...

Una versión más práctica (convirtiendo productos en sumatoria con logaritmos) y dividiendo por m (para reflejar la esperanza en términos de $\hat{p}_{data}(x)$), para la estimación ML es

$$\theta_{ML} = \arg \max_{\theta} E_{x \sim \hat{p}_{data}} \log p_{model}(\mathbf{x}; \theta)$$

Interpretación: estimación ML como la minimización de la diferencia entre la distribución $\hat{p}_{data}(x)$, del conjunto de entrenamiento y la distribución del modelo. Esa diferencia se mide con la **divergencia de Kullback-Leibler (KL)**

$$D_{KL}(\hat{p}_{data} \| p_{model}) = E_{x \sim \hat{p}_{data}} [\log \hat{p}_{data}(\mathbf{x}) - \log p_{model}(\mathbf{x})]$$

El término de la izquierda es una función únicamente del proceso de generación de datos, no del modelo. Entonces, para minimizar la divergencia KL, solo necesitamos minimizar p_{model} , que es el estimador ML.

ML puede verse como un intento de que la distribución del modelo $-E_{x \sim \hat{p}_{data}} \log p_{model}(\mathbf{x})$ se parezca a la distribución de los datos $\hat{p}_{data}$, ya que no se conoce la que genera los datos reales p_{data} .

Aprendizaje automático ...

Estimación ML: Relación con MSE

El estimador ML se puede extender al objetivo de estimar una probabilidad condicional $P(y|x; \theta)$ para predecir y dado x (base de la mayor parte del AA).

Si $\mathbf{X}$ representa todas nuestras entradas e $\mathbf{Y}$ todas las salidas observadas, entonces el estimador ML condicional es

$$\theta_{ML} = \arg \max_{\theta} P(\mathbf{Y}|\mathbf{X}; \theta)$$

Si se supone que las muestras son i.i.d., esto se puede descomponer en

$$\theta_{ML} = \arg \max_{\theta} \sum_{i=1}^m P(\mathbf{y}_i|\mathbf{x}_i; \theta)$$

Aprendizaje automático ...

Estimación ML: Relación con MSE ...

Ejemplo: Regresión lineal como ML.

En lugar de producir una única predicción $\hat{y}$, ahora el modelo produce $p(y|x)$. Con un conjunto de entrenamiento infinitamente grande, se tendrían varios ejemplos de entrenamiento con el mismo valor de entrada x pero diferentes valores de y .

El objetivo del algoritmo de aprendizaje ahora es ajustar la distribución $p(y|x)$ a todos esos diferentes valores de y que son compatibles con x .

Definimos $p(y|x) = \mathcal{N}(y; \hat{y}(x; w), \sigma^2)$. La función $\hat{y}(x; w)$ es la estimación de la media de la gaussiana. Se asume que la varianza es una constante σ^2 elegida por el usuario.

Aprendizaje automático ...

Estimación ML: Relación con MSE ...

Ejemplo: Regresión lineal como ML...

Dado que se supone que los ejemplos son i.i.d., el estimador ML condicional es ahora

$$\begin{aligned} \mathbf{w}_{ML} &= \arg \max_{\mathbf{w}} \sum_{i=1}^m \log p(y_i | \mathbf{x}_i; \mathbf{w}) \\ &= \arg \max_{\mathbf{w}} \left[-m \log \sigma - \frac{m}{2} \log(2\pi) - \sum_{i=1}^m \frac{\|\hat{y}_i - y_i\|^2}{2\sigma^2} \right] \end{aligned}$$

donde $\hat{y}_i$ es la salida de regresión lineal de $\mathbf{x}_i$.

Maximizar esta expresión es equivalente a minimizar

$$MSE_{train} = \frac{1}{m} \sum_{i=1}^m \|\hat{y}_i - y_i\|^2$$

Aprendizaje automático ...

Estimación ML: Propiedades

El principal atractivo del estimador ML es que es **consistente** (convergencia al verdadero valor con $m \rightarrow \infty$), si se cumple:

- La distribución real p_{data} debe encontrarse dentro de la familia $p_{model}(\cdot; \theta)$ de modelos. Si no, ningún estimador puede recuperar p_{data} .
- La distribución real p_{data} debe corresponder exactamente a un valor de θ . De lo contrario, el ML puede recuperar el p_{data} correcto, pero no podrá determinar qué valor de θ se utilizó en la generación de datos.

Sin embargo, varios estimadores consistentes pueden tener diferente **eficiencia estadística** (diferentes m para obtener igual error de generalización).

Para el caso de **modelado paramétrico**, el MSE obtenido del ML disminuye a mayor m . Para m suficientemente grande, la cota inferior de Cramer-Rao muestra que **no existe otro estimador consistente con menor MSE que el obtenido con ML**.

Aprendizaje automático ...

Estadística Bayesiana

El estimador ML obtiene un único valor de θ y la posterior realización de todas las predicciones basadas en esa estimación. Otro enfoque es considerar todos los valores posibles de θ al realizar una predicción. Este último es el dominio de la **estadística bayesiana**, donde **el objetivo es la estadística (distribución) de θ** .

En la perspectiva bayesiana se utiliza la probabilidad para reflejar los grados de certeza de los estados de conocimiento. El conjunto de datos se observa directamente y, por lo tanto, no es aleatorio. Por otro lado, el parámetro real θ es desconocido o incierto y, por lo tanto, se representa como una variable aleatoria.

Antes de observar los datos, representamos nuestro conocimiento de θ mediante la distribución de probabilidad a priori, $p(\theta)$.

Aprendizaje automático ...

Estadística Bayesiana ...

Se dispone de un conjunto de muestras de datos $\{x_1, \dots, x_m\}$. Es posible recuperar el efecto de los datos en nuestra creencia sobre θ combinando $p(x_1, \dots, x_m | \theta)$, con la distribución a priori mediante la regla de Bayes:

$$p(\theta | x_1, \dots, x_m) = \frac{p(x_1, \dots, x_m | \theta) p(\theta)}{p(x_1, \dots, x_m)}$$

En los escenarios donde se suele utilizar la estimación bayesiana, la distribución a priori se elige suficientemente general (uniforme o gaussiana) de forma que brinde alta entropía (información).

La observación de los datos suele provocar que la distribución posterior pierda entropía y se concentre en unos pocos valores altamente probables de los parámetros.

Aprendizaje automático ...

Estadística Bayesiana ...

Dos diferencias con la estimación ML:

- La estimación Bayesiana se **orienta a estimar la distribución del parámetro θ y no un valor puntual** como en ML.
- En la estimación Bayesiana, después de observar m muestras, la distribución de la próxima x_{m+1} está dada (simplemente integrando) por

$$p(x_{m+1}|x_1, \dots, x_m) = \int p(x_{m+1}|\theta) p(\theta|x_1, \dots, x_m) d\theta$$

- El uso de la distribución a priori de la estimación Bayesiana **desplaza la densidad de probabilidad** a regiones del espacio de parámetros que son preferidas a priori.

Aprendizaje automático ...

Estadística Bayesiana ...

Ejemplo: Regresión lineal Bayesiana.

En regresión lineal, se aprende una función lineal a partir de un vector de entrada $x \in R^n$ para predecir el valor de un escalar $y \in R$. La predicción está parametrizada por $w \in R^n$: $\hat{y} = w^T x$.

Dado un conjunto de m muestras de entrenamiento (X, y) , la predicción sobre todo el conjunto será: $y = Xw$.

Expresada como una distribución condicional gaussiana en y , se tiene:

$$p(y|X, w) = \mathcal{N}(y; Xw, I) \propto \exp \left(-\frac{1}{2} (y - Xw)^T (y - Xw) \right),$$

donde se asume que la varianza de y es unitaria.

Aprendizaje automático ...

Estadística Bayesiana ...

Ejemplo: Regresión lineal Bayesiana...

Para determinar la distribución posterior sobre w , primero es necesario especificar una distribución a priori. Esta distribución a priori debe reflejar nuestra creencia ingenua sobre el valor de estos parámetros.

Si bien a veces resulta difícil o poco natural expresar nuestras creencias previas en términos de los parámetros del modelo, en la práctica se suele asumir una distribución bastante amplia que exprese un alto grado de incertidumbre sobre θ .

Para parámetros de valor real, es común usar una distribución gaussiana como distribución a priori:

$$p(w) = \mathcal{N}(w; \mu_0, \Lambda_0) \propto \exp\left(-\frac{1}{2}(w - \mu_0)^T \Lambda_0^{-1}(w - \mu_0)\right),$$

donde μ_0 y Λ_0 son el vector media y matriz covarianza correspondientes.

Aprendizaje automático ...

Estadística Bayesiana ...

Ejemplo: Regresión lineal Bayesiana...

Con las definiciones: $\Lambda_m = (\mathbf{X}^T \mathbf{X} + \Lambda_0^{-1})^{-1}$ y $\mu_m = (\mathbf{X}^T \mathbf{y} + \Lambda_0^{-1} \mu_0)$, la distribución a posteriori será

$$\begin{aligned} p(\mathbf{w} | \mathbf{X}, \mathbf{y}) &\propto p(\mathbf{y} | \mathbf{X}, \mathbf{w}) p(\mathbf{w}) \\ &\propto \exp \left(-\frac{1}{2} (\mathbf{w} - \mu_m)^T \Lambda_m^{-1} (\mathbf{w} - \mu_m) + \frac{1}{2} \mu_m^T \Lambda_m^{-1} \mu_m \right) \\ &\propto \exp \left(-\frac{1}{2} (\mathbf{w} - \mu_m)^T \Lambda_m^{-1} (\mathbf{w} - \mu_m) \right) \end{aligned}$$

donde se han omitido todos los términos que no incluyen $\mathbf{w}$.

Efecto de la inferencia bayesiana: en general se hace $\mu_0 = \mathbf{0}$. Si además $\Lambda_0 = \frac{1}{\alpha} \mathbf{I}$, entonces μ_m proporciona la misma estimación que la regresión lineal ML con la penalización $\alpha \mathbf{w}^T \mathbf{w}$.

La diferencia más importante es que la estimación bayesiana proporciona una matriz covarianza Λ_m que muestra la probabilidad de todos los diferentes valores de $\mathbf{w}$, no solo μ_m .

Aprendizaje automático ...

Estimación de Máximo a posteriori (MAP)

Si se requiere una estimación puntual (no la distribución) del parámetro θ , en lugar de volver a la estimación ML, se usa algunas de las ventajas del enfoque bayesiano al permitir que la distribución a priori influya en la elección de la estimación puntual.

Una forma es elegir la estimación puntual **a posteriori máxima (MAP)**. La estimación MAP elige el punto de máxima probabilidad posterior

$$\theta_{MAP} = \arg \max_{\theta} p(\theta | x) = \arg \max_{\theta} \log p(x | \theta) + \log p(\theta)$$

Es posible reconocer en el lado derecho, $\log p(x | \theta)$, el término estándar de log-verosimilitud, y $\log p(\theta)$, correspondiente a la distribución a priori.

Aprendizaje automático ...

Estimación de Máximo a posteriori (MAP)

Ejemplo: Regresión lineal con MAP.

Se considera un modelo de regresión lineal con una distribución a priori gaussiana sobre w . Si esta distribución a priori es $\mathcal{N}(w; 0, \frac{1}{\lambda} I)$, entonces el término $\log p(\theta)$, anterior es proporcional a la conocida penalización $\lambda w^T w$.

La inferencia MAP bayesiana con una distribución a priori gaussiana sobre los pesos corresponde, por lo tanto, a la ponderación de los pesos.

Al igual que con la inferencia bayesiana completa, la inferencia bayesiana MAP tiene la ventaja de aprovechar la información proporcionada por la distribución a priori que no se encuentra en los datos de entrenamiento.

Esta información adicional ayuda a reducir la varianza en la estimación puntual de MAP (en comparación con la estimación de ML). Sin embargo, esto conlleva un mayor sesgo (por el término de ponderación).

Aprendizaje automático ...

Estimación de Máximo a posteriori (MAP)

- Muchas estrategias de estimación regularizada, como el aprendizaje ML regularizado con decaimiento de pesos, pueden interpretarse como una aproximación de MAP a la inferencia bayesiana.
- Este punto de vista se aplica cuando la regularización consiste en añadir un término adicional a la función objetivo que corresponde a $\log p(\theta)$. No todas las penalizaciones de regularización corresponden a la inferencia bayesiana MAP.
- La inferencia bayesiana MAP proporciona una forma sencilla de diseñar términos de regularización complejos pero interpretables.

Aprendizaje automático ...

Aprendizaje supervisado

- Los algoritmos de AA son, en términos generales, algoritmos que aprenden a asociar una entrada con una salida, dado un conjunto de entrenamiento de ejemplos de entradas x y salidas y .
- En muchos casos, las salidas pueden ser difíciles de recopilar automáticamente y deben ser proporcionadas por un supervisor humano, pero el término sigue siendo válido incluso cuando los objetivos del conjunto de entrenamiento se recopilaran automáticamente.

Aprendizaje automático ...

Aprendizaje supervisado probabilístico

- Muchos de los algoritmos de aprendizaje supervisado se basan en la estimación de una distribución de probabilidad $p(y|x)$. Se diseñan **utilizando la estimación ML** para encontrar el mejor vector de parámetros θ para una familia paramétrica de distribuciones $p(y|x; \theta)$.
- Ya hemos visto que la **regresión lineal corresponde a la familia**

$$p(y|x; \theta) = \mathcal{N}(y; \theta^T x, I)$$

- Es posible **generalizar la regresión lineal a clasificación** definiendo una familia diferente de distribuciones de probabilidad. Si tenemos dos clases, la clase 0 y la clase 1, solo necesitamos especificar la probabilidad de una de ellas.

Aprendizaje automático ...

Aprendizaje supervisado probabilístico ...

- Una distribución sobre una variable binaria debe estar entre 0 y 1. Una forma de resolver este problema es utilizar la **función sigmoide logística** para comprimir el resultado en el intervalo (0, 1) e interpretar ese valor como una probabilidad:

$$p(y = 1|\mathbf{x}; \boldsymbol{\theta}) = \sigma(\boldsymbol{\theta}^T \mathbf{x}), \quad \sigma(z) = \frac{1}{1 + \exp(-z)}$$

- Este enfoque se conoce como **regresión logística** (aunque se usa para clasificación).
- **No existe una solución cerrada** para los coeficientes óptimos de la regresión logística. En su lugar, se pueden obtener minimizando la función log-verosimilitud negativa (NLL) **mediante técnicas de gradiente** (Steepest Descent).
- Esta misma estrategia se puede aplicar a prácticamente cualquier problema de aprendizaje supervisado, escribiendo una familia paramétrica de distribuciones de probabilidad condicional sobre el tipo correcto de variables de entrada y salida.

Aprendizaje automático supervisado ...

Máquinas de vector de soporte

- Uno de los enfoques más influyentes para el aprendizaje supervisado es la **máquina de vector de soporte** (SVM). Este modelo es similar a la regresión logística, ya que se basa en una función lineal $w^T x + b$, pero la SVM no proporciona probabilidades, sino que solo **genera una identidad de clase**.
- La SVM define que la clase positiva está presente cuando $w^T x + b > 0$ y lo contrario para la clase negativa.
- Una innovación clave asociada con las SVM es el uso del **kernel**: muchos algoritmos de AA pueden escribirse exclusivamente en términos de productos escalares. Por ejemplo, la función lineal utilizada por la SVM puede reescribirse como

$$w^T x + b = \sum_{i=1}^m \alpha_i x^T x_i + b$$

donde x_i es una muestra de entrenamiento y α_i son coeficientes.

Aprendizaje automático supervisado ...

Máquinas de vector de soporte ...

- Esto permite reemplazar ~~por~~ la salida de una función característica dada $\phi(\mathbf{x})$ y el producto escalar con una función $k(\mathbf{x}, \mathbf{x}_i) = \phi(\mathbf{x})^T \phi(\mathbf{x}_i)$, que define el kernel.

- Tras sustituir los productos escalares por evaluaciones kernel, podemos realizar predicciones utilizando la función

$$f(\mathbf{x}) = b + \sum_{i=1}^m \alpha_i k(\mathbf{x}, \mathbf{x}_i)$$

- Esta función es en general no lineal en $\mathbf{x}$, pero si es lineal la relación entre $\phi(\mathbf{x})$ y $f(\mathbf{x})$, lo mismo que la relación entre α y $f(\mathbf{x})$.
- La función basada en kernel es equivalente a preprocesar los datos aplicando $\phi(\mathbf{x})$ a todas las entradas y, posteriormente, aprendiendo un modelo lineal en el **nuevo espacio transformado**.

Aprendizaje automático supervisado ...

Máquinas de vector de soporte ...

El kernel es muy útil por dos razones:

- Permite aprender modelos no lineales en función de x mediante técnicas de optimización convexa que garantizan una convergencia eficiente. Esto es posible al considerar ϕ fijo y optimizar solo α_i .
- El kernel $k(\cdot, \cdot)$ suele admitir una implementación significativamente más simple que construir ingenuamente dos vectores $\phi(x)$ y calcular explícitamente su producto escalar.

En algunos casos, $\phi(x)$ puede incluso ser de dimensión infinita, lo que resultaría en un costo computacional infinito si se usa una aproximación ingenua.

Aprendizaje automático supervisado ...

Máquinas de vector de soporte ...

- El kernel más comúnmente utilizado es el kernel gaussiano

$$k(\mathbf{u}, \mathbf{v}) = \mathcal{N}(\mathbf{u} - \mathbf{v}; \mathbf{0}, \sigma^2 \mathbf{I})$$

donde $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ es la densidad normal estándar. Este kernel se conoce como kernel de **función de base radial** (RBF), ya que su valor decrece a lo largo de las líneas en el espacio $\mathbf{v}$ que irradian desde $\mathbf{u}$.

- Podemos considerar el kernel gaussiano como una especie de **apareamiento de mapeos** (template matching). Un $\mathbf{x}$ asociado con un y se convierte en un mapeo para la clase y . Cuando una generalización $\mathbf{x}'$ está cerca de $\mathbf{x}$, el kernel gaussiano tiene una respuesta grande, lo que indica que $\mathbf{x}'$ es muy similar a $\mathbf{x}$. El modelo entonces asigna un peso alto a la y asociada.

Aprendizaje automático supervisado ...

Máquinas de vector de soporte ...

Una desventaja de SVM es que el costo de evaluar la función de decisión es lineal en el número de muestras de entrenamiento, ya que el i -ésimo ejemplo aporta un término $\alpha_i k(\mathbf{x}, \mathbf{x}_i)$ a la función de decisión.

Las SVM pueden mitigar esto entrenando los α_i para que sean mayormente 0. Clasificar un nuevo ejemplo requiere evaluar la función kernel solo para los ejemplos con α_i distinto de cero. Estos ejemplos de entrenamiento se conocen como **vectores de soporte**.

Las SVM con kernels genéricos (no lineales) tienen dificultades para generalizar correctamente. El resurgimiento del AA a través del denominado **aprendizaje profundo (deep learning)** se diseñó para superar estas limitaciones.

El renacimiento actual del aprendizaje profundo comenzó cuando se demostró (Hinton, 2006) que una **red neuronal podía superar el rendimiento de la SVM de kernel RBF**.

Aprendizaje automático supervisado ...

Máquinas de vector de soporte ...

Antes de la llegada del aprendizaje profundo, la principal forma de aprender modelos no lineales era usar la técnica del kernel en combinación con un modelo lineal.

Muchos algoritmos de aprendizaje con kernel requieren la construcción de una matriz ($m \times m$)

$G_{i,j} = k(x_i, x_j)$. Construir esta matriz tiene un costo $O(m^2)$, lo cual es claramente indeseable para conjuntos de datos con miles de millones de ejemplos.

A partir de 2006, el **aprendizaje profundo** resultó interesante inicialmente porque permite generalizar a nuevos ejemplos al entrenarse con conjuntos de datos con ordenes de tamaño 2 o 3 veces menores que los de SVM.

Aprendizaje automático ...

Aprendizaje no supervisado

- Los algoritmos no supervisados son aquellos que solo experimentan **características**, pero no una señal de supervisión.
- De manera informal, el aprendizaje no supervisado se refiere a la mayoría de los intentos de extraer información de una distribución que no requieren la intervención humana para anotar ejemplos.
- El término suele asociarse con:
 - la estimación de una distribución,
 - el aprendizaje para extraer muestras de una distribución,
 - el aprendizaje para eliminar el ruido de alguna distribución,
 - la búsqueda de una variedad cercana a la que se encuentran los datos o
 - la agrupación de los datos en grupos de ejemplos relacionados.

Aprendizaje automático ...

Aprendizaje no supervisado ...

Una tarea clásica de aprendizaje no supervisado **consiste en encontrar la mejor representación** de los datos (clave para deep learning): que conserve la mayor cantidad de información de x , a la vez que genere la representación más simple.

Existen múltiples maneras de definir una representación más simple:

- **de menor dimensión**, intentan comprimir la mayor cantidad de información posible sobre en una representación más pequeña.
- **representaciones ^{x} dispersas**, conducen a una representación (de mayor dimensión) cuyas entradas son mayoritariamente ceros. y
- **representaciones independientes**, intentan desentrañar las fuentes de variación subyacentes a la distribución de los datos, de modo que las dimensiones de la representación sean estadísticamente independientes.

Por supuesto, estos criterios no son mutuamente excluyentes (reducir el tamaño conduce a encontrar y eliminar redundancias).

Aprendizaje automático supervisado: Análisis de componentes principales (PCA)

- Es posible considerar PCA como un algoritmo de aprendizaje no supervisado que aprende una representación de los datos.
- Esta representación se basa en dos de los criterios descritos anteriormente para una representación simple: de menor dimensionalidad y cuyos elementos no tienen correlación lineal entre sí.
- Para lograr una independencia total, un algoritmo de aprendizaje de representaciones también debe eliminar las relaciones no lineales entre las variables.

Aprendizaje automático supervisado: Análisis de componentes principales (PCA)

- PCA se puede entrenar para aprender una transformación lineal ortogonal de los datos que proyecta una entrada x en una representación z .
- Es posible aprender una representación unidimensional que reconstruya mejor los datos originales (en el sentido del error cuadrático medio) y que esta representación corresponda al **primer componente principal** (asociada a la descomposición en valores singulares) de los datos.
- Por lo tanto, es posible utilizar PCA como un método simple y eficaz de reducción de dimensionalidad que preserva la mayor cantidad posible de información en los datos (de nuevo, medida mediante el error de reconstrucción por mínimos cuadrados).

Aprendizaje automático supervisado: Análisis de componentes principales (PCA)

- Apuntando a otra propiedad se discutirá cómo la representación de PCA decorrelaciona la representación original de los datos $\mathbf{X}$ de $(m \times n)$.
- PCA encuentra una representación $\mathbf{z} = \mathbf{x}^T \mathbf{W}$ (a través de una transformación lineal), donde $\text{Var}[\mathbf{z}]$ es diagonal (las componentes están decorrelacionadas).
- Las componentes principales se pueden analizar mediante la **descomposición en valores singulares**. Específicamente, sean $\mathbf{W}$ ($\mathbf{W}^T \mathbf{W} = \mathbf{I}$) de $(n \times n)$ los vectores singulares por derecha, $\mathbf{U}$ ($\mathbf{U}^T \mathbf{U} = \mathbf{I}$) de $(m \times m)$ los vectores singulares por izquierda y Σ la matriz de valores singulares $(m \times n)$ de la descomposición

$$\mathbf{X} = \mathbf{U} \Sigma \mathbf{W}^T$$

Aprendizaje automático supervisado: Análisis de componentes principales (PCA)

Como

$$\mathbf{X}^T \mathbf{X} = (\mathbf{U} \mathbf{\Sigma} \mathbf{W}^T)^T \mathbf{U} \mathbf{\Sigma} \mathbf{W}^T = \mathbf{W} \mathbf{\Sigma}^2 \mathbf{W}^T$$

La matriz covarianza de las muestras será

$$\text{Var}[\mathbf{x}] = \frac{1}{m-1} \mathbf{X}^T \mathbf{X} = \frac{1}{m-1} \mathbf{W} \mathbf{\Sigma}^2 \mathbf{W}^T$$

Y para la nueva representación de PCA

$$\text{Var}[\mathbf{z}] = \frac{1}{m-1} \mathbf{Z}^T \mathbf{Z} = \frac{1}{m-1} \mathbf{W}^T \mathbf{X}^T \mathbf{X} \mathbf{W} = \frac{1}{m-1} \mathbf{W}^T \mathbf{W} \mathbf{\Sigma}^2 \mathbf{W}^T \mathbf{W} = \frac{1}{m-1} \mathbf{\Sigma}^2$$

Si bien la correlación es una categoría importante de dependencia entre los datos, también interesa aprender representaciones que desentrañen formas más complejas de dependencia de características que una simple transformación lineal.

Aprendizaje automático no supervisado: Agrupamiento de k medias (k-means clustering)

- Este algoritmo divide el conjunto de entrenamiento en k grupos diferentes de ejemplos cercanos entre sí. Usa un vector $\mathbf{h}$ ($k \times 1$) que representa una entrada $\mathbf{x}$. Si $\mathbf{x}$ pertenece al clúster i , entonces $h_i = 1$ y todas las demás entradas de $\mathbf{h}$ son cero.
- El código es un ejemplo de **representación dispersa**, ya que la mayoría de sus entradas son cero para cada entrada.
- Este tipo de código es un ejemplo extremo de representaciones dispersas que pierden muchas de las ventajas de una representación distribuida.
- El código tiene algunas ventajas estadísticas (la idea de que todos los ejemplos en el mismo grupo son similares entre sí) y tiene la ventaja computacional que toda la representación puede ser capturada por un solo entero.

Aprendizaje automático no supervisado: Agrupamiento de k medias (k-means clustering) ...

Se inicializa con k centroides diferentes $\{\mu_1, \dots, \mu_k\}$, alternando luego entre dos pasos hasta la convergencia:

1. cada ejemplo de entrenamiento se asigna al clúster i , donde i es el índice del centroide μ_i más cercano.
2. cada centroide μ_i se actualiza a la media de todos los ejemplos de entrenamiento x_j asignados al clúster i .

Una dificultad del algoritmo es que el problema de la agrupación está inherentemente mal condicionado, en el sentido de que no existe un criterio único que mida la correspondencia entre la agrupación de datos y el mundo real.

Aprendizaje automático no supervisado: Agrupamiento de k medias (k-means clustering) ...

- Por ejemplo, se ejecutan dos algoritmos de agrupación en un conjunto de datos compuesto por imágenes de camiones rojos, coches rojos, camiones grises y coches grises.
- Si solicitamos a cada algoritmo de agrupamiento que encuentre dos soluciones, uno podría encontrar una agrupación de coches y otra de camiones, mientras que el otro podría encontrar una agrupación de vehículos rojos y otra de vehículos grises.
- Si también ejecutamos un tercer algoritmo de agrupamiento, que permita determinar el número de agrupamientos, este podría asignar cuatro: coches rojos, camiones rojos, coches grises y camiones grises. Este nuevo agrupamiento ahora al menos captura información sobre ambos atributos, pero ha perdido información sobre la similitud.

Aprendizaje automático no supervisado: Agrupamiento de k medias (k-means clustering) ...

- Estos problemas ilustran algunas de las razones por las que podríamos preferir una **representación distribuida** a una representación dispersa.
- Una representación distribuida podría tener dos atributos para cada vehículo: uno que represente su color y otro que represente si se trata de un coche o un camión.
- Aún no está del todo claro cuál es la representación distribuida óptima (¿cómo puede el algoritmo de aprendizaje saber si los dos atributos que nos interesan son el color y la comparación entre coche y camión, en lugar del fabricante y la antigüedad?).
- Sin embargo, tener muchos atributos reduce la carga del algoritmo para adivinar qué atributo nos interesa y nos permite medir la similitud entre objetos de forma detallada comparando muchos atributos en lugar de comprobar si solo uno coincide.

Aprendizaje automático ...

Desarrollo de un algoritmo de AA

- Casi todos los algoritmos de AA pueden describirse como ejemplos particulares de una fórmula bastante simple: combinan la especificación de un conjunto de datos, una función costo, un procedimiento de optimización y un modelo.
- Por ej., el algoritmo de regresión lineal combina un conjunto de datos compuesto por $\mathbf{X}$ e $\mathbf{y}$, la función de costo

$$J(\mathbf{w}, b) = E_{\mathbf{x} \sim \hat{p}_{data}} \log p_{model}(\mathbf{y}|\mathbf{x})$$

la especificación del modelo $p_{model}(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}; \mathbf{x}^T \mathbf{w} + b, 1)$ y, en la mayoría de los casos, el algoritmo de optimización definido al resolver el gradiente del costo 0.

- Teniendo en cuenta que es posible reemplazar cualquiera de estos componentes prácticamente de forma independiente, se obtiene una amplia variedad de algoritmos.

Aprendizaje automático ...

Desarrollo de un algoritmo de AA ...

- La función costo más común es la log-verosimilitud negativa, de modo que al minimizarla se obtiene una estimación ML.
- La función costo también puede incluir términos adicionales, como los de regularización. Por ejemplo, podemos añadir la descomposición de pesos a la función costo de la regresión lineal para obtener

$$J(\mathbf{w}, b) = \lambda \|\mathbf{w}\|_2^2 = E_{x \sim \hat{p}_{data}} \log p_{model}(y|x)$$

Esto aún permite una optimización en forma cerrada.

- Si modificamos el modelo para que sea no lineal, la mayoría de las funciones costo ya no podrán optimizarse en forma cerrada. Esto requiere un procedimiento iterativo de optimización numérica, como el de gradiente.

Aprendizaje automático ...

Desarrollo de un algoritmo de AA ...

- La fórmula para construir un algoritmo de aprendizaje combinando modelos, costos y algoritmos de optimización admite tanto el aprendizaje supervisado como el no supervisado.
- El ejemplo de regresión lineal muestra cómo admitir el aprendizaje supervisado.
- El aprendizaje no supervisado se puede definir a través de un conjunto de datos que contenga solo $\mathbf{X}$ y también un costo y un modelo no supervisado adecuados.
- Por ejemplo, es posible obtener el primer vector PCA especificando que la función costo sea

$$J(\mathbf{w}) = E_{\mathbf{x} \sim \hat{p}_{data}} \|\mathbf{x} - r(\mathbf{x}; \mathbf{w})\|_2^2$$

mientras que el modelo se define con $\mathbf{w}$ de norma unitaria y la función de reconstrucción

$$r(\mathbf{x}) = \mathbf{w}^T \mathbf{x} \mathbf{w}.$$

Aprendizaje automático ...

Desarrollo de un algoritmo de AA ...

- En algunos casos, la función costo puede ser una función que no podemos evaluar por razones computacionales. En estos casos, aún podemos **minimizarla aproximadamente mediante optimización numérica iterativa**, siempre que tengamos alguna forma de aproximar sus gradientes.
- La mayoría de los algoritmos de AA utilizan esta fórmula, aunque puede que no sea evidente a primera vista. Si un algoritmo de AA parece especialmente único o diseñado a mano, generalmente se puede entender que **utiliza un optimizador de casos especiales**.
- Tener en cuenta que la mayoría de los algoritmos de AA pueden seguir esta receta ayuda a ver los diferentes algoritmos como parte de una **taxonomía de métodos para realizar tareas relacionadas que funcionan por razones similares**, en lugar de como una larga lista de algoritmos con justificaciones independientes.

Aprendizaje Automático

- Algoritmos de Aprendizaje
- Capacidad, sobremodelado y submodelado
- Hiperparámetros y datos de validación
- Estimadores, Sesgo y Varianza
- Algoritmos de Aprendizaje Supervisado y No Supervisado
- Desarrollo de un Algoritmo de Aprendizaje Automático